

西安交通大学
XI'AN JIAOTONG UNIVERSITY

人工智能
Artificial Intelligence

- 主讲：刘欢
- 西安交通大学计算机学院
- E-mail：huanliu@xjtu.edu.cn

- 6.1 绪论
- 6.2 模型评估与选择
- 6.3 线性模型
- 6.4 决策树
- 6.5 支持向量机
- 6.6 贝叶斯分类器
- 6.7 集成学习
- 6.8 聚类
- 6.9 降维
- 6.10 特征选择

西安交通大学 XI'AN JIAOTONG UNIVERSITY

第六章 机器学习

- 6.1 绪论
  - 6.1.1 定义
  - 6.1.2 应用
  - 6.1.3 基本术语

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1 绪论

机器学习是人工智能的一个重要分支，

是实现智能化的关键！

经典定义：利用经验改善系统自身的性能



经验 → 数据



随着该领域的发展，目前主要研究智能数据分析的理论和算法，并已成为智能数据分析技术的源泉之一

图灵奖连续授予在该方面取得突出成就的学者



Leslie Valiant
(1949 -)
(Harvard Univ.)
2011年度
“计算学习理论”奠基人

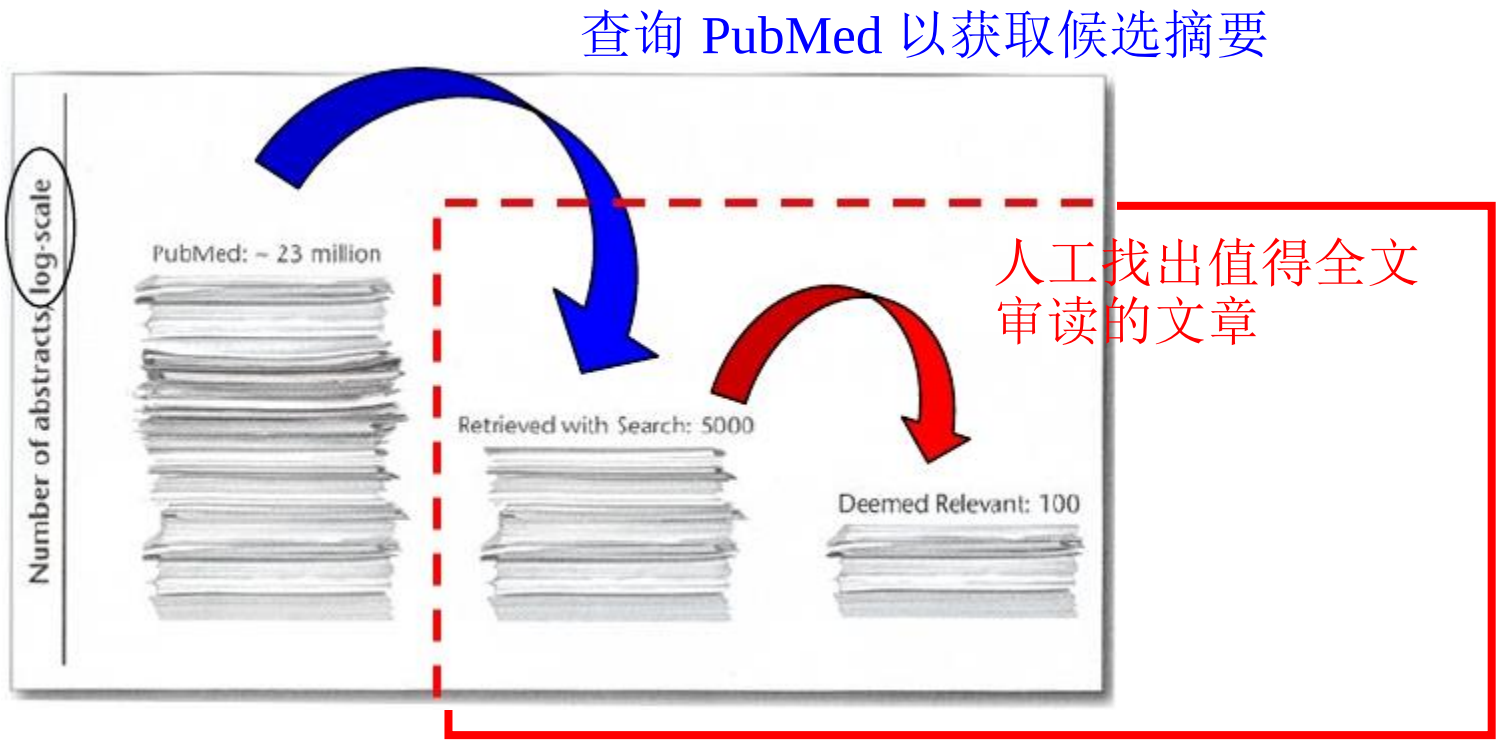


Judea Pearl
(1936 -)
(UCLA)
2012年度
“图模型学习方法”先驱

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.1 定义 — 例子

- 在“循证医学” （evidence-based medicine）中，针对特定的临床问题，先要对相关研究报告进行详尽评估

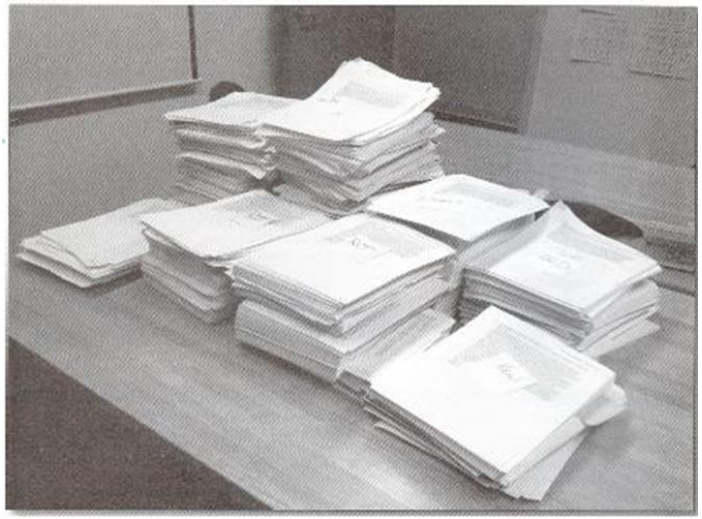


[C. Brodley et al., AI Magazine 2012]

6.1.1 定义 — 例子

- 在一项关于婴儿和儿童残疾的研究中，美国Tufts医学中心筛选了约 33,000 篇摘要。
- 尽管Tufts医学中心的专家效率很高，处理每篇摘要只需要30秒钟，但该工作仍花费了260小时。

每项新的研究都要重复该过程，且需要筛选的文章数在不断显著增长！

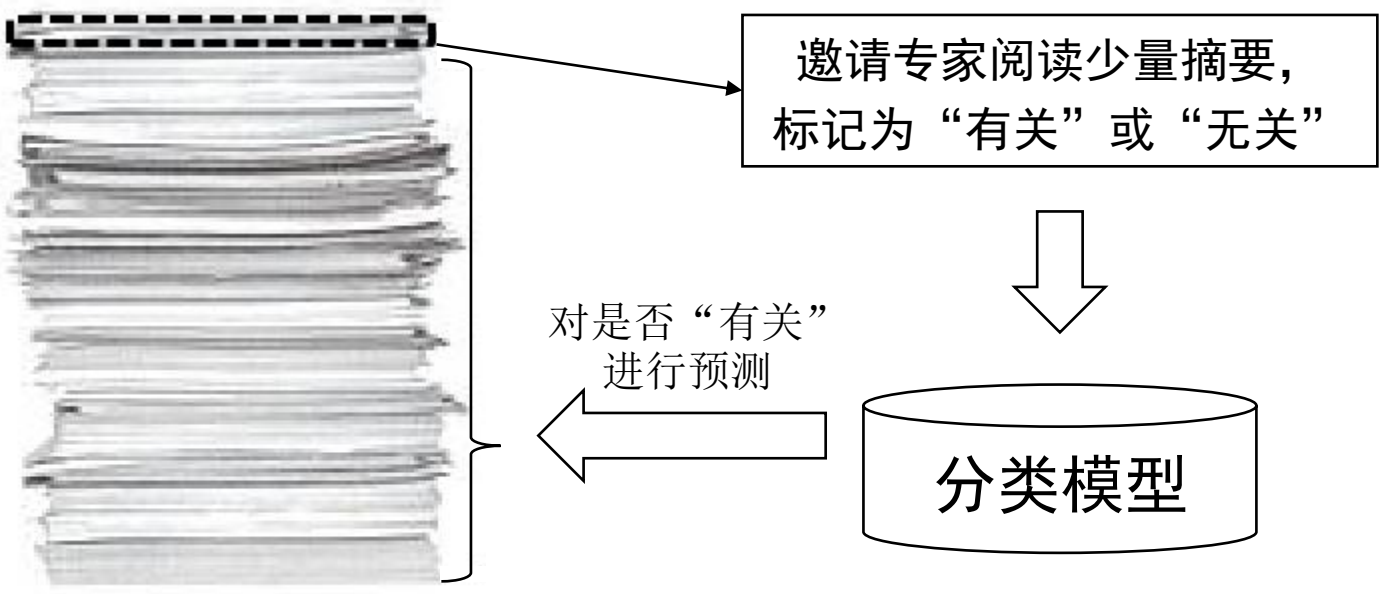


33,000 篇摘要中的一部分

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.1 定义 — 例子

- 为了降低昂贵的成本，Tufts医学中心引入了**机器学习**技术



人类专家只需阅读 **60** 篇摘要，系统的自动筛选精度就达到 **93%**

人类专家阅读 **1,000** 篇摘要，则系统的自动筛选敏感度达到 **96%**

(人类专家以前需阅读 **33,000** 篇摘要才能获得此效果)

6.1.1 定义

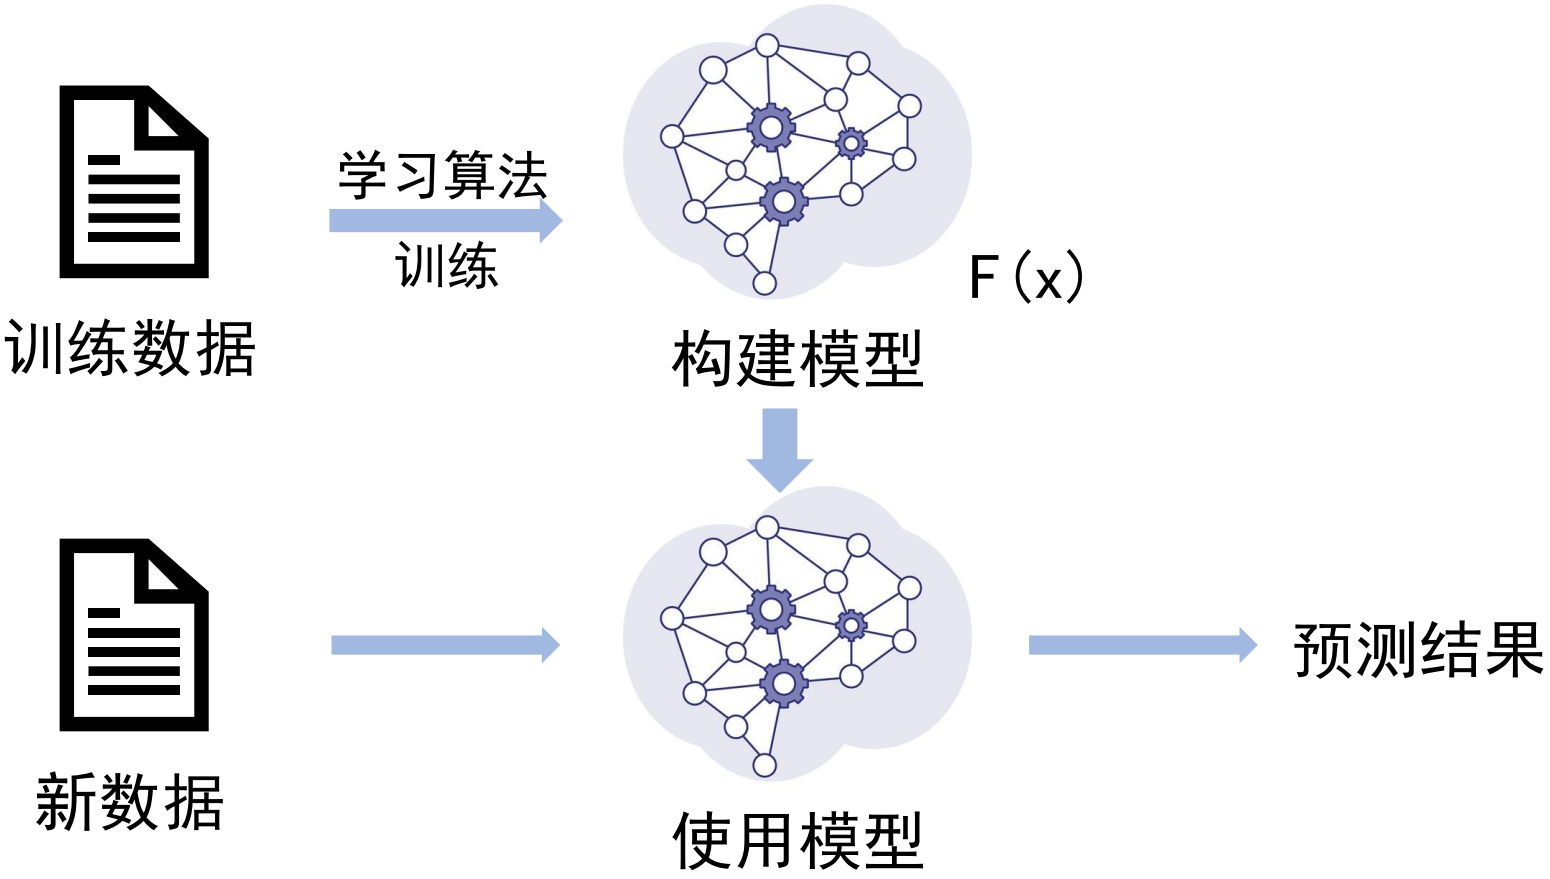
- 机器学习（Machine Learning）是一门涉及统计学、系统辨识、逼近理论、神经网络、优化理论、计算机科学、脑科学等诸多领域的交叉学科，研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识 结构使之不断改善自身的性能，是人工智能技术的核心。
- 基于数据的机器学习是现代智能技术中的重要方法之一，研究从观测数据（样本）出发寻找规律，利用这些规律对未来数据或无法观测的数据进行预测。

——人工智能标准化白皮书（2018版）

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.1 定义

典型机器学习过程



6.1.2 应用

机器学习能做什么？

机器学习已经改变了我们的世界！

- 机器学习的应用领域广泛而深远。
- 不管是在艺术、文化、政治、经济，还是我们日常生活的方方面面，机器学习都在发挥着重要作用。



西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 画作鉴别

画作鉴别（painting authentication）：识别画作的真伪





勃鲁盖尔（1863-1890）的作品？

梵高（1863-1890）的作品？







西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 画作鉴别

- 除专用技术手段外，笔触分析(brushstroke analysis)是画作鉴定的重要工具；它旨在从视觉上判断画作中是否具有艺术家的特有“笔迹”。
- 该工作对专业知识要求极高
  - 具有较高的绘画艺术修养
  - 掌握画家的特定绘画习惯
- 只有少数专家花费很大精力才能完成分析工作。

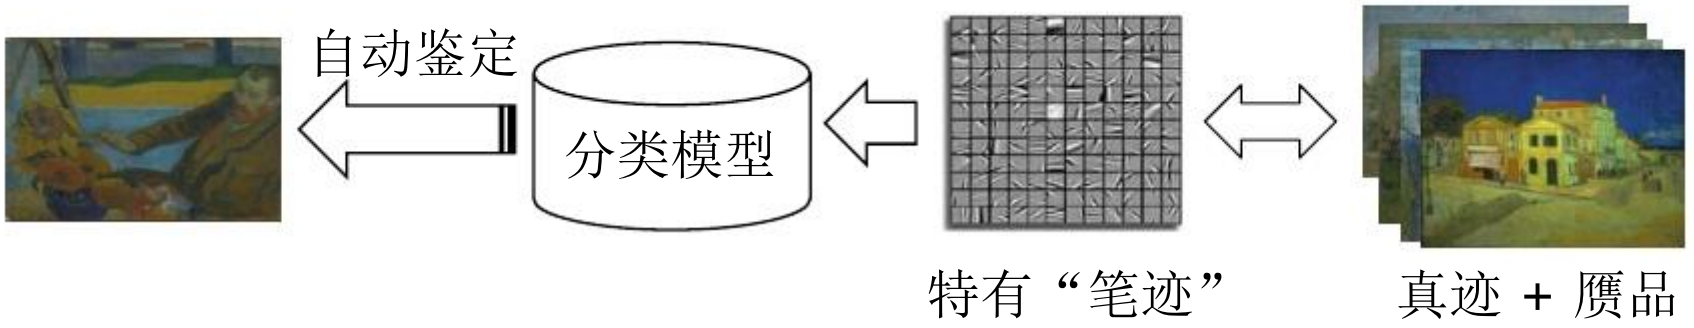




西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 画作鉴别

为了降低分析成本，引入机器学习技术



- Kröller Müller美术馆与Cornell等大学的学者对82幅梵高真迹和6幅赝品进行分析，自动鉴别精度达96%。
- Dartmouth学院、巴黎高师的学者对8幅勃鲁盖尔真迹和6幅赝品进行分析，自动鉴别精度达 100%
- **准确高效、门槛低、适用范围广**

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 古文献修复

古文献是进行历史研究的重要素材，但是其中很多损毁严重。

Dead Sea Scrolls (死海古卷)

- 1947年出土
- 超过30,000个羊皮纸片段

Cairo Genizah

- 19世纪末被发现
- 超过300,000个片段
- 散布于全球多家博物馆



高水平专家的大量精力
被用于古文献修复

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 古文献修复

古文献是进行历史研究的重要素材，但是其中很多损毁严重。



人工拼接书页十分困难

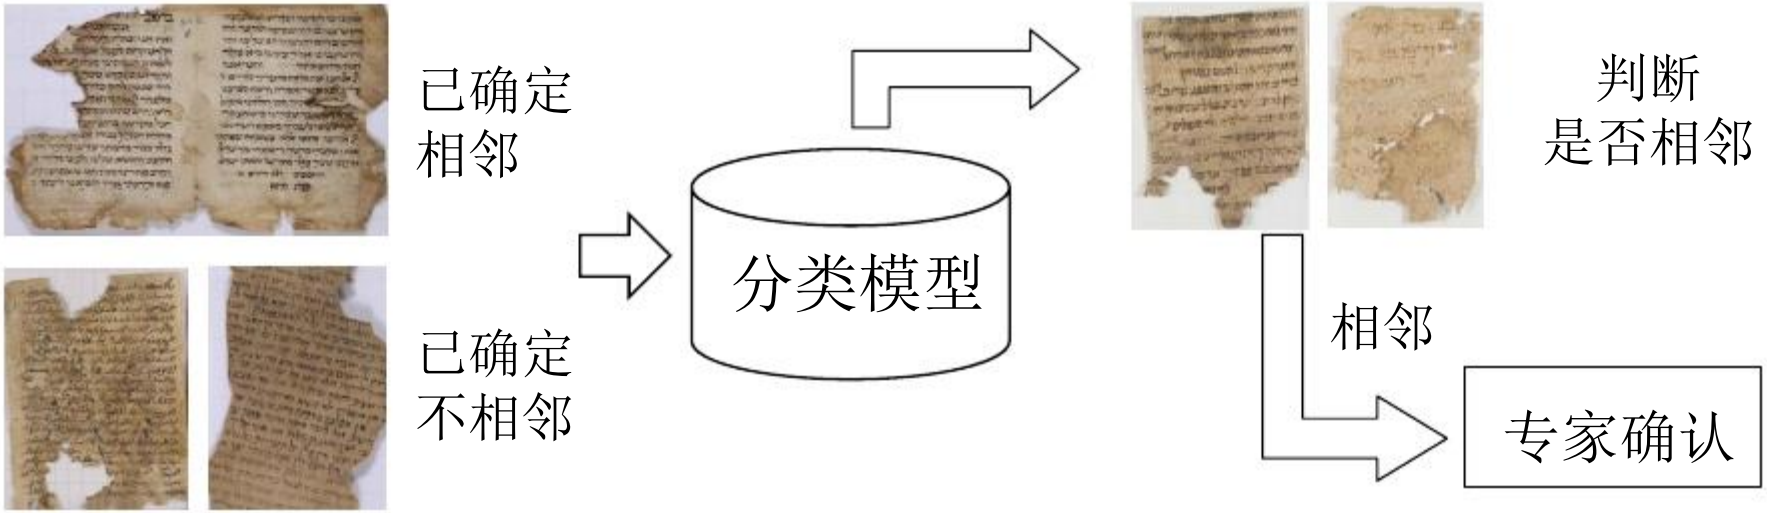
- 书页数量大，且分布在多处
- 部分损毁较为严重，字迹模糊
- 需要大量掌握古文字的专业人才

近年来，古文献的数字化浪潮给自动文学修复提供了机会

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 古文献修复

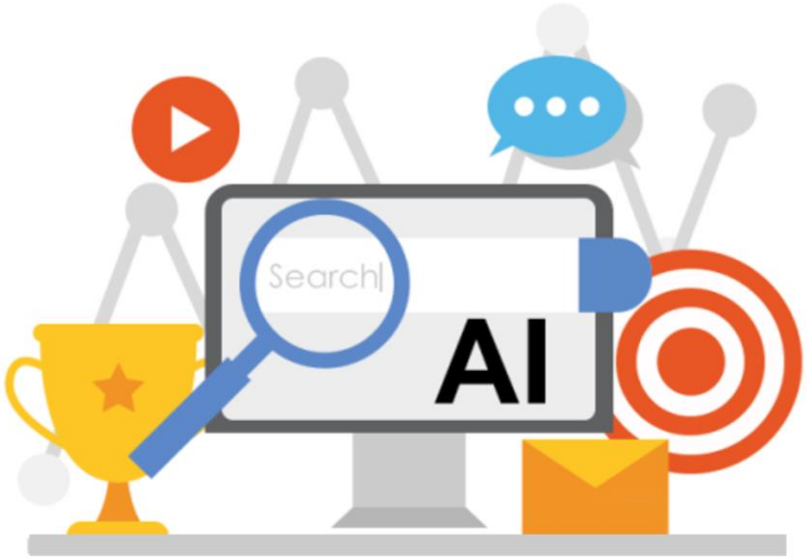
以色列特拉维夫大学的学者将机器学习用于自动的书页拼接



- 在Cairo Genizah测试数据上，系统的自动判断精度超过 93%
- 完成约 1,000 篇Cairo Genizah文章的拼接
- 过去整个世纪，数百人类专家只完成了几千篇文章拼接

西安交通大学 XI'AN JIAOTONG UNIVERSITY

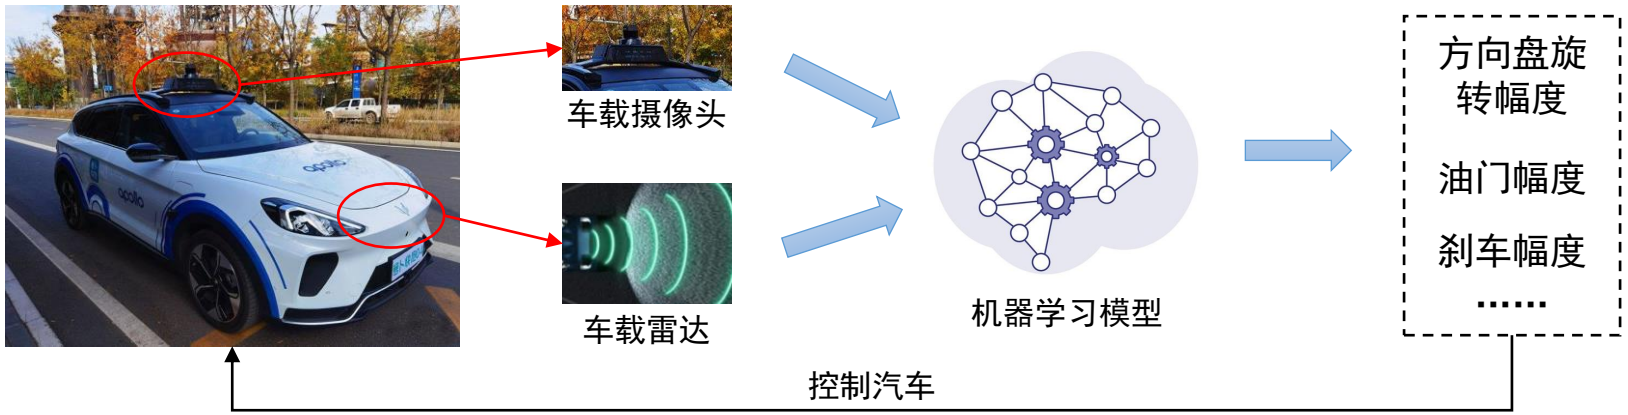
6.1.2 应用 — 现代搜索引擎



- 个性化搜索
- 语义搜索
- 用户意图识别
- 图像/视频搜索
- 排序优化
- 隐私保护与数据安全

……

6.1.2 应用 — 自动驾驶



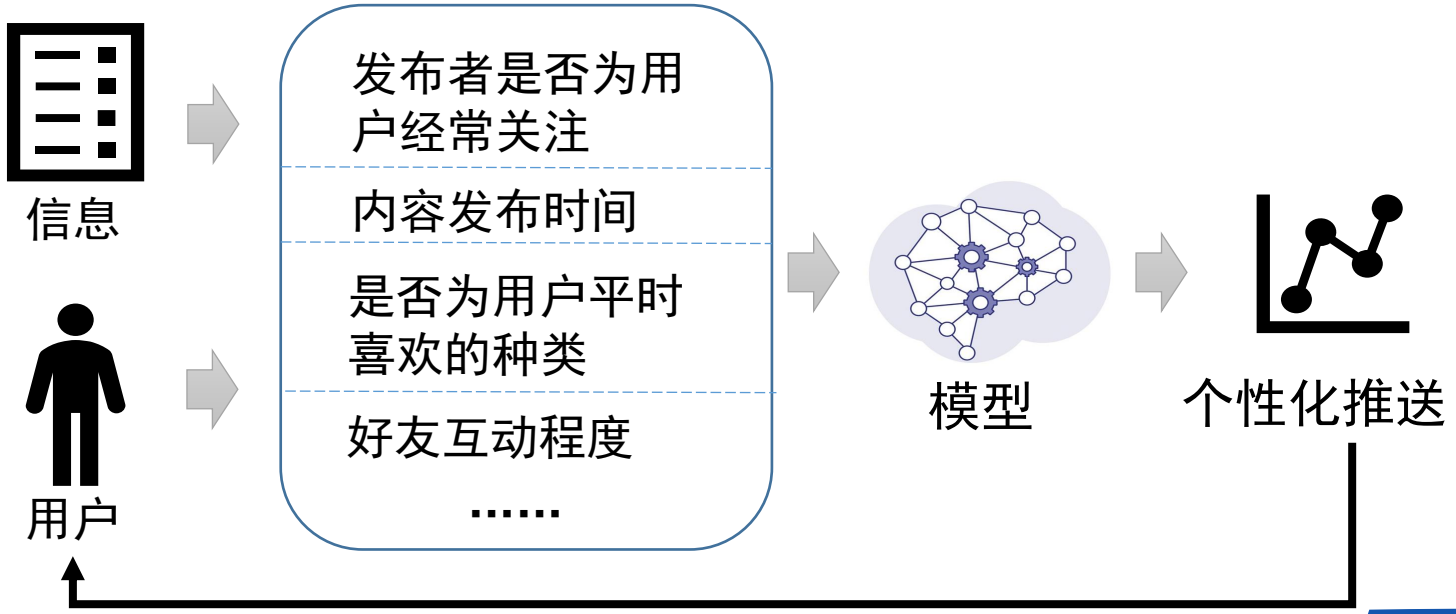
- 自动驾驶算法是指赋予自动驾驶汽车感知、决策和控制能力的软件和算法。
- 通过摄像头、激光雷达、雷达和 GPS 等传感器采集环境数据，利用计算机视觉、机器学习等人工智能技术对周围环境进行识别和理解，并根据分析结果做出安全驾驶决策。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.2 应用 — 美国选举

社交媒体大数据推送影响选民投票倾向

脸书（Facebook）在2016年竞选期间，根据网民社交账户的浏览记录和发表过的言论，将选民划分为不同类别，并且采取不同的信息推送，从而影响选民的政治意见。

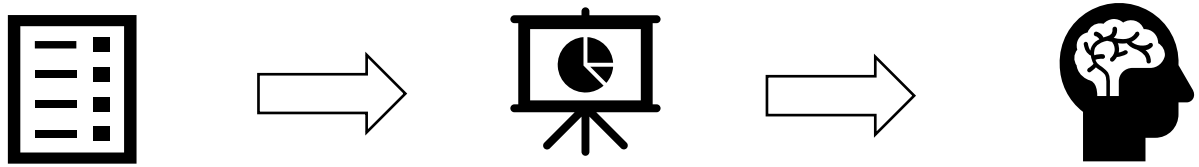


6.1.2 应用 — 美国选举

社交媒体大数据推送影响选民投票倾向

剑桥分析公司：

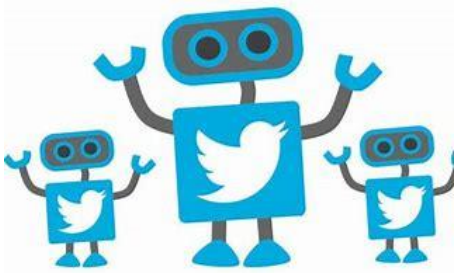
1. 数据收集：在2016年大选之前，有偿吸引美国公众填写问卷，以此收集信息。
2. 数据分析：根据问卷收集到的信息分析美国网民性格，尤其是美国网民的个人态度和偏好，建立用户性格心理档案。
3. 精准投放：把美国网民分为三十余种不同的性格类型，在大选期间投放“精心设计”政治信息。



6.1.2 应用 — 美国选举

机器学习制作和传播“假新闻”，扰乱选民视听

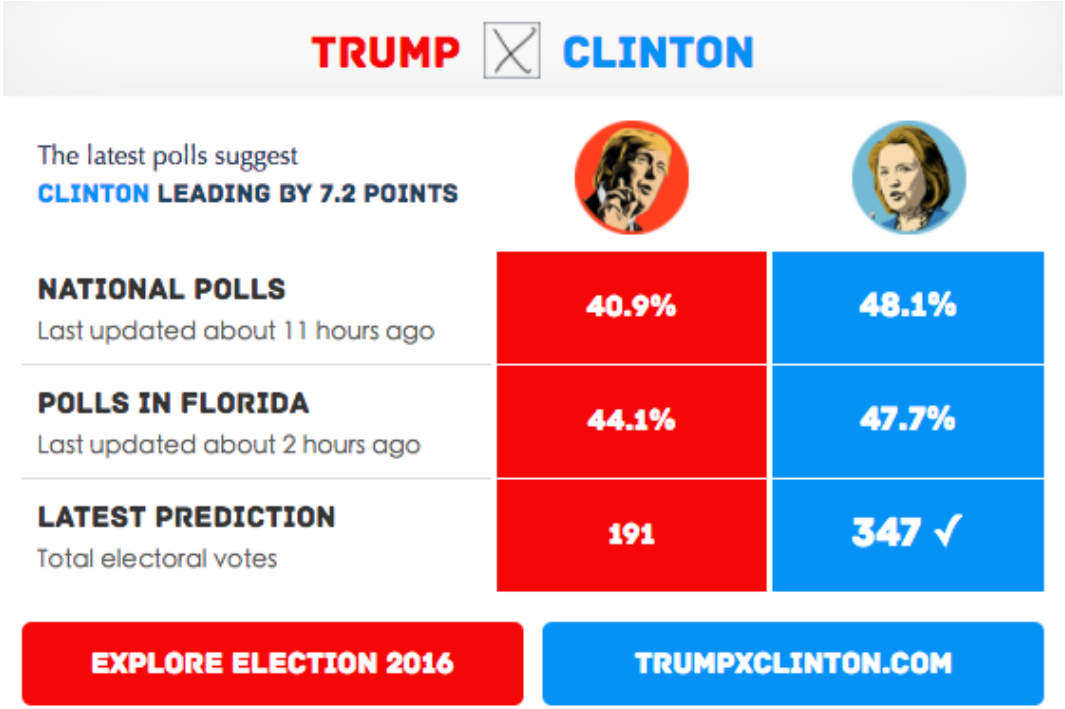
- 社交账号机器人（推特水军），模仿人类用户的活动并自动发布内容或参与讨论。
- 改变网上对话，创造热门话题，影响人们的观点思维。
- 总统大选辩论期间，由推特机器人发送推文约380万条，占总发文量19%，23%的美国人有意或者无意地分享了虚假的政治新闻。



Twitter Bots

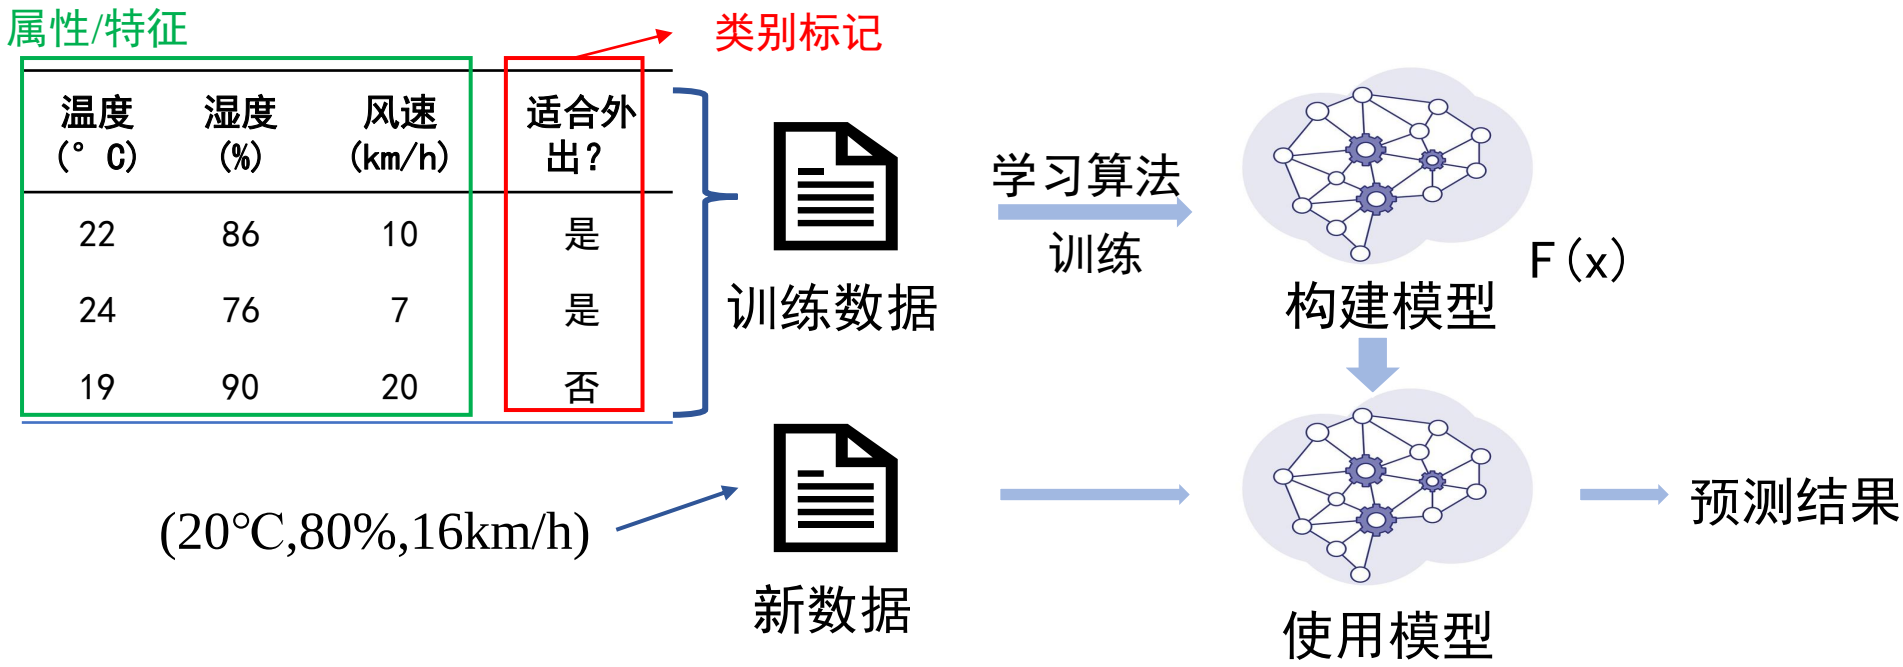
6.1.2 应用 — 美国选举

人工智能预测选举结果



- 2016年大选期间，印度公司Genic.ai开发的MogIA成功预测了特朗普的胜选。
- MogIA不掺杂任何人为干预，只依靠机器的自主强化学习，把互联网及社交媒体数据做为分析样本。

6.1.3 基本术语



- 数据集：训练集、测试集
- 属性/特征、属性值
- 属性空间、样本空间/输入空间
- 特征向量
- 标记空间/输出空间
- 有监督学习、无监督学习

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.3 基本术语 — 假设空间

温度（°C）	湿度（%）	风速（km/h）	适合外出？
22	86	10	是
24	76	7	是
19	90	20	否
16	86	16	否
21	80	12	是
23	70	6	是
18	86	26	否

假设（Hypothesis）

- 一个机器学习模型对数据的解释或预测规则。
- 一个可能的假设是：如果温度在20°C到26°C之间，湿度低于86%，并且风速小于16 km/h，则适合外出。

真相（Ground Truth）

- 数据集中“真实的”标签或结果。它代表了已知的正确答案，是模型需要学习和预测的目标。
- “适合外出？”列中是或否的标签

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.3 基本术语 — 假设空间

温度（° C）	湿度（%）	风速（km/h）	适合外出？
22	86	10	是
24	76	7	是
19	90	20	否
16	86	16	否
21	80	12	是
23	70	6	是
18	86	26	否

假设空间（Hypothesis Space）

- 假设空间是所有可能假设的集合。
- 例如不同的温度、湿度、风速条件下是否适合外出。

机器学习过程 → 在所有假设组成的空间中进行**搜索**的过程

机器学习目标 → 找到与训练集所“匹配”的假设

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.3 基本术语 — 版本空间

版本空间(Version Space):

所有与训练数据一致的假设子集。也就是说，版本空间包含了所有能够正确分类训练样本的假设。

温度（°C）	湿度（%）	风速（km/h）	适合外出？
22	85	10	是
24	75	7	是
19	90	20	否
15	85	15	否
21	80	12	是
23	70	5	是
18	85	25	否

- **假设 A**：只要温度大于20°C，则适合外出
- **假设 B**：湿度低于90%，且风速小于16 km/h，则适合外出。
- **假设 C**：温度在20°C到26°C之间，湿度低于90%，风速小于16 km/h，则适合外出.

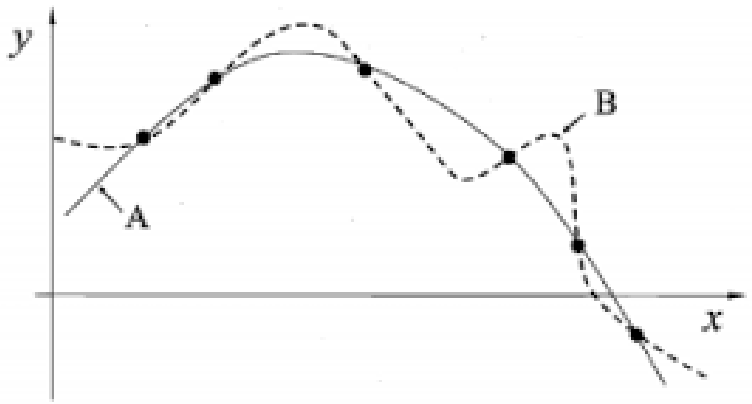
通过版本空间的收敛，模型能够找到与数据最符合的假设或假设集合，以便在新的样本上做出更准确的预测。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.1.3 基本术语 — 归纳偏好

归纳偏好(Inductive Bias):

机器学习算法在学习过程中对某种类型假设的偏好。



存在多条曲线与训练集一致

A还是B?

奥卡姆剃刀原理：若有多个假设与观察一致，则选最简单的那个

在具体的现实问题中，算法的归纳偏好是否与问题本身匹配，大多数时候直接决定了算法能否取得好的性能。

6.1.3 基本术语 — NFL定理

NFL定理，即“没有免费的午餐”定理（No Free Lunch Theorem）

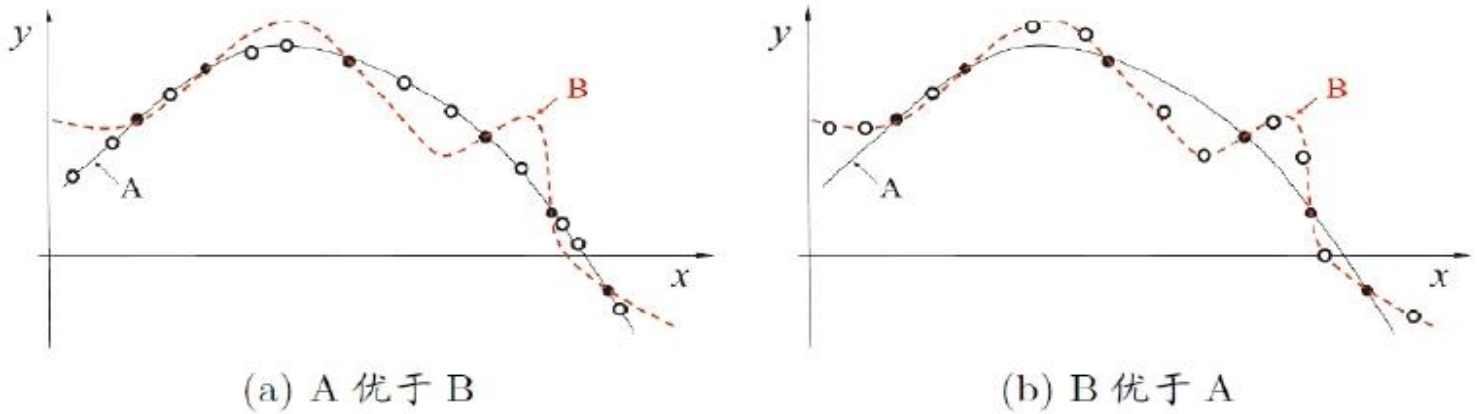


图 1.4 没有免费的午餐. (黑点: 训练样本; 白点: 测试样本)

NFL定理：一个算法A在某些问题上比另一个算法B好，必存在另一些问题，算法B比A好。

在不考虑问题特性的情况下，空泛地谈论哪种算法好是毫无意义的，要谈论算法优劣必须针对具体问题！

第六章 机器学习

- 6.2 模型评估与选择
  - 6.2.1 基本概念
  - 6.2.2 评估方法
  - 6.2.3 性能度量
  - 6.2.4 比较检验

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.2.1 基本概念

什么模型更好？

温度（°C）	湿度（%）	风速（km/h）	适合外出？
22	86	10	是
24	76	7	是
19	90	20	否

训练数据

学习算法

训练

构建模型

F(x)

(20°C,80%,16km/h)

新数据

使用模型

预测结果

泛化能力强 —— 能很好地适用于 unseen instance

如：错误率低、精度高

如果在m个样本中有a个样本分类错误

错误率： E=a/m　　精度： 1- a/m

西安交通大学 XI'AN JIAOTONG UNIVERSITY

泛化误差 vs 经验误差

误差：模型的实际预测输出与样本的真实输出之间的差异。

经验误差：在训练集上的误差。

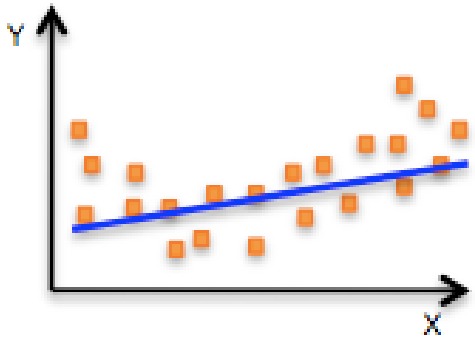
泛化误差：在新样本上的误差。

- 泛化误差越小越好
- 经验误差是否越小越好？

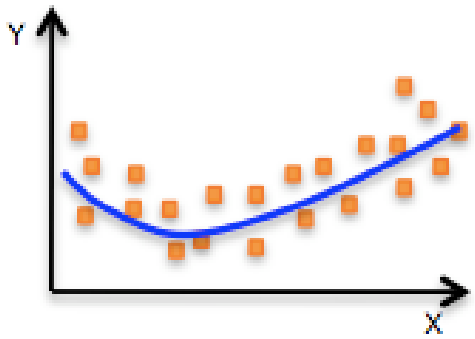
  否。经验误差过小，可能会出现“过拟合”

西安交通大学 XI'AN JIAOTONG UNIVERSITY

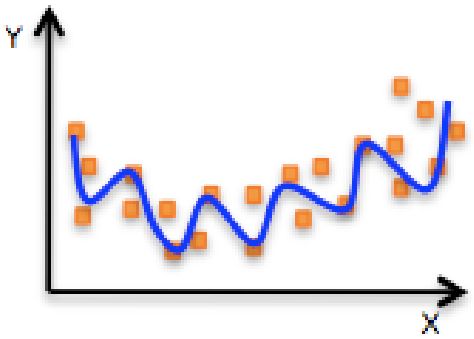
过拟合 vs 欠拟合



Underfitting



Just right!



overfitting

训练样本





新样本



过拟合模型分类结果：

→ 不是树叶

（误以为树叶必须有锯齿）



欠拟合模型分类结果：

→ 是树叶

（误以为绿色的都是树叶）

模型选择

三个关键问题：

- 如何获得测试结果？ 评估方法
- 如何评估性能优劣？ 性能度量
- 如何判断实质差别？ 比较检验

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.2.2 评估方法

关键：如何获得“测试集”？

测试集应该与训练集“互斥”

常用方法：

- 留出法 (hold-out)
- 交叉验证法 (cross validation)
- 自助法 (bootstrap)

西安交通大学 XI'AN JIAOTONG UNIVERSITY

留出法



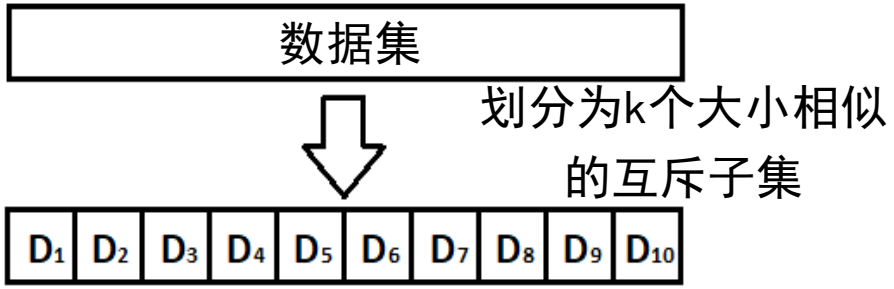
留出法：直接将数据集D划分为两个互斥的集合，其中一个集合作为训练集S，另一个作为测试集T，即 $D = S \cup T, S \cap T = \emptyset$

注意：

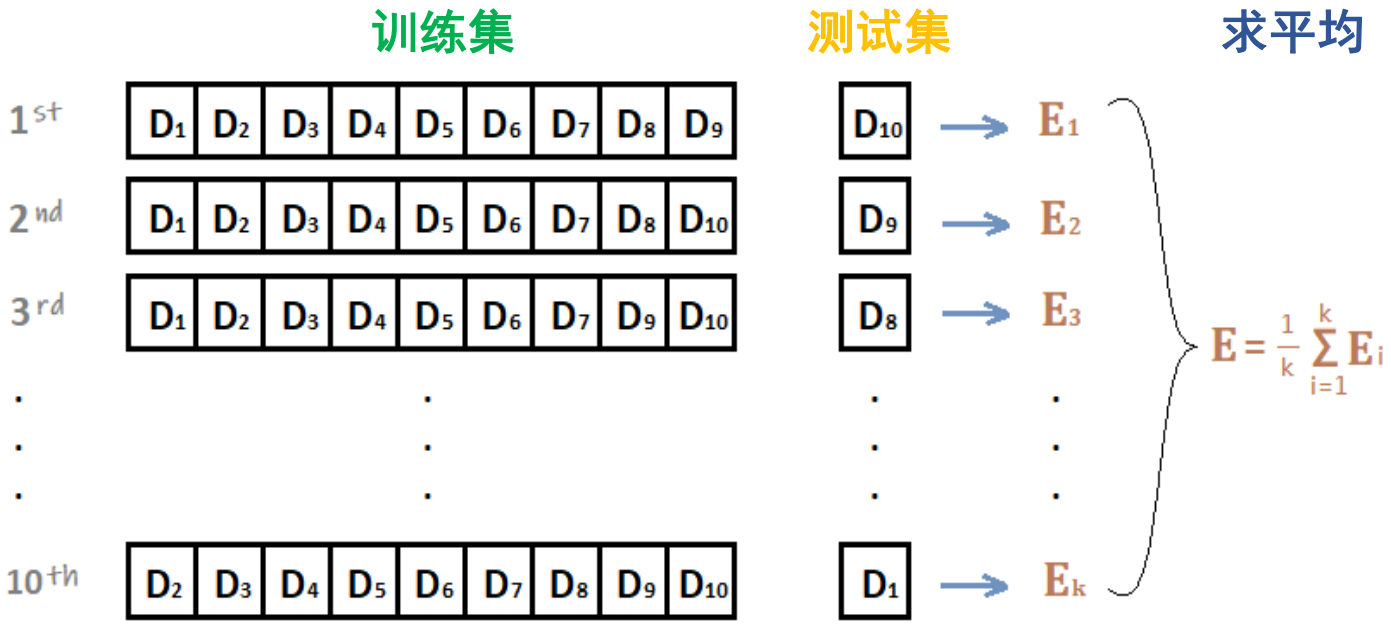
- 保持数据分布的一致性，避免因数据划分引入额外的偏差。
- 多次重复划分。单次留出法的估计结果往往不够稳定可靠。
- 测试集不能太大，也不能太小。通常为数据集的1/5-1/3.

西安交通大学 XI'AN JIAOTONG UNIVERSITY

k-折交叉验证法



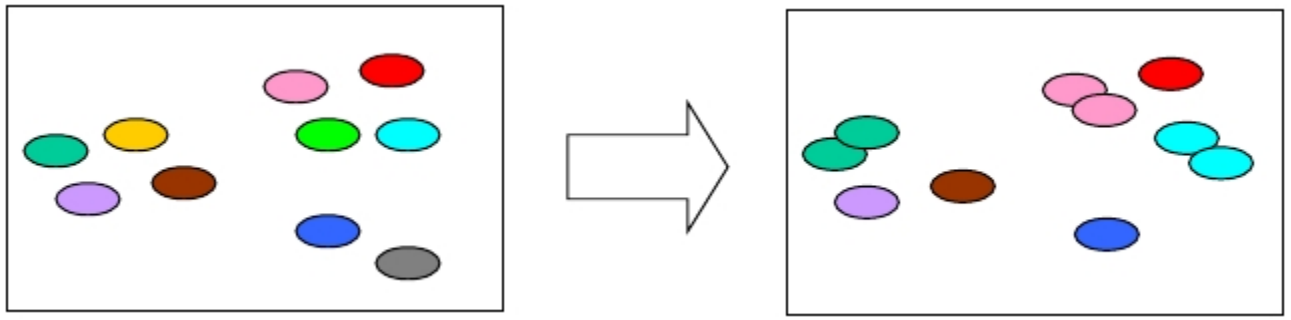
假定数据集中包含m个样本，令k=m,则得到“留一法”（leave-one-out）



自助法

自主采样：

- 给定包含m个样本的数据集D，以及采样产生的数据集D'
- 每次随机从D中挑选一个样本，将其拷贝放入D',然后放回原始数据集D。
- 重复执行m次采样，即可得到包含了m个样本的数据集D'



约有36.8%的样本不会出现在 D' 中。

$$\lim_{m\to\infty}\left(1-\frac{1}{m}\right)^{m}\to\frac{1}{e}\approx 0.368$$

D'→ 训练集　$D\backslash D'$→ 测试集

- 训练集与原样本集同规模
- 数据分布有所改变

西安交通大学 XI'AN JIAOTONG UNIVERSITY

比较

- 留出法 (Hold-out)
  - 划分方式: 将数据集分为训练集和测试集（例如70%训练，30%测试）。
  - 优点: 简单直接，快速评估。
  - 缺点: 评估结果依赖于数据划分，可能不稳定。
- 交叉验证法 (Cross Validation)
  - 将数据集分为k个子集，每次用k-1个子集训练，剩余一个子集测试。重复k次，取平均性能。
  - 优点: 更稳定和可靠的性能估计。
  - 缺点: 计算开销较大，需要多次训练模型。
- 自助法 (Bootstrap)
  - 采样方式: 有放回地从原始数据集中随机采样生成训练集。
  - 优点: 适合小数据集，能充分利用数据。
  - 缺点: 可能导致偏差，因为训练集分布可能与原始数据集不同。

➢ 这三种方法各有优缺点，选择合适的方法取决于数据集大小和任务需求。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

调参与最终模型

算法的参数：一般由人工设定，亦称“超参数”。

模型的参数：一般由学习确定。

调参过程类似于：

先产生若干模型，然后基于某种评估方法进行选择。

参数调得好不好往往对最终模型性能有着关键性影响。

训练集 vs. 测试集 vs. 验证集 (validation set)

⇩

模型评估与选择中用于评估测试的数据集

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.2.3 性能度量

性能度量(performance measure)是衡量模型泛化能力的评价标准，反映了任务需求。

使用不同的性能度量往往会导致不同的评判结果

什么样的模型是“好”的，不仅取决于算法和数据，还取决于任务需求！

- 回归任务最常用的性能度量是“均方误差”

$$\mathrm{E}(f;D)=\frac{1}{m}\sum_{i=1}^{m}(f(x_i)-y_i)^2$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

错误率 vs 精度

- 错误率

$$\mathrm{E}(f;D)=\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}(f(x_i)\neq y_i)$$

- 精度(Accuracy)

$$\begin{aligned}\mathrm{acc}(f;D)&=\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}(f(x_i)=y_i)\\&=1-E(f;D)\end{aligned}$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

查准率 vs 查全率

分类结果混淆矩阵

		预测结果	
		正例	反例
真实情况	正例	TP(true positive)	FN(false negative)
	反例	FP(false positive)	TN(true negative)

- 查准率(Precision):

$$P = \frac{TP}{TP + FP}$$

- 查全率(Recall):

$$R = \frac{TP}{TP + FN}$$

一般来说，查准率高时，查全率往往偏低；查全率高时，查准率往往偏低。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

查准率 vs 查全率

- 为了提高查准率，模型就需要更加严格地筛选正例，但是由于过于“严格”，也会漏掉一些正例，导致查全率降低
- 为了提高查全率，模型就需要尽可能多的筛选出正例，但由于过于“宽松”，就会导致很多反例被选择，导致查准率降低

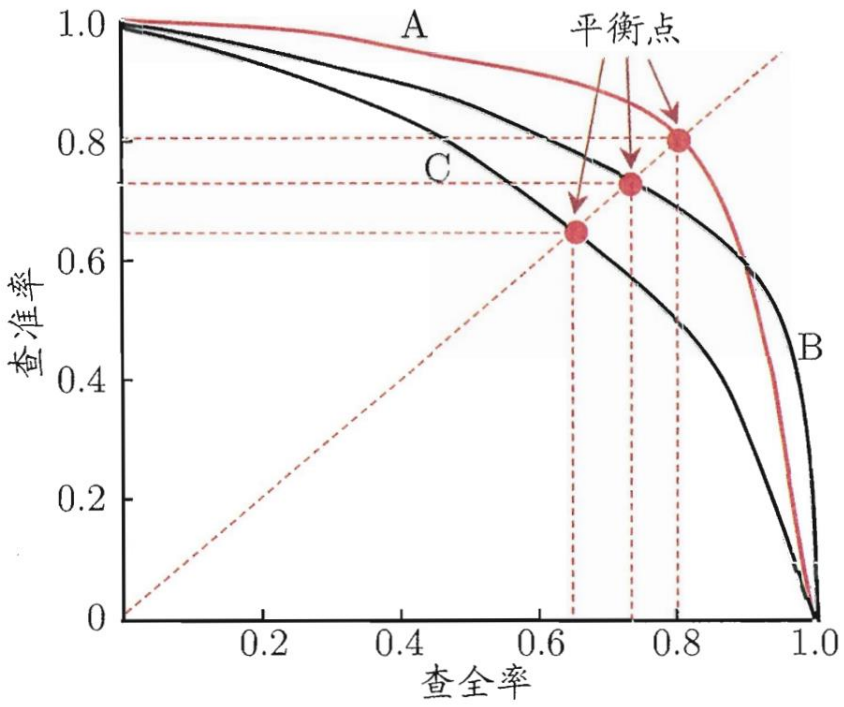
- 以疾病检测为例：
- 高查准率: 希望所有检测为阳性的病例几乎都是确诊的病人（少错报）。
  - ✓ 可能漏掉一些真正有病的病人（低Recall ）。
- 高查全率: 希望几乎所有有病的病人都被检测出来。
  - ✓ 可能会误报一些健康人（低Precision ）。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

PR 图

- 根据学习器的预测结果，按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测。PR曲线越靠近右上角越好。

- 如果一个学习器的PR曲线被另一个学习器完全包住，则可断言后者的性能优于前者。



从左侧PR图可知：

- A优于C
- B优于C
- A？ B

平衡点（Break-Event Point，BEP）

- P=R 时的取值
- A优于B

PR 图

真实标签		预测值			
Inst#	Class	Score	Inst#	Class	Score
1	p	.9	11	p	.4
2	p	.8	12	n	.39
3	n	.7	13	p	.38
4	p	.6	14	n	.37
5	p	.55	15	n	.36
6	p	.54	16	n	.35
7	n	.53	17	p	.34
8	n	.52	18	n	.33
9	p	.51	19	p	.30
10	n	.505	20	n	.1

真实情况：正例p、反例n各有10个

$$P = \frac{TP}{TP + FP} \qquad R = \frac{TP}{TP + FN}$$

逐个样本设置阈值：

$\mu = 0.9,\ P = \frac{1}{1+0} = 1,\ R = \frac{1}{1+9} = 0.1$

$\mu = 0.8,\ P = \frac{2}{2+0} = 1,\ R = \frac{2}{2+8} = 0.2$

$\mu = 0.7,\ P = \frac{2}{2+1} = 0.67,\ R = \frac{2}{2+8} = 0.2$

$\mu = 0.6,\ P = \frac{3}{3+1} = 0.75,\ R = \frac{3}{3+7} = 0.3$

...

$\mu = 0.33,\ P = \frac{9}{9+9} = 0.5,\ R = \frac{9}{9+1} = 0.9$

$\mu = 0.3,\ P = \frac{10}{10+9} = 0.53,\ R = \frac{10}{10+0} = 1$

$\mu = 0.1,\ P = \frac{10}{10+10} = 0.5,\ R = \frac{10}{10+0} = 1$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

F1度量

BEP过于简化，更常用的是F1度量：

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

若对查准率/查全率有不同偏好：

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

$\beta > 1$时，查全率有更大影响；

$\beta < 1$时，查准率有更大影响。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

宏xx vs 微xx

若有多个混淆矩阵，如多次训练/测试、多个数据集、多分类任务

方法一：先在各混淆矩阵上分别计算出查准率和查全率$(P_1, R_1), \dots (P_n, R_n)$，再计算平均值。 宏(macro-)

$$marco - P = \frac{1}{n}\sum_{i=1}^{n} P_i$$

$$marco - R = \frac{1}{n}\sum_{i=1}^{n} R_i$$

$$marco - F1 = \frac{2 \times macro_P \times macro_R}{macro_P + macro_R}$$

方法二：先将各混淆矩阵的对应元素进行平均$\overline{TP}, \overline{FP}, \overline{TN}, \overline{FN}$。 微(micro-)

$$micro - P = \frac{\overline{TP}}{\overline{TP} + \overline{FP}}$$

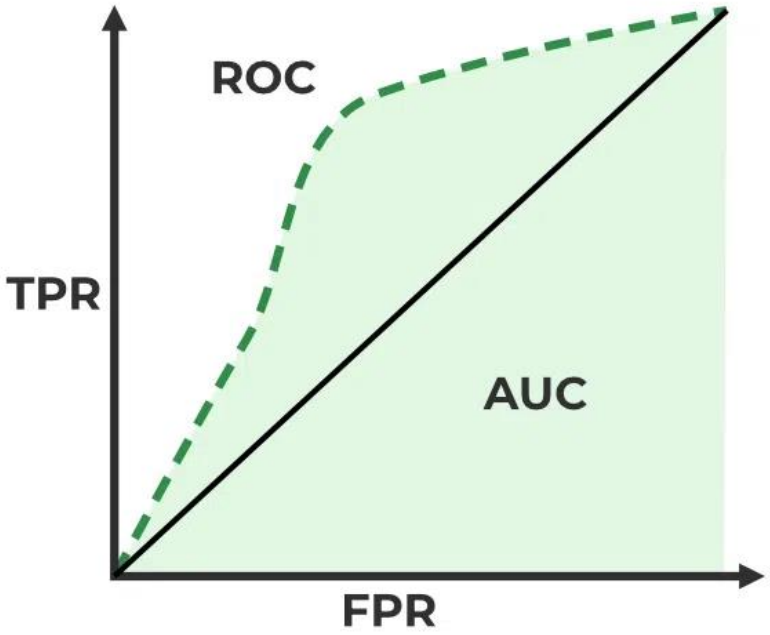
$$micro - R = \frac{\overline{TP}}{\overline{TP} + \overline{FN}}$$

$$mirco - F1 = \frac{2 \times micro_P \times micro_R}{micro_P + micro_R}$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ROC, AUC

与PR曲线类似，根据学习器的预测结果对样例进行排序，并逐个把样本作为正例计算 TPR、FPR。



真正例率(True Positive Rate)

$$TPR = \frac{TP}{TP + FN}$$

假正例率(False Positive Rate)

$$FPR = \frac{FP}{TP + FP}$$

The bigger, the better

AUC(Area Under ROC Curve): ROC 曲线下各部分的面积。

非均等代价

非均等代价(unequal cost)：犯不同的错误往往会造成不同的损失

真实情况	预测结果	
	第0类	第1类
第0类	0	$cost_{01}$
第1类	$cost_{10}$	0

二分类代价矩阵

- 代价敏感(cost-sensitive)错误率：

$$E(f;D;cost)=\frac{1}{m}\left(\sum_{x_i\in D^+}\mathbb{I}(f(x_i)\neq y_i)\times cost_{01}+\sum_{x_i\in D^-}\mathbb{I}(f(x_i)\neq y_i)\times cost_{10}\right)$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.2.4 比较检验

在某种度量下取得评估结果后，是否可以直接比较以评判优劣？

否。

- 测试性能不等于泛化性能
- 测试性能随着测试集的变化而变化
- 很多机器学习算法本身有一定的随机性

如何对学习器的性能进行比较？

西安交通大学 XI'AN JIAOTONG UNIVERSITY

常用方法

统计假设检验(hypothesis test)为性能比较提供重要依据

- 两学习器比较：
  - 交叉验证t检验(基于成对t检验)

    k折交叉验证；5×2交叉验证
  - McNemar检验（基于列联表，卡方检验）
- 多学习器比较：
  - Friedman+Nemenyi
    - Friedman 检验（基于序值，F检验; 判断”是否都相同”）
    - Nemenyi 后续检验（基于序值，进一步判断两两差别）

西安交通大学 XI'AN JIAOTONG UNIVERSITY

偏差-方差分解

“误差”包含了哪些因素？从机器学习的角度，“误差”从何而来？

偏差-方差分解：对学习算法的期望泛化错误率进行拆解。

对于回归任务，泛化误差可拆解为：

$$E(f;D) = bias^2(x) + var(x) + \varepsilon^2$$

$bias^2(x) = \left(\bar{f}(x) - y\right)^2$ 期望输出与真实输出的差别

同样大小训练集的变动，导致的性能变化

$var(x) = \mathbb{E}_D\left[\left(f(x;D) - \bar{f}(x)\right)^2\right]$

训练样本标记与真实标记的区别，为当前任务上任何学习算法所能达到的期望泛化误差下界

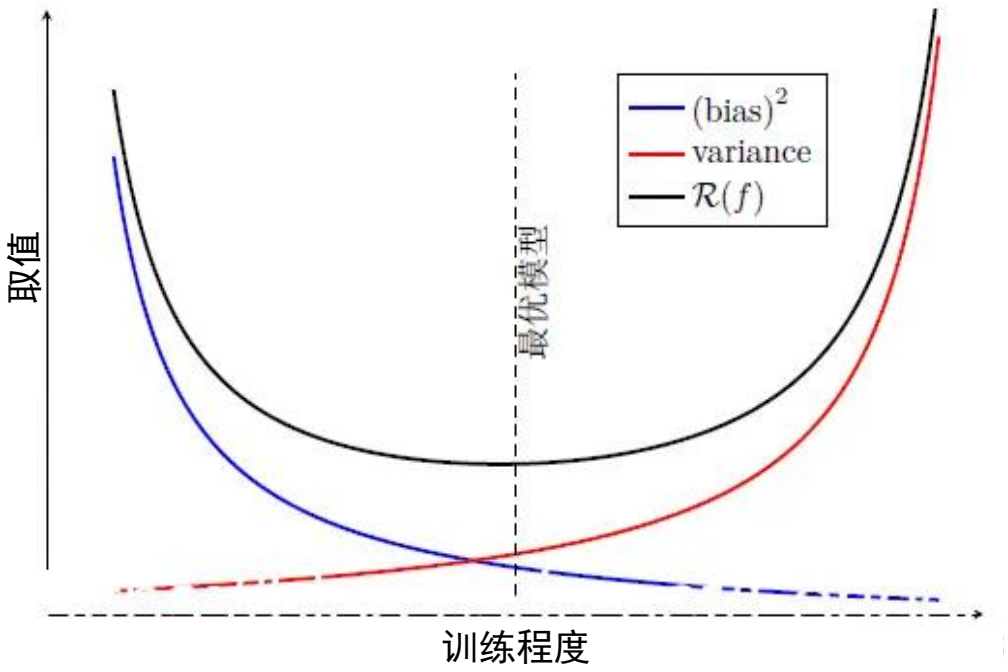
$\varepsilon^2 = \mathbb{E}_D[(y_D - y)^2]$

泛化性能由学习算法的能力、数据的充分性以及学习任务本身的难度共同决定

偏差-方差窘境

一般而言，偏差与方差存在冲突：

- 训练不足时，学习器拟合能力，偏差主导。
- 随着训练程度加深，学习器拟合能力逐渐增强，方差逐渐主导。
- 训练充足后，学习器的拟合能力很强，方差主导。

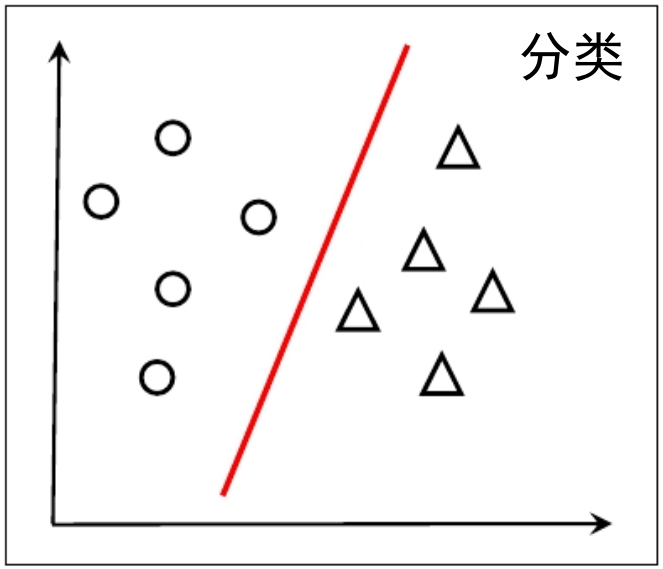


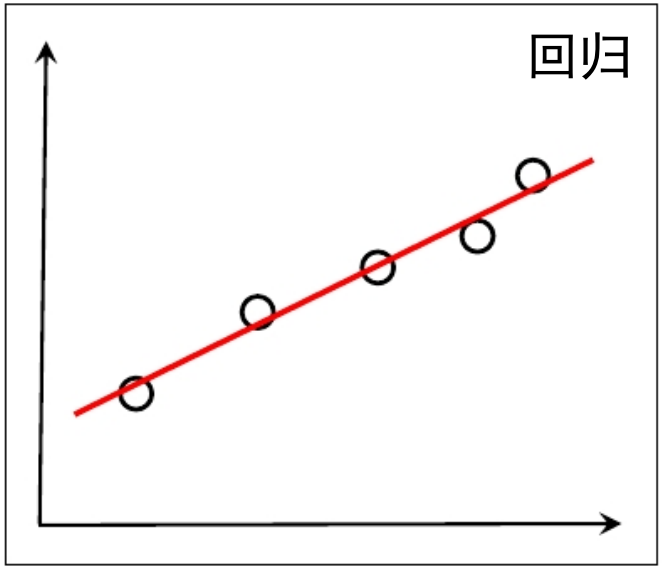
第六章 机器学习

- 6.3 线性模型
  - 6.3.1 线性回归
  - 6.3.2 代价函数
  - 6.3.3 最小二乘法

西安交通大学 XI'AN JIAOTONG UNIVERSITY

线性模型





线性模型（linear model）：试图学得一个通过属性的线性组合来进行预测的函数，即：

$$f(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b$$

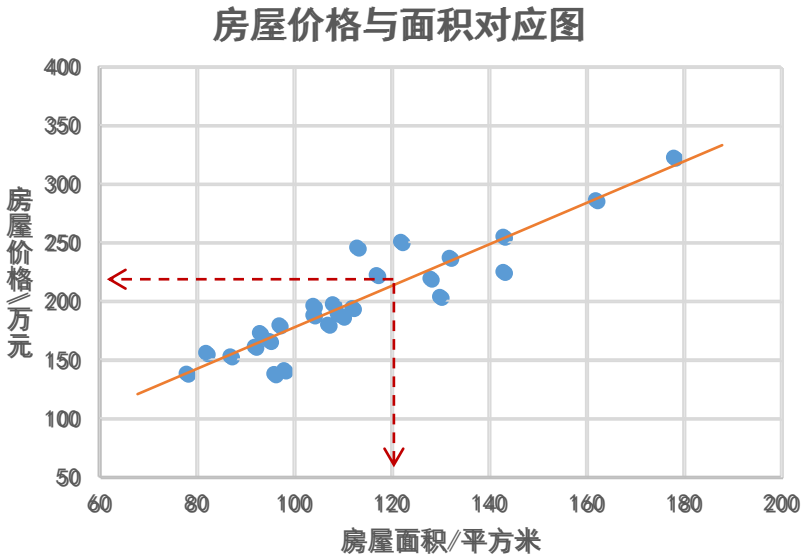
$$f(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} + b$$

线性模型形式简单、易于建模、可解释性

西安交通大学 XI'AN JIAOTONG UNIVERSITY

问题引入

- 如何根据房屋的面积预测价格？



概念区分

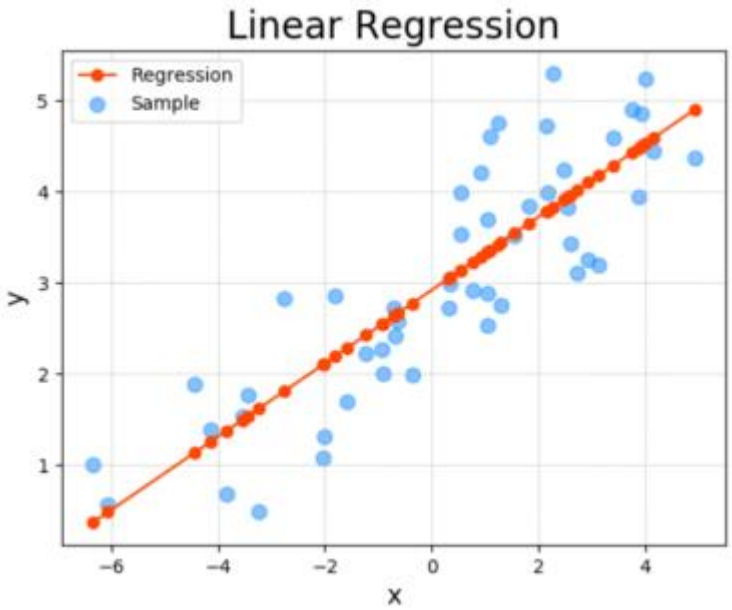
- 回归（regression）：连续标签
  - ✓ 如何根据房屋的面积、楼层、房龄、区位等属性预测房屋价格？
- 分类（classification）：离散标签
  - ✓ 如何根据患者的年龄、性别、肿瘤大小等属性判断良性或恶性？

西安交通大学 XI'AN JIAOTONG UNIVERSITY

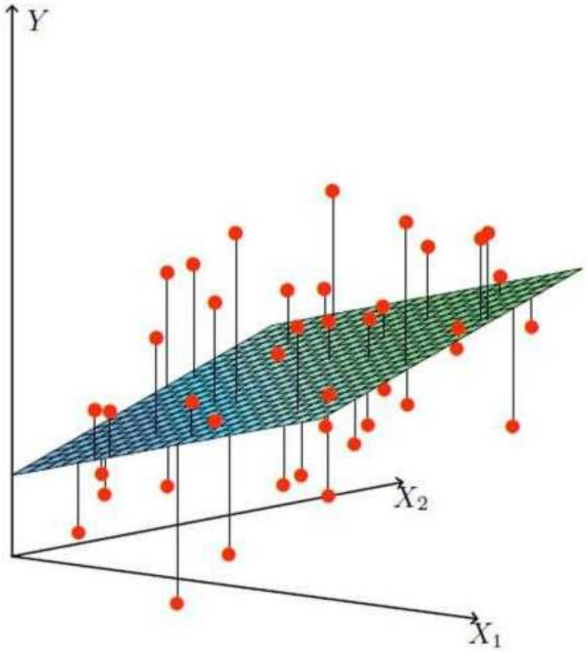
线性回归定义

线性回归（linear regression）

- 旨在学习一个线性模型，能够通过特征的线性组合来进行预测，能够找到一条直线或者一个平面或者一个高维超平面，使得预测值尽可能接近真实值



二维空间中是一条直线



三维空间中是一个平面

西安交通大学 XI'AN JIAOTONG UNIVERSITY

线性回归模型

形式化定义

- m个样本：$D=\{(\boldsymbol{x}^{(1)},y^{(1)}),(\boldsymbol{x}^{(2)},y^{(2)}),\dots,(\boldsymbol{x}^{(m)},y^{(m)})\}$

如何利用样本特征进行预测？

- 每个样本包含n种特征：$\boldsymbol{x}^{(i)}=\left[x_1^{(i)},x_2^{(i)},\dots,x_n^{(i)}\right]^T\in\mathbb{R}^n$

- ✓ 第2个样本的特征：$\boldsymbol{x}^{(2)}=[96\ \ 1.2\ \ 10\ \ \cdots]^T$
- ✓ 所有样本的第3种特征：$\boldsymbol{x}_3=\begin{bmatrix}5\\10\\3\\\vdots\end{bmatrix}$
- ✓ 第4个样本的第1种特征：$x_1^{(4)}=113$
- ✓ 第4个样本的标签：$y^{(4)}=245$

面积	地铁	房龄	楼层	…	房价
82	0.5	5	15	…	155
96	1.2	10	6	…	137
104	0.4	3	12	…	195
113	1.8	12	16	…	245
122	1.1	6	3	…	250
132	0.8	4	24	…	236
143	2.4	2	27	…	224
…	…	…	…	…	…

特征矩阵（$m\times n$）　　标签

西安交通大学 XI'AN JIAOTONG UNIVERSITY

线性回归模型

线性回归模型

$$h_\theta\left(\boldsymbol{x}^{(i)}\right) = \theta_0 + \theta_1 x_1^{(i)} + \ldots + \theta_n x_n^{(i)}$$

如何评价模型预测的好坏？

- 基于给定的特征$\boldsymbol{x}^{(i)}$和模型参数$\boldsymbol{\theta} = [\theta_0, \theta_1, \ldots, \theta_n]^T$进行预测
- 令$x_0^{(i)} = 1$，改写特征为$\boldsymbol{x}^{(i)} = \left[x_0^{(i)}, x_1^{(i)}, \ldots, x_n^{(i)}\right]^T$
- 改写线性回归模型为：

$$h_\theta\left(\boldsymbol{x}^{(i)}\right) = \theta_0 x_0^{(i)} + \theta_1 x_1^{(i)} + \ldots + \theta_n x_n^{(i)} = \sum_{j=0}^{n} \theta_j x_j^{(i)} = \boldsymbol{\theta}^T \boldsymbol{x}^{(i)}$$

- ✓ 给定线性回归模型$\boldsymbol{\theta} = [0.25, 1.82]^T$ 和房屋面积$x = 120$平米
- ✓ 预测房屋价格为：$h_\theta(x) = 0.25 + 1.82x = 218.65$万元

西安交通大学 XI'AN JIAOTONG UNIVERSITY

代价函数

代价函数（cost function）

- 用来度量线性回归模型拟合真实数据的程度
- 代价函数值越小，代表模型拟合的越好
- 采用均方误差（mean squared error）作为线性回归的代价函数

$$J(\theta_0,\theta_1,\dots,\theta_n)=\frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta\left(\boldsymbol{x}^{(i)}\right)-y^{(i)}\right)^2$$

如何求解？

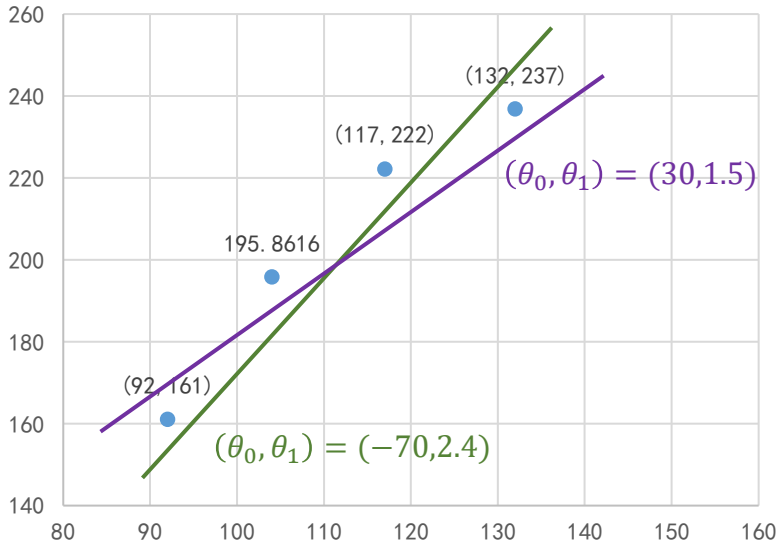
当模型为$(\theta_0,\theta_1)=(-70,2.4)$，

代价值为$J_1(-70,2.4)$=74.31；

当模型为$(\theta_0,\theta_1)=(30,1.5)$，

代价值为$J_2(30,1.5)$=62.78；

因此，$J_2<J_1$，第2个模型更好



西安交通大学 XI'AN JIAOTONG UNIVERSITY

最小二乘法

最小二乘法（ordinary least squares）

- 基于均方误差最小化进行模型求解的方法称为最小二乘法

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} \frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right)^2$$

代价函数矩阵表示

令 $X = \begin{bmatrix} \left(\boldsymbol{x}^{(1)}\right)^T \\ \left(\boldsymbol{x}^{(2)}\right)^T \\ \vdots \\ \left(\boldsymbol{x}^{(m)}\right)^T \end{bmatrix} = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \cdots & x_n^{(m)} \end{bmatrix}$ $\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ $\boldsymbol{y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$

$$\Rightarrow \quad J(\boldsymbol{\theta}) = \frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right)^2 = \frac{1}{2m}(X\boldsymbol{\theta} - \boldsymbol{y})^T(X\boldsymbol{\theta} - \boldsymbol{y})$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

最小二乘法

若$\boldsymbol{a} \in \mathbb{R}^m$，$\sum_{i=1}^{m} a_i^2 = \|\boldsymbol{a}\|_2^2 = \boldsymbol{a}^T\boldsymbol{a}$

$\Rightarrow$ $\sum_{i=1}^{m}\left(h_\theta\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right)^2$ 为列向量 $\begin{bmatrix} h_\theta\left(\boldsymbol{x}^{(1)}\right) - y^{(1)} \\ h_\theta\left(\boldsymbol{x}^{(2)}\right) - y^{(2)} \\ \vdots \\ h_\theta\left(\boldsymbol{x}^{(m)}\right) - y^{(m)} \end{bmatrix}$ 的模平方

$$\begin{bmatrix} h_\theta\left(\boldsymbol{x}^{(1)}\right) - y^{(1)} \\ h_\theta\left(\boldsymbol{x}^{(2)}\right) - y^{(2)} \\ \vdots \\ h_\theta\left(\boldsymbol{x}^{(m)}\right) - y^{(m)} \end{bmatrix} = \begin{bmatrix} \left(\boldsymbol{x}^{(1)}\right)^T\boldsymbol{\theta} \\ \left(\boldsymbol{x}^{(2)}\right)^T\boldsymbol{\theta} \\ \vdots \\ \left(\boldsymbol{x}^{(m)}\right)^T\boldsymbol{\theta} \end{bmatrix} - \boldsymbol{y} = \begin{bmatrix} \left(\boldsymbol{x}^{(1)}\right)^T \\ \left(\boldsymbol{x}^{(2)}\right)^T \\ \vdots \\ \left(\boldsymbol{x}^{(m)}\right)^T \end{bmatrix}\boldsymbol{\theta} - \boldsymbol{y} = X\boldsymbol{\theta} - \boldsymbol{y}$$

那么，$\sum_{i=1}^{m}\left(h_\theta\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right)^2 = \|X\boldsymbol{\theta} - \boldsymbol{y}\|_2^2 = (X\boldsymbol{\theta} - \boldsymbol{y})^T(X\boldsymbol{\theta} - \boldsymbol{y})$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

最小二乘法

参数估计

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} \frac{1}{2m}(X\boldsymbol{\theta} - \boldsymbol{y})^T(X\boldsymbol{\theta} - \boldsymbol{y})$$

- 令代价函数$J(\boldsymbol{\theta})$对$\boldsymbol{\theta}$的导数为$\mathbf{0}$：

若A为方阵，则有$\nabla_{\boldsymbol{\theta}}\boldsymbol{\theta}^T A\boldsymbol{\theta} = 2A\boldsymbol{\theta}$
若$\boldsymbol{a}$为向量，则有$\nabla_{\boldsymbol{\theta}}\boldsymbol{\theta}^T\boldsymbol{a} = \nabla_{\boldsymbol{\theta}}\boldsymbol{a}^T\boldsymbol{\theta} = \boldsymbol{a}$

$$\nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \frac{1}{2m}(\boldsymbol{\theta}^T X^T X\boldsymbol{\theta} - \boldsymbol{\theta}^T X^T\boldsymbol{y} - \boldsymbol{y}^T X\boldsymbol{\theta} + \boldsymbol{y}^T\boldsymbol{y})$$

$$= \frac{1}{2m}(2X^T X\boldsymbol{\theta} - X^T\boldsymbol{y} - X^T\boldsymbol{y} + \mathbf{0}) = \mathbf{0}$$

$$\Rightarrow \quad X^T X\boldsymbol{\theta} = X^T\boldsymbol{y}$$

$$\Rightarrow \quad (X^T X)^{-1}X^T X\boldsymbol{\theta} = (X^T X)^{-1}X^T\boldsymbol{y}$$

$A^{-1}A = I; \quad I\theta = \theta$

$$\Rightarrow \quad \boldsymbol{\theta} = (X^T X)^{-1}X^T\boldsymbol{y}$$

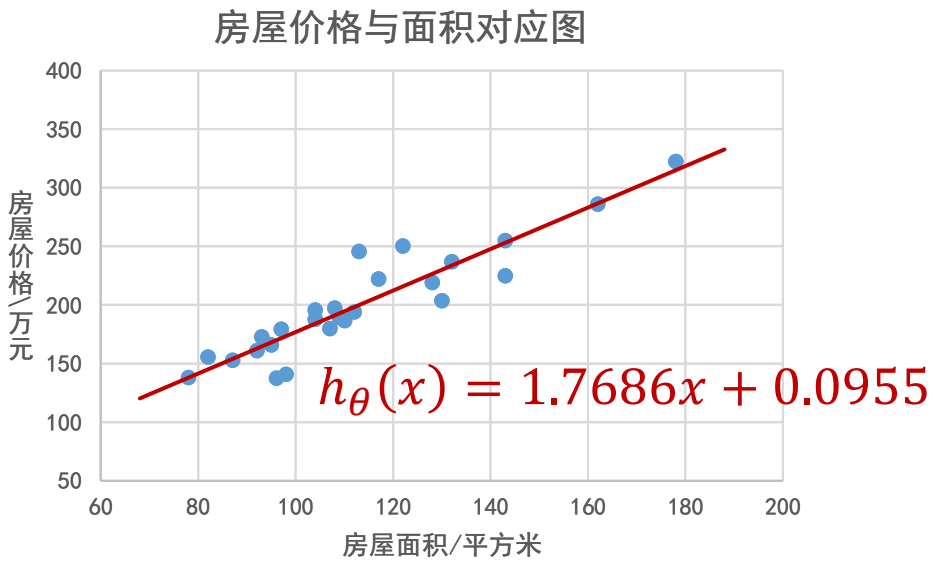
称为模型参数$\boldsymbol{\theta}$的闭式解（closed-form）

西安交通大学 XI'AN JIAOTONG UNIVERSITY

最小二乘法应用

- 实例：根据房价与面积的数据，构建一元线性回归模型，估计模型参数

序号	面积/平米	房价/万元
1	82	155. 7178
2	96	137. 7184
3	104	195. 8616
4	113	245. 6477
5	122	250. 4338
6	132	236. 8628
7	143	224. 9347
8	178	322. 4362
9	162	286. 1498
10	98	141. 0042
11	97	179. 3613
12	93	172. 7897
13	104	187. 8616
14	108	197. 4332
15	117	222. 2193
16	130	203. 577
17	87	152. 9323
18	95	166. 0755
19	110	186. 719
20	143	254. 9347
21	92	161. 1468
22	128	219. 2912
23	112	194. 0048
24	109	189. 0761
25	78	138. 1462
26	107	179. 7903



构建$X = \begin{bmatrix} 1 & 82 \\ 1 & 96 \\ \vdots & \vdots \\ 1 & 107 \end{bmatrix}$和$\boldsymbol{y} = \begin{bmatrix} 155.72 \\ 137.72 \\ \vdots \\ 179.80 \end{bmatrix}$

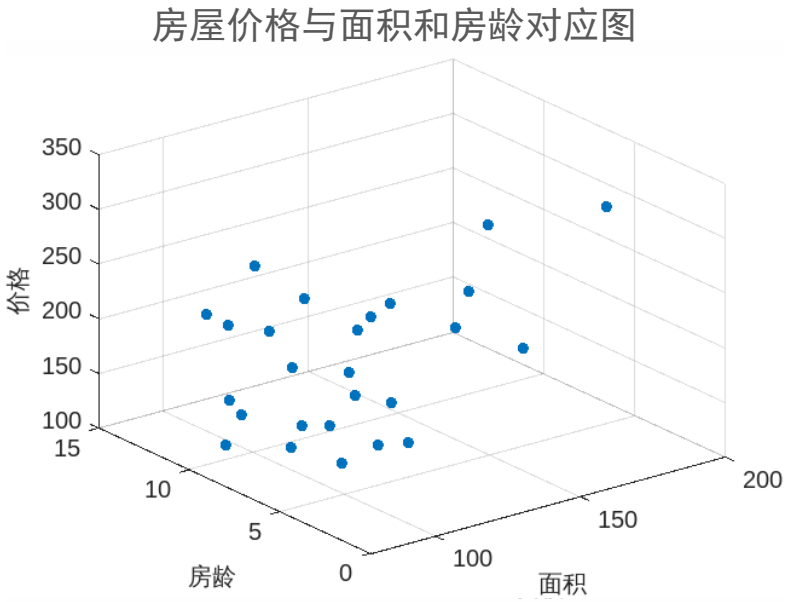
计算$\boldsymbol{\theta} = (X^T X)^{-1} X^T \boldsymbol{y}$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

最小二乘法应用

- 实例：根据房价与面积和房龄的数据，构建二元线性回归模型，估计模型参数

序号	面积/平米	房龄/年	房价/万元
1	82	5	155.7178
2	96	10	137.7184
3	104	3	195.8616
4	113	12	245.6477
5	122	6	250.4338
6	132	4	236.8628
7	143	2	224.9347
8	178	3	322.4362
9	162	7	286.1498
10	98	11	141.0042
11	97	1	179.3613
12	93	2	172.7897
13	104	5	187.8616
14	108	6	197.4332
15	117	7	222.2193
16	130	12	203.577
17	87	3	152.9323
18	95	5	166.0755
19	110	13	186.719
20	143	5	254.9347
21	92	6	161.1468
22	128	8	219.2912
23	112	11	194.0048
24	109	14	189.0761
25	78	8	138.1462
26	107	9	179.7903



构建$X=\begin{bmatrix}1 & 82 & 5\\ 1 & 96 & 10\\ \vdots & \vdots & \vdots\\ 1 & 107 & 9\end{bmatrix}$和$y=\begin{bmatrix}155.72\\ 137.72\\ \vdots\\ 179.80\end{bmatrix}$

$h_\theta(x_1,x_2)=1.757x_1-1.01x_2+8.3214$

计算$\boldsymbol{\theta}=(X^TX)^{-1}X^T\boldsymbol{y}$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

总结与延伸

内容总结

- 线性回归模型的概念–建立模型
- 基于均方误差的代价函数–评价模型
- 利用最小二乘法进行参数估计–求解模型

问题延伸

- θ的闭式解中$(X^TX)^{-1}$存在两个问题：
  - ✓ 矩阵$(X^TX) \in \mathbb{R}^{n\times n}$并不总是可逆的
  - ✓ 矩阵求逆时间复杂度为$O(n^3)$，当特征数量较大时（$n > 10^3$），效率低下

完