

西安交通大学
XI'AN JIAOTONG UNIVERSITY

人工智能
Artificial Intelligence

- 主讲：刘欢
- 西安交通大学计算机学院
- E-mail：huanliu@xjtu.edu.cn

第六章 机器学习

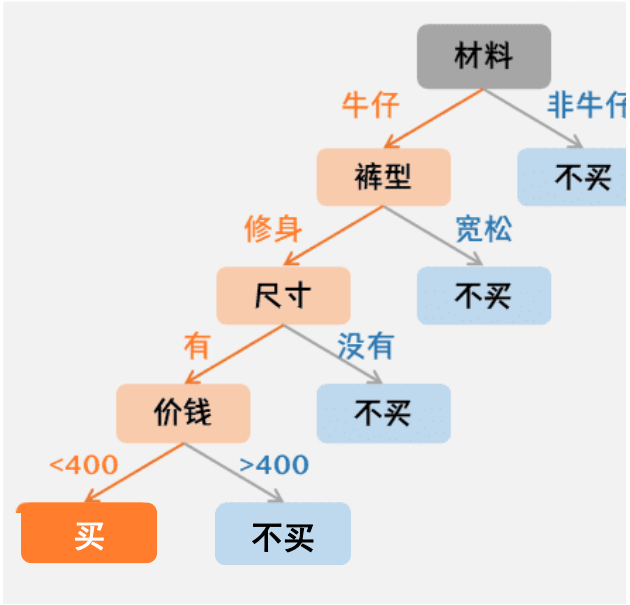
- 6.4 决策树
  - 6.4.1 基本流程
  - 6.4.2 划分属性选择
  - 6.4.3 过拟合、欠拟合
  - 6.4.4 连续值、缺失值
  - 6.4.5 多变量决策树

西安交通大学 XI'AN JIAOTONG UNIVERSITY

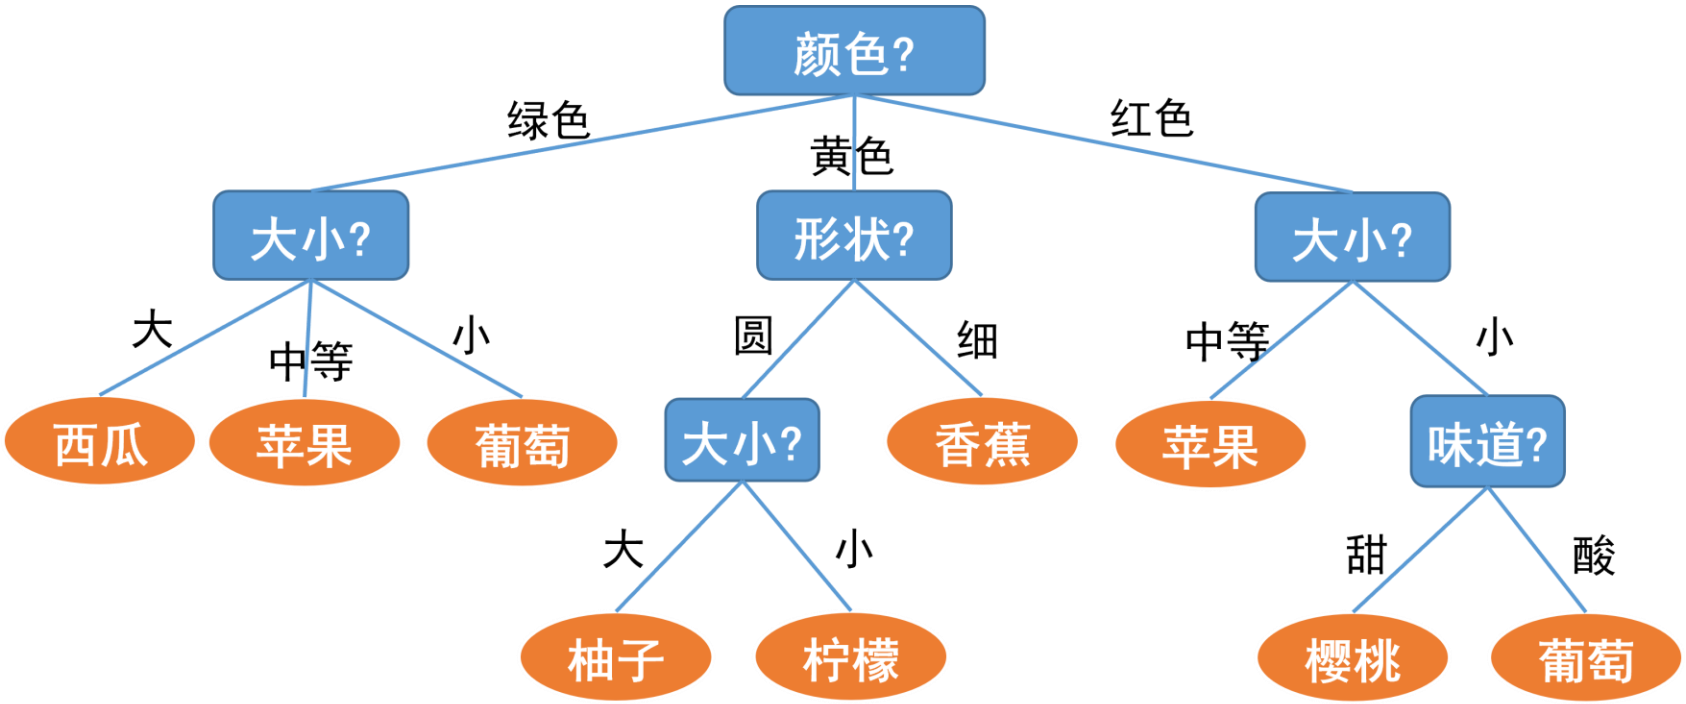
如何分类？

模拟人类决策过程：





如何分类？



考虑一个水果分类问题，采用的特征向量为：{颜色, 尺寸, 形状, 味道}，颜色取值{红, 绿, 黄}, 味道取值{甜, 酸}……

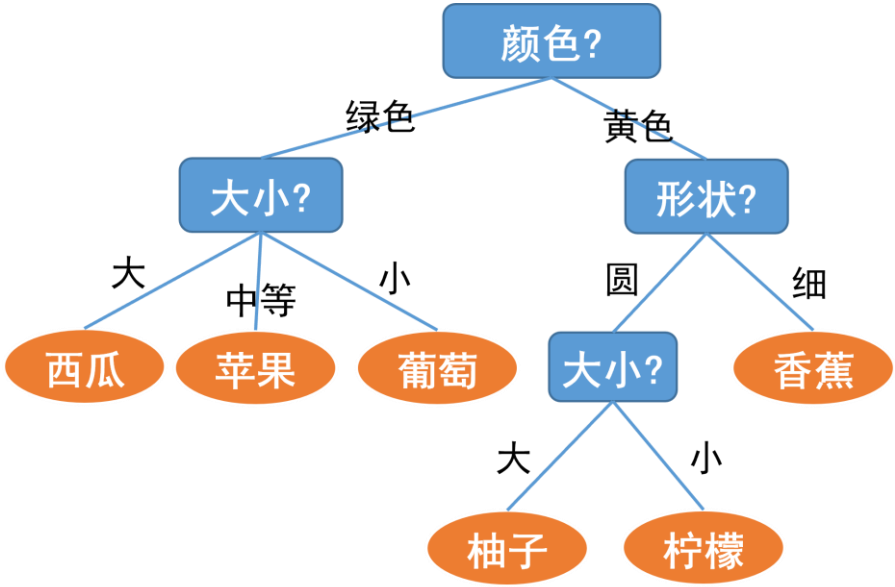
- 样本集：一批水果，知道其特征向量及类别
- 问　题：一个新的水果，观测到了其特征向量，将其分类。

决策树

决策树（Decision Tree）：基于“树”结构进行决策分析的模型

- 一棵决策树包含一个根结点、若干内部结点、若干叶结点
- 每个内部结点对应某个属性上的“测试”，每个分支对应测试的一种可能结果（属性的某个取值）
- 每个叶结点对应一个决策结果

本质：通过将问题分解成一系列的决策步骤，从而将复杂问题简化为多个二选一或多选一的问题。



6.4.1 基本流程

- 策略：“分而治之”

输入： 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \ldots, a_d\}$.

过程： 函数 TreeGenerate(D, A)

1: 生成结点 node;
2: **if** D 中样本全属于同一类别 C **then**
3: 将 node 标记为 C 类叶结点; **return**
4: **end if**
5: **if** $A = \varnothing$ **OR** D 中样本在 A 上取值相同 **then**
6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; **return**
7: **end if**
8: 从 A 中选择最优划分属性 a_*;
9: **for** a_* 的每一个值 a_*^v **do**
10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
11: **if** D_v 为空 **then**
12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; **return**
13: **else**
14: 以 TreeGenerate(D_v, $A \setminus \{a_*\}$)为分支结点
15: **end if**
16: **end for**

输出： 以 node 为根结点的一棵决策树

三种递归返回情形

（1）

（2）

当前结点的后验分布

（3）

将父结点样本分布作为当前结点的先验分布

决策树算法的核心

决策树生成 → 由根节点到叶结点的递归过程

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.4.2 划分属性选择

决策树学习的关键：如何选择最优划分属性？

原则：随着划分过程不断进行，决策树的分支结点所包含的样本尽可能属于同一类别，即结点的“纯度”越来越高。

度量：

- 信息增益(information gain)
- 增益率 (gain ratio)
- 基尼指数(Gini index)

西安交通大学 XI'AN JIAOTONG UNIVERSITY

信息增益

信息熵(entropy)：度量样本集合纯度最常用的一种指标。

假定当前样本集合D中第k类样本所占比例为$p_k(k = 1,2,\dots,|y|)$,则D的信息熵定义为：

$$Ent(D) = -\sum_{k=1}^{|y|} p_k \log_2(p_k)$$

- $Ent(D)$的值越小，则D的纯度越高。
- 约定: 若$p = 0$，则$plog_2(p) = 0$。
- $Ent(D)$的最小值为0，此时D中只有一类；最大值为$\log_2(y)$，此时D中每个样本都是一类。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

信息增益

- D中包含一个类别，那么Ent(D)= $1 \times \log_2 1 = 0$
- D中包含2个类别：

  0.3和0.7，Ent(D)= $-0.3 \times \log_2 0.3 - 0.7 \times \log_2 0.7 = 0.88$；

  0.5和0.5，Ent(D)= $-0.5 \times \log_2 0.5 \times 2 = 1$；

  0.1和0.9，Ent(D)= $-0.1 \times \log_2 0.1 - 0.9 \times \log_2 0.9 = 0.47$
- D中包含5个类别：

  0.2，Ent(D)= $-0.2 \times \log_2 0.2 \times 5 = 2.32$；

  0.05，0.1，0.1，0.05，0.7，Ent(D)= 1.46
- D中包含10个类别， Ent(D)= 3.32

西安交通大学 XI'AN JIAOTONG UNIVERSITY

信息增益

假设离散属性a有V个可能的取值$\{a^1, a^2, \ldots, a^V\}$, D^v表示样本集中在a上取值为a^v的样本集合，可计算出用属性a对样本集D进行划分所获得的“信息增益”：

划分前的信息熵　　划分后的信息熵

$$Gain(D,a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$$

分支权重，即样本数越多，影响越大

- 信息增益越大，则说明使用属性a划分所获得的“纯度提升”越大。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法（Iterative Dichotomiser）

ID3算法：以信息增益为准则来选择划分属性的经典决策树算法

$$a_* = \arg\max_{a \in A} Gain(D, a)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

西瓜数据集：17个训练样例、2个类别

训练开始时，根结点包含D中所有样本，其中正例$p_1 = \frac{8}{17}$，反例$p_2 = \frac{9}{17}$。所以可以计算出根结点的信息熵为：

$$Ent(D) = -(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}) = 0.998$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

- 然后，计算出当前属性集合{色泽、根蒂、敲声、纹理、脐部、触感}中每个属性的信息增益。以属性“色泽”为例，它有3个可能的取值：{青绿，乌黑，浅白}。使用该属性对D进行划分，可得到3个子集，分别记为：D^1（色泽=青绿），D^2（色泽=乌黑），D^3（色泽=浅白）.

- 子集D^1包含编号为{1,4,6,10,13,17}的6个样本，其中正反例$p_1=\frac{3}{6}, p_2=\frac{3}{6}$：

$$Ent(D^1)=-\left(\frac{3}{6}\log_2\frac{3}{6}+\frac{3}{6}\log_2\frac{3}{6}\right)=1.000$$

- 子集D^2包含编号为{2,3,7,8,9,15}的6个样例，其中正反例$p_1=\frac{4}{6}, p_2=\frac{2}{6}$：
- 子集D^3包含编号为{5,11,12,14,16}的5个样例，其中正反例$p_1=\frac{1}{5}, p_2=\frac{4}{5}$.

$$Ent(D^2)=0.918 \quad Ent(D^3)=0.772$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

- 然后，可以计算出属性“色泽”的信息增益为：

$$Gain(D, 色泽) = Ent(D) - \sum_{v=1}^{3} \frac{|D^v|}{|D|} Ent(D^v)$$
$$= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right)$$
$$= 0.109$$

类似的可以计算其他属性的信息增益：

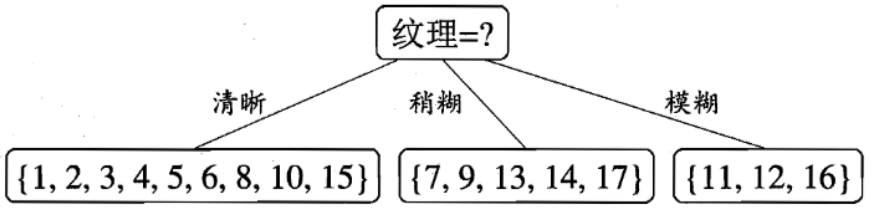
$Gain(D, 根蒂) = 0.143$

$Gain(D, 敲声) = 0.141$

$Gain(D, 纹理) = 0.381$

$Gain(D, 脐部) = 0.289$

$Gain(D, 触感) = 0.006$

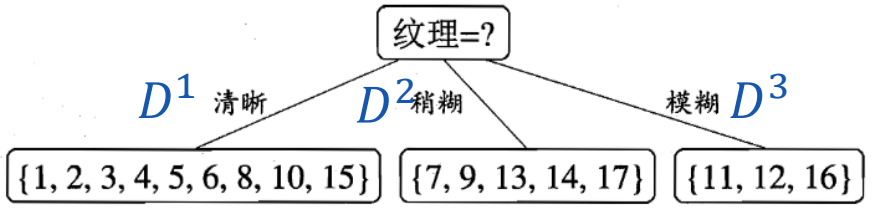


西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

- 然后，对每个分支结点做进一步划分。以第一个分支“清晰”为例，D^1包含编号为{1,2,3,4,5,6,8,10,15}的9个样本，可用属性集合为{色泽、根蒂、敲声、脐部、触感}（此时“纹理”不再作为划分属性）。

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响		凹陷	硬滑	是
2	乌黑	蜷缩	沉闷		凹陷	硬滑	是
3	乌黑	蜷缩	浊响		凹陷	硬滑	是
4	青绿	蜷缩	沉闷		凹陷	硬滑	是
5	浅白	蜷缩	浊响		凹陷	硬滑	是
6	青绿	稍蜷	浊响		稍凹	软粘	是
7	乌黑	稍蜷	浊响		稍凹	软粘	是
8	乌黑	稍蜷	浊响		稍凹	硬滑	是
9	乌黑	稍蜷	沉闷		稍凹	硬滑	否
10	青绿	硬挺	清脆		平坦	软粘	否
11	浅白	硬挺	清脆		平坦	硬滑	否
12	浅白	蜷缩	浊响		平坦	软粘	否
13	青绿	稍蜷	浊响		凹陷	硬滑	否
14	浅白	稍蜷	沉闷		凹陷	硬滑	否
15	乌黑	稍蜷	浊响		稍凹	软粘	否
16	浅白	蜷缩	浊响		平坦	硬滑	否
17	青绿	蜷缩	沉闷		稍凹	硬滑	否



$Gain(D^1, 根蒂) = 0.458$；$Gain(D^1, 敲声) = 0.331$；

$Gain(D^1, 色泽) = 0.043$；$Gain(D^1, 脐部) = 0.458$；

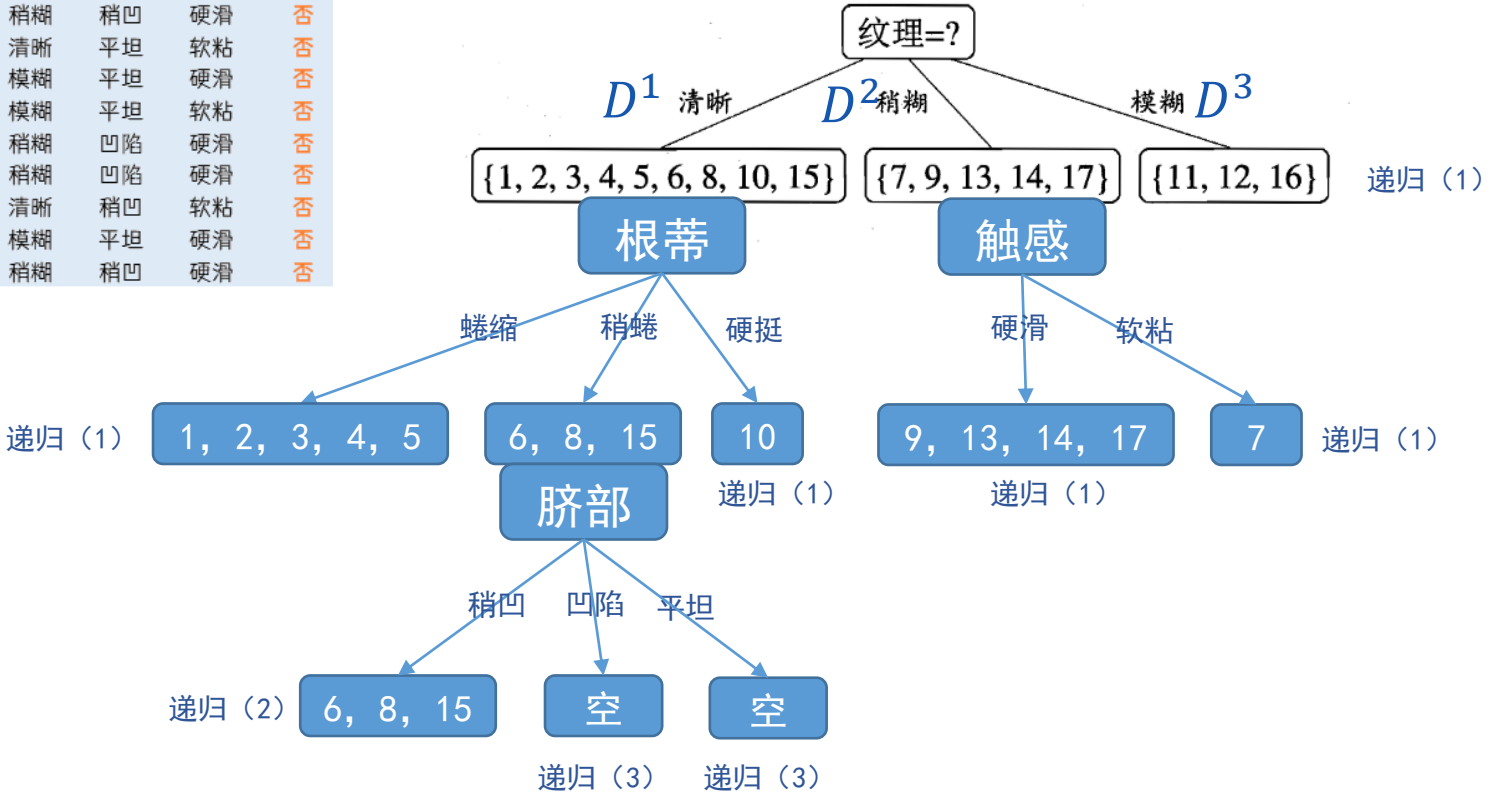
$Gain(D^1, 触感) = 0.458$

- “根蒂”、“脐部”、“触感”3个属性均取得了最大的信息增益，任选其一作为划分属性。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

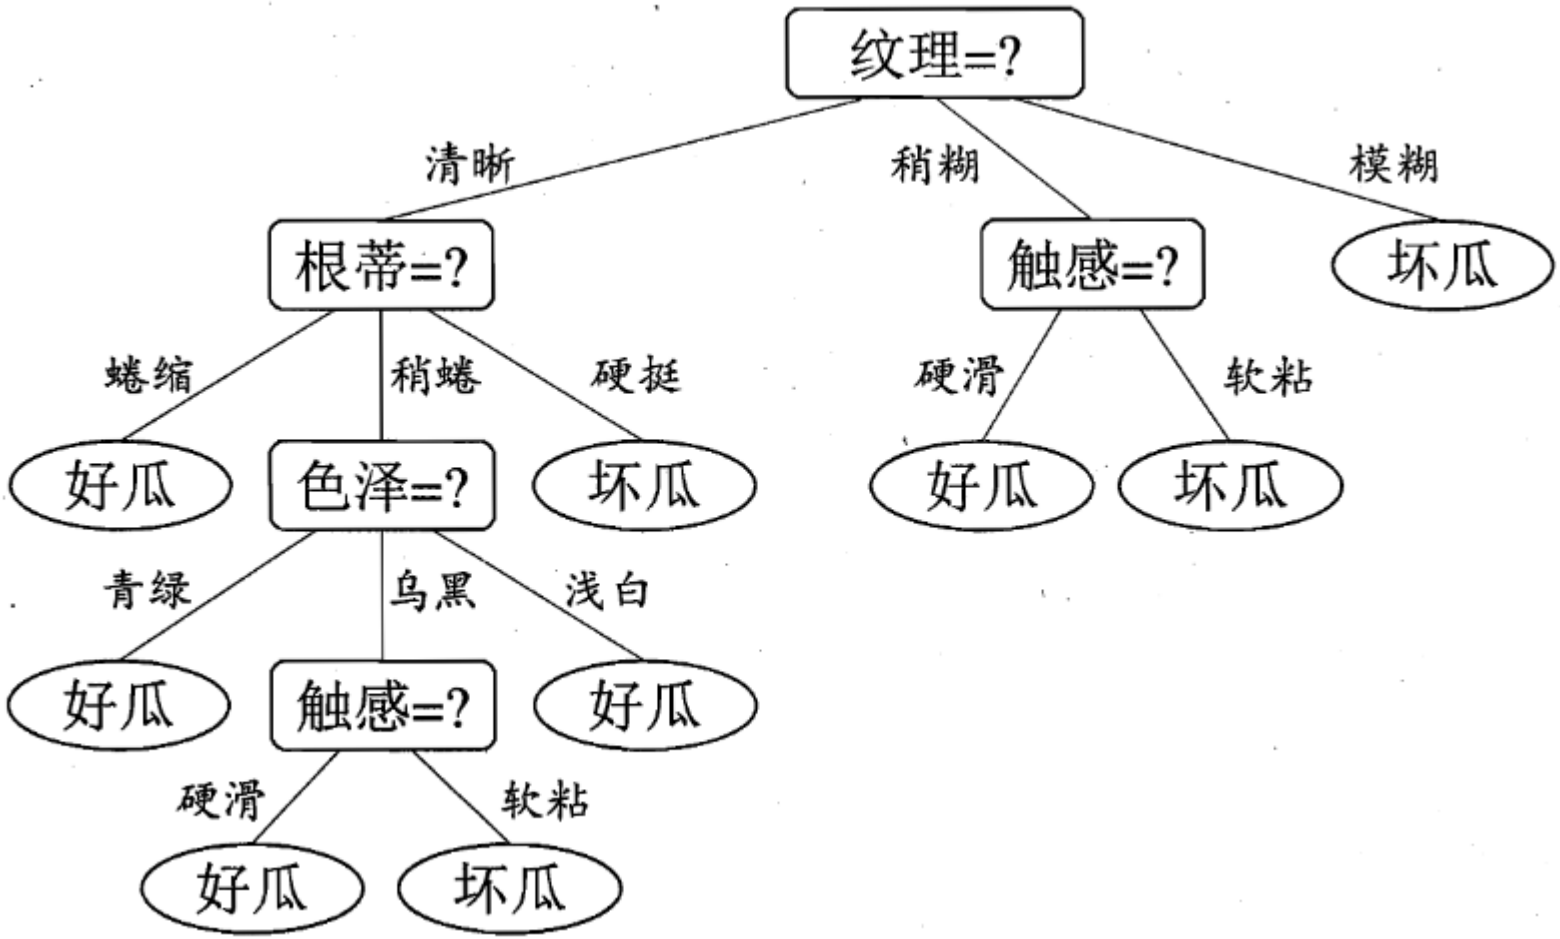
ID3算法

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否



ID3算法

- 类似的，对每个分支结点做上述操作，最终得到决策树。



ID3算法

ID3算法：以信息增益为准则来选择划分属性的经典决策树算法

$$a_* = \arg\max_{a \in A} Gain(D, a)$$

	颜色	重量	表面纹理	形状	种类
1	红色	150	光滑	圆形	苹果
2	黄色	200	粗糙	圆形	橙子
3	黄色	120	光滑	长条形	香蕉
4	红色	180	光滑	圆形	苹果
5	黄色	220	粗糙	圆形	橙子
6	黄色	110	光滑	长条形	香蕉
7	黄色	170	光滑	圆形	苹果
8	黄色	210	粗糙	圆形	橙子
9	黄色	130	光滑	长条形	香蕉
10	红色	160	光滑	圆形	苹果
11	黄色	190	粗糙	圆形	橙子
12	黄色	140	光滑	长条形	香蕉
13	红色	155	光滑	圆形	苹果
14	黄色	215	粗糙	圆形	橙子
15	黄色	125	光滑	长条形	香蕉

以水果分类为例：

属性：颜色、重量、表面纹理、形状

类别	苹果	橙子	香蕉
概率	1/3	1/3	1/3

$$Ent(D) = -3 * \frac{1}{3}\log_2\frac{1}{3} \approx 1.585$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

	颜色	重量	表面纹理	形状	种类
1	红色	150	光滑	圆形	苹果
2	黄色	200	粗糙	圆形	橙子
3	黄色	120	光滑	长条形	香蕉
4	红色	180	光滑	圆形	苹果
5	黄色	220	粗糙	圆形	橙子
6	黄色	110	光滑	长条形	香蕉
7	黄色	170	光滑	圆形	苹果
8	黄色	210	粗糙	圆形	橙子
9	黄色	130	光滑	长条形	香蕉
10	红色	160	光滑	圆形	苹果
11	黄色	190	粗糙	圆形	橙子
12	黄色	140	光滑	长条形	香蕉
13	红色	155	光滑	圆形	苹果
14	黄色	215	粗糙	圆形	橙子
15	黄色	125	光滑	长条形	香蕉

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

- 以属性“颜色”为例，对应两个数据子集D^1(颜色 = 黄色), D^2(颜色 = 红色)
- 子集$D^1 = \{2,3,5,6,7,8,9,11,12,14,15\}$，苹果占比$p_1 = \frac{1}{11}$, 橙子$p_2 = \frac{5}{11}$, 香蕉$p_3 = \frac{5}{11}$； D^2同理，两个结点的信息熵为：

$$Ent(D^1) = -\left(\frac{1}{11}\log_2\frac{1}{11} + \frac{5}{11}\log_2\frac{5}{11} + \frac{5}{11}\log_2\frac{5}{11}\right) \approx 1.349$$

$$Ent(D^2) = -(1 * \log_2 1 + 0\log_2 0) = 0$$

- 属性“颜色”的信息增益为：

$$Gain(D, \text{颜色}) = Ent(D) - \sum_{v=1}^{2}\frac{|D^v|}{|D|}Ent(D^v)$$

$$= 1.585 - \left(\frac{4}{15} * 0 + \frac{11}{15} * 1.349\right) \approx 0.596$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

- 以属性“重量”为例，设定阈值（如是否>160g），两个数据子集$D^1(\text{重量} < 160g), D^2(\text{重量} \geq 160g)$
- $D^1 = \{1,3,4,6,7,9,10,12,13,15\}$, 苹果$p_1 = \frac{2}{7}$，香蕉$p_3 = \frac{5}{7}$

$$Ent(D^1) = -\left(\frac{2}{7}\log_2\frac{2}{7} + \frac{5}{7}\log_2\frac{5}{7}\right) \approx 0.863$$

$$Ent(D^2) = -\left(\frac{3}{8}\log_2\frac{3}{8} + \frac{5}{8}\log_2\frac{5}{8}\right) \approx 0.954$$

- 属性“重量”的信息增益为：

$$Gain(D, \text{重量}) = Ent(D) - \sum_{v=1}^{2}\frac{|D^v|}{|D|}Ent(D^v)$$

$$= 1.585 - \left(\frac{7}{15} * 0.863 + \frac{8}{15} * 0.954\right) \approx 0.673$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

	颜色	重量	表面纹理	形状	种类
1	红色	150	光滑	圆形	苹果
2	黄色	200	粗糙	圆形	橙子
3	黄色	120	光滑	长条形	香蕉
4	红色	180	光滑	圆形	苹果
5	黄色	220	粗糙	圆形	橙子
6	黄色	110	光滑	长条形	香蕉
7	黄色	170	光滑	圆形	苹果
8	黄色	210	粗糙	圆形	橙子
9	黄色	130	光滑	长条形	香蕉
10	红色	160	光滑	圆形	苹果
11	黄色	190	粗糙	圆形	橙子
12	黄色	140	光滑	长条形	香蕉
13	红色	155	光滑	圆形	苹果
14	黄色	215	粗糙	圆形	橙子
15	黄色	125	光滑	长条形	香蕉

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

- 同理，以属性“表面纹理”为例，对应两个数据子集 $D^1(\text{纹理}=\text{光滑}), D^2(\text{纹理}=\text{粗糙})$
- $D^1=\{1,3,4,6,7,9,10,12,13,15\}$，苹果$p_1=\frac{1}{2}$, 香蕉$p_3=\frac{1}{2}$

$$Ent(D^1)=-\left(\frac{1}{2}\log_2\frac{1}{2}+\frac{1}{2}\log_2\frac{1}{2}\right)=1$$

$$Ent(D^2)=-(1\times\log_2 1+0\times\log_2 0)=0$$

- 属性“纹理”的信息增益为：

$$Gain(D,\text{纹理})=Ent(D)-\sum_{v=1}^{2}\frac{|D^v|}{|D|}Ent(D^v)$$

$$=1.585-\left(\frac{1}{2}*1+\frac{1}{2}*0\right)=1.085$$

$$Gain(D,\text{形状})=1.085$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

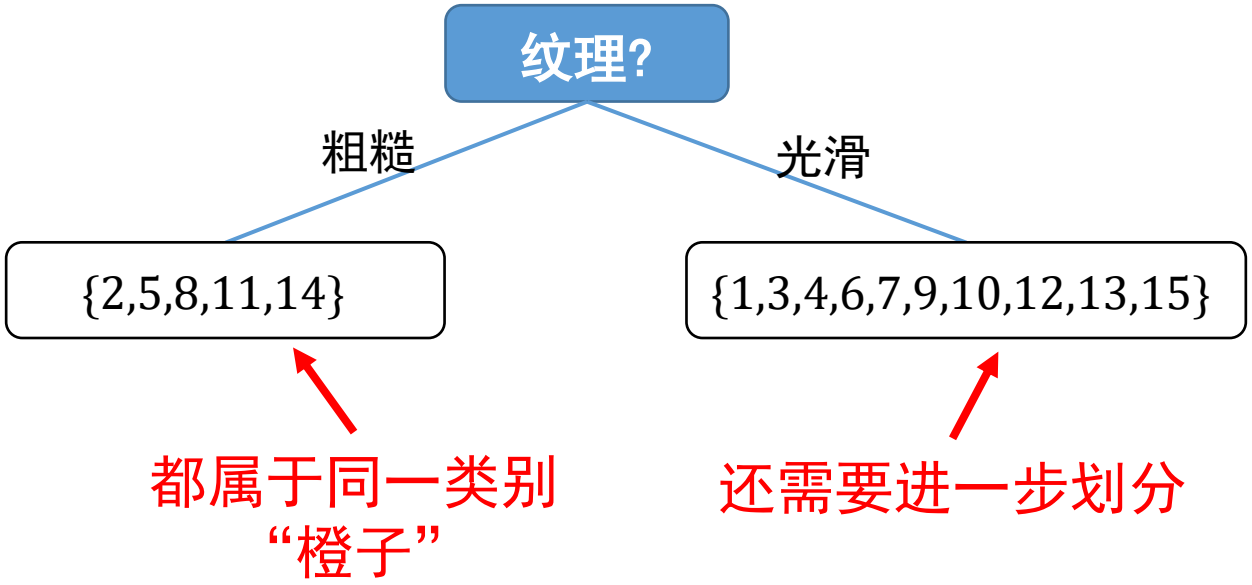
ID3算法

- 各属性的信息增益统计如下：

$$Gain(D, 颜色) = 0.596, \quad Gain(D, 重量) = 0.673$$

$$Gain(D, 纹理) = \boxed{1.085,} \quad Gain(D, 形状) = \boxed{1.085}$$

- 选择信息增益最大的属性（纹理/形状）为划分属性，可得：



西安交通大學 XI'AN JIAOTONG UNIVERSITY

ID3算法

第一次划分后，右侧子结点样本集。 $Ent(D') = -2 * \frac{1}{2}\log_2\frac{1}{2} \approx 1$

	颜色	重量	表面纹理	形状	种类
1	红色	150	光滑	圆形	苹果
3	黄色	120	光滑	长条形	香蕉
4	红色	180	光滑	圆形	苹果
6	黄色	110	光滑	长条形	香蕉
7	黄色	170	光滑	圆形	苹果
9	黄色	130	光滑	长条形	香蕉
10	红色	160	光滑	圆形	苹果
12	黄色	140	光滑	长条形	香蕉
13	红色	155	光滑	圆形	苹果
15	黄色	125	光滑	长条形	香蕉

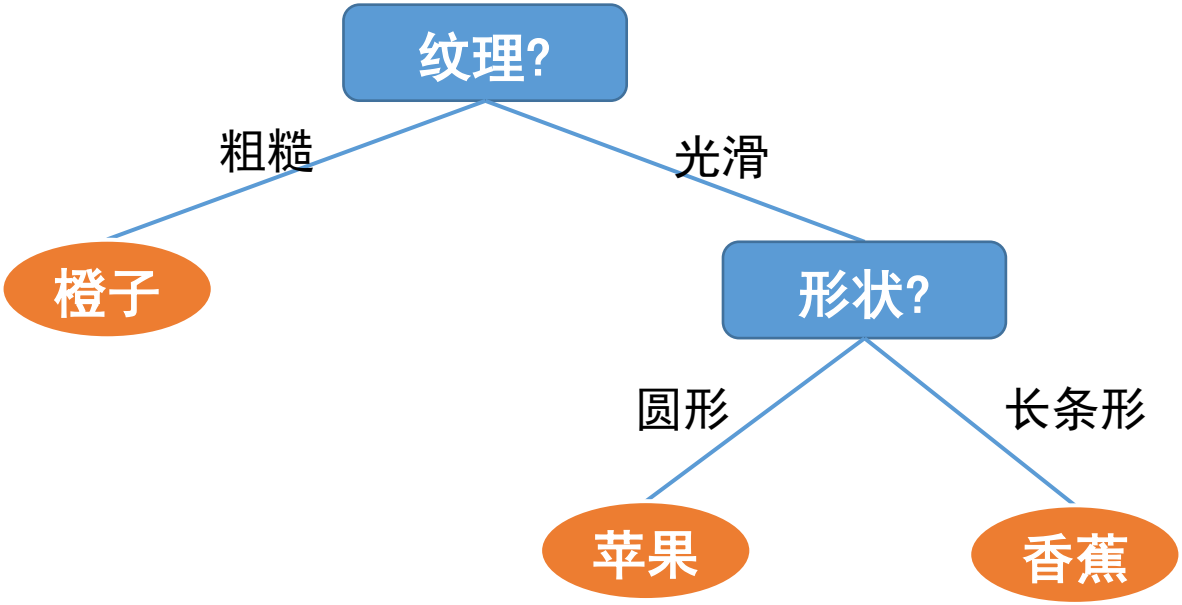
$Gain(D', 形状) = 1,$ $Gain(D', 颜色) = 0.61$

$Gain(D', 重量) = 0.396, Gain(D', 纹理) = 0$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

ID3算法

对分支结点做进一步划分，可得到决策树：



增益率

- 信息增益对可取值数目较多的属性有所偏好。
  - 比如，若将“编号”也作为一个候选划分属性，则根据信息增益度量，将会选择“编号”作为划分属性。
  - $Gain(D,a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$
  - D的信息熵是确定的，第二项越小，增益越大。当一个属性在每个样本上的值都不同时，得到的每个分支结点纯度都是最大的（熵最小），因此信息增益最大。
  - 这样的决策树显然不具备泛化能力！

西安交通大学 XI'AN JIAOTONG UNIVERSITY

增益率

增益率：$$Gain_ratio(D,a) = \frac{Gain(D,a)}{IV(a)}$$

其中 $IV(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$，称为属性a的固有值（intrinsic value）。属性a的可能取值数目越多（即V越大），$IV(a)$的值通常越大。

$$IV(\text{触感}) = -(\frac{12}{17} \times \log_2 \frac{12}{17} + \frac{5}{17} \times \log_2 \frac{5}{17}) = 0.874$$

$$IV(\text{色泽}) = -\sum_{v=1}^{3} \frac{|D^v|}{17} \log_2 \frac{|D^v|}{17} = 1.580$$

$$IV(\text{编号}) = -\sum_{v=1}^{17} \frac{|D^v|}{17} \log_2 \frac{|D^v|}{17} = 4.088$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

XI'AN JIAOTONG UNIVERSITY

增益率

- 增益率准则对可取值数目较少的属性有所偏好。
- C4.5算法：不直接选择增益率最大的候选划分属性，采用启发式，即先从候选划分属性中找出信息增益高于平均水平的属性，再从中选择增益率最高的。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

基尼指数

数学上用于信息量（或者纯度）衡量的不止有熵相关的定义，还可以使用基尼指数来表示数据集的不纯度。

基尼值：度量数据集D的纯度

$$Gini(D) = \sum_{k=1}^{|y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|y|} p_k^2$$

- 即从数据集D中随机抽取两个样本，其类别标记不一致的概率
- Gini(D)越小，数据集D的纯度越高。
- 有放回摸球，有不同颜色的球，其中第k类占比记作p_k，那两次摸到的球都是第k类的概率就是p_k^2，那两次摸到的球颜色不一致的概率就是1- $\sum p_k^2$，它的取值越小，两次摸球颜色不一致的概率就越小，纯度就越高。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

基尼指数

CART决策树使用“基尼指数”来选择划分属性.

CART - Classification and Regression Tree

属性a的基尼指数：$Gini_index(D,a)=\sum_{v=1}^{V}\frac{|D^v|}{|D|}Gini(D^v)$

- 在候选属性集合中，选择使得划分后基尼指数最小的属性。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.4.3 过拟合 vs. 欠拟合

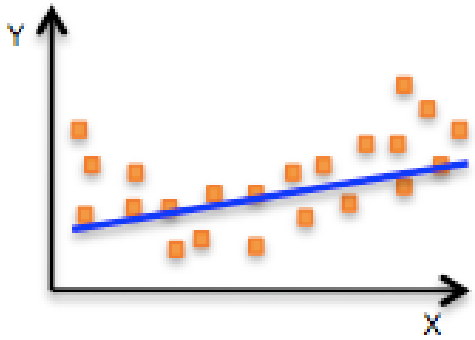
在构建决策树的过程中，考虑一个策略：

对于每一个可以进一步划分的结点都进行划分，直到得到一个不可划分的子结点，并将该子结点定为叶结点，从而得到一个所有叶结点均为不可进一步划分的结点。 该策略是否可行？

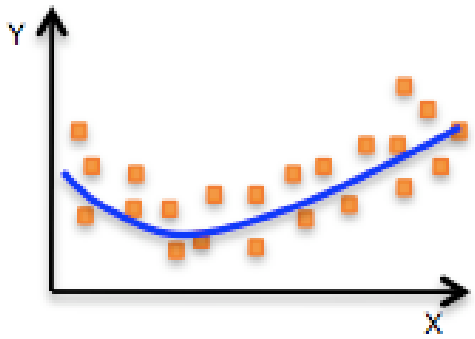
否。决策树是根据训练样本的集合构成的。该集合中的样本是随机的。不同的随机实验会得到不同的样本集合。因此，该集合并不能完全描述样本(即特征向量)真实分布。当叶结点按上述方法确定时，所得决策树虽然对训练样本集合给出了最优的分类，但是却背离了样本的真实分布，因此削弱了对未来新样本的分类能力。这一现象称为过度拟合(指决策数对训练样本过度拟合，从而背离了样本的真实分布)。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

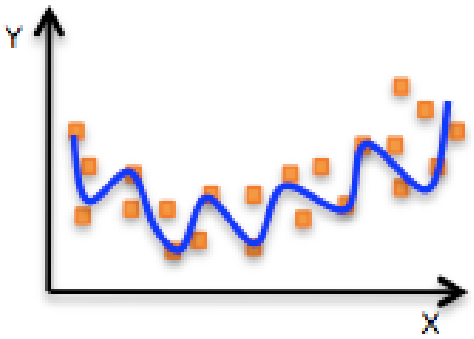
过拟合 vs 欠拟合



Underfitting



Just right!



overfitting

训练样本





新样本



过拟合模型分类结果：

→ 不是树叶

（误以为树叶必须有锯齿）



欠拟合模型分类结果：

→ 是树叶

（误以为绿色的都是树叶）

6.4.3 过拟合 vs. 欠拟合

过拟合

决策树模型对训练数据学习得过于“细致”，包括学习到数据中的噪声或异常，从而对训练数据表现很好，但对新数据的泛化能力较差。

特征：

- 决策树深度过大，叶节点过多，每个叶节点包含的数据量很少
- 训练集准确率很高，但测试集准确率较低。

欠拟合

决策树模型没有充分学习训练数据中的模式，模型过于简单，无法捕捉数据的复杂结构。

特征：

- 决策树深度过小，分裂次数不足。
- 训练集和测试集的准确率都较低。

在过拟合与欠学习之间寻求合理的平衡。

克服过拟合与欠拟合的方法

测试集方法

- 将数据样本集合分为训练集与测试集。
- 根据训练集构建决策树，每展开一层子结点，就将其设为叶结点，并得到一棵决策树，然后采用测试集对所得决策树的分类性能进行统计。
- 重复上述过程，可以得到决策树在测试集上的学习曲线。
- 根据学习曲线，选择在测试集上性能最佳的决策树为最终的决策树。

阈值方法

- 在决策树开始训练之前，先设定一个阈值作为终止学习的条件。
- 在学习过程中如果一个结点满足了终止条件就停止划分，并将其作为叶结点。
- 终止条件：
  - ✓ 可以选择为信息增益小于某阈值；
  - ✓ 或结点中样本数量占全体样本数量的比例小于某阈值。

剪枝方法

西安交通大学 XI'AN JIAOTONG UNIVERSITY

剪枝

“剪枝”(pruning)是决策树学习算法应对“过拟合”的主要手段。

通过主动去掉一些分支来降低过拟合的风险

基本策略：

- 预剪枝(pre-pruning): 提前终止某些分支的生长。
- 后剪枝(post-pruning): 生成一颗完全树，再“回头”剪枝

剪枝过程中需评估剪枝前后决策树的泛化性能是否提升

“留出法”：预留一部分数据用作验证集以进行性能评估。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

剪枝

训练集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

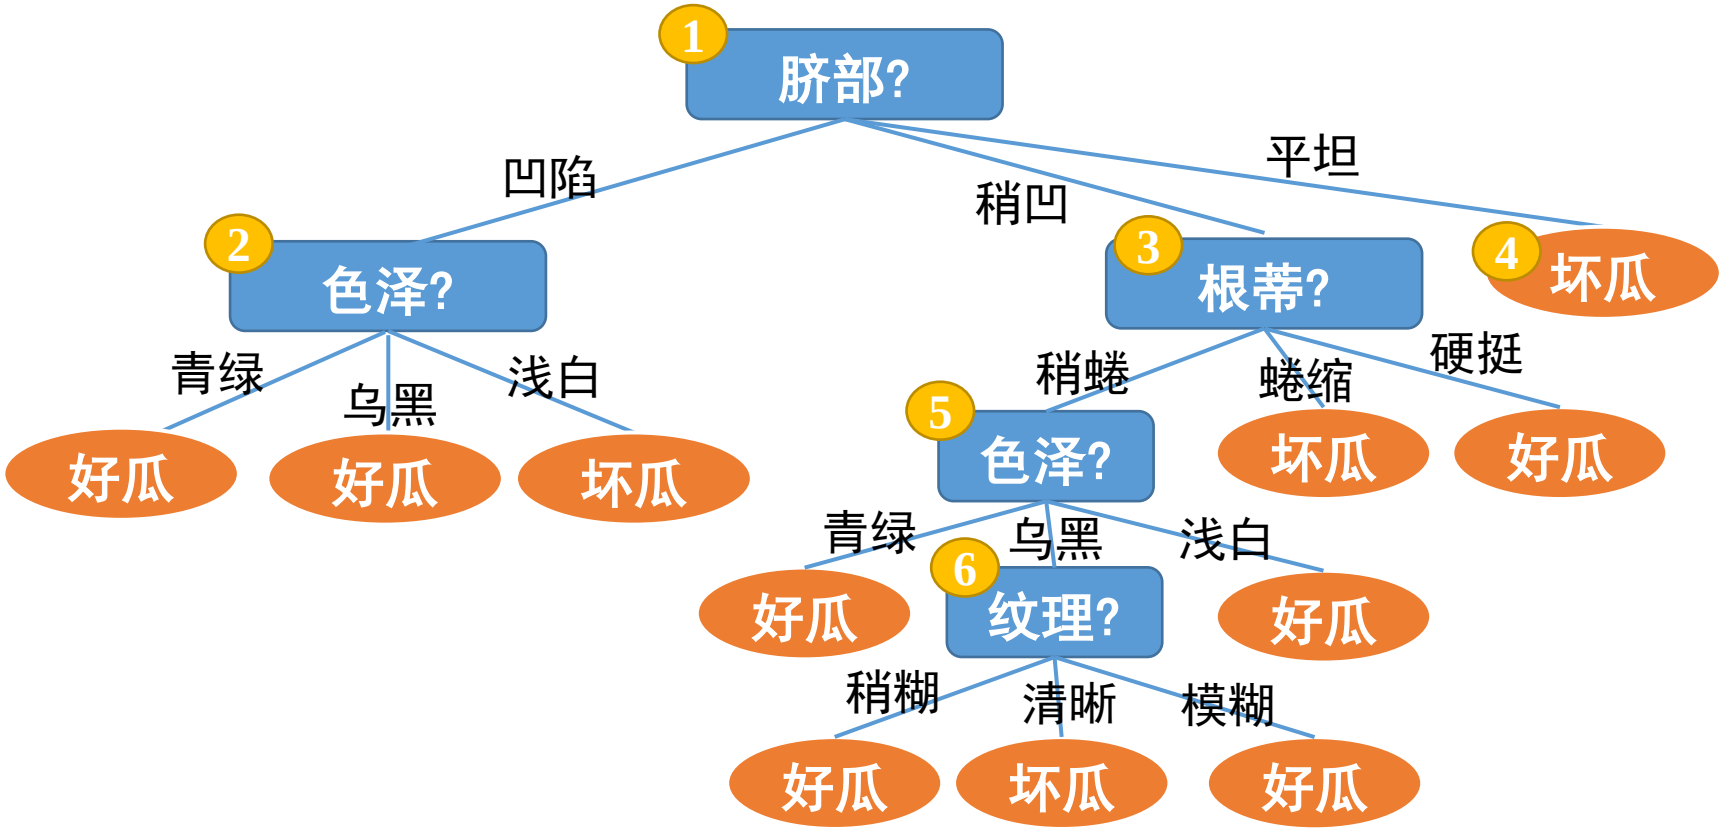
验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

西安交通大学 XI'AN JIAOTONG UNIVERSITY

剪枝

- 采用信息增益进行划分属性选择，从上述训练集中可以得到如下图所示的决策树。



预剪枝

- 预剪枝：在决策树生成过程中，对每个结点划分前先进行估计，若当前结点的划分不能提升决策树泛化性能，则停止划分，并将当前结点标记为叶结点。

① 划分之前，所有样例集中在根结点。若不划分，该结点记为叶结点，且类别标记应为“好瓜”。

好瓜

验证集精度：

$\frac{3}{7} * 100\% = 42.9\%$

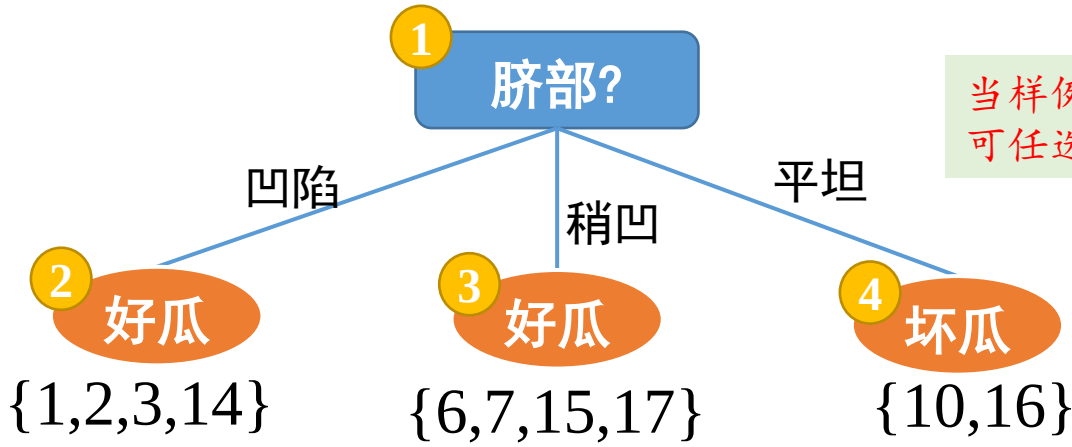
编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	√
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	√
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	√
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	×
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	×
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	×

西安交通大学 XI'AN JIAOTONG UNIVERSITY

预剪枝

② 若用属性“脐部”划分，划分后精度 > 划分前精度

训练阶段



当样例最多的类不唯一时，可任选其中一类

训练集

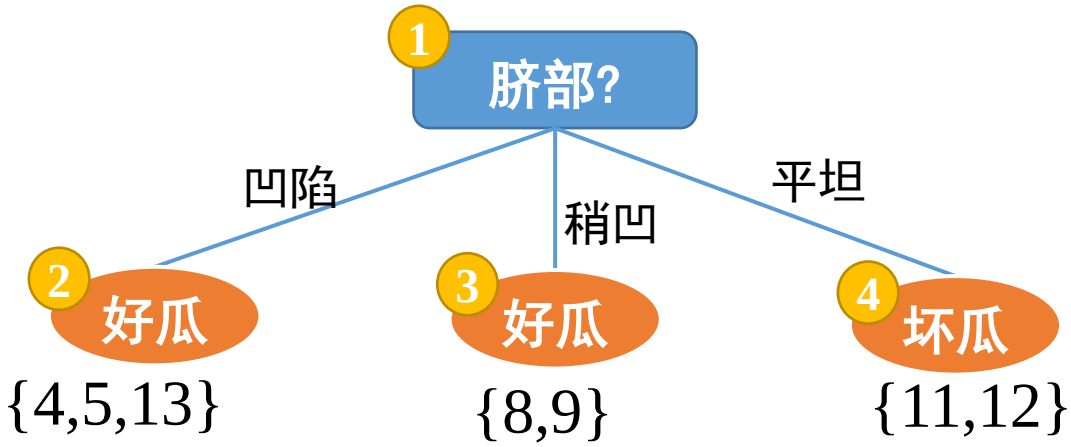
编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

西安交通大学 XI'AN JIAOTONG UNIVERSITY

预剪枝

② 若用属性“脐部”划分，划分后精度 > 划分前精度

测试阶段



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	√
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	√
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	√
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	√
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	√
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	×

验证集精度：

$\frac{5}{7} * 100\% = 71.4\%$

划分 √

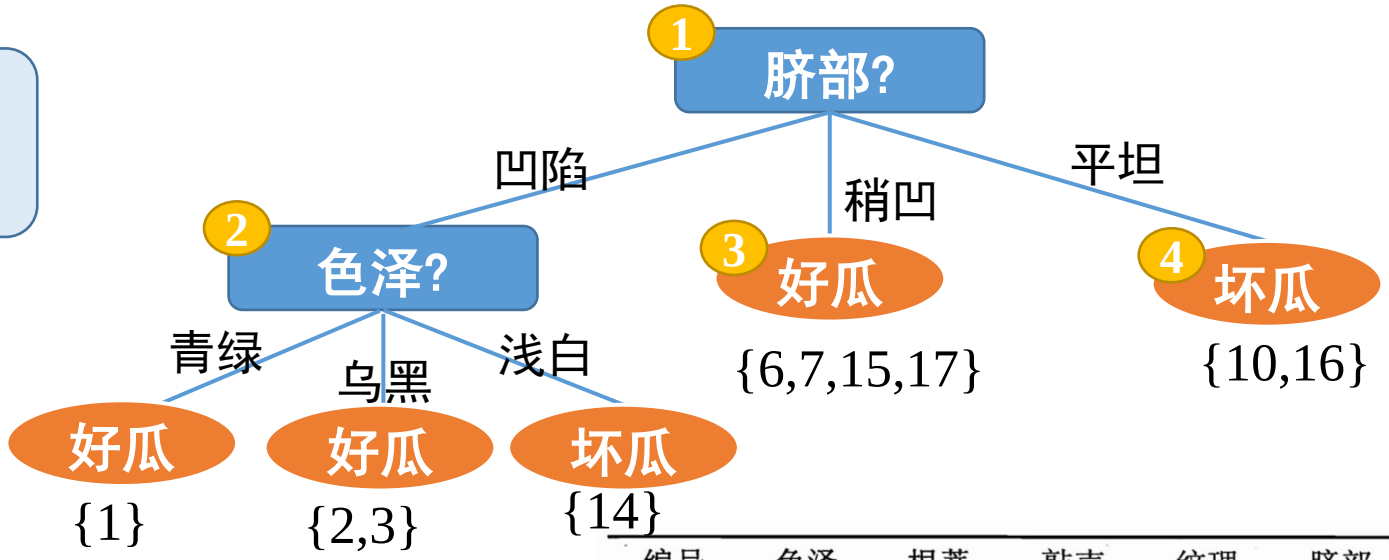
西安交通大学 XI'AN JIAOTONG UNIVERSITY

预剪枝

③ 对子结点2进行划分：

- 基于信息增益算法，选择“色泽”作为划分属性

训练阶段



训练集

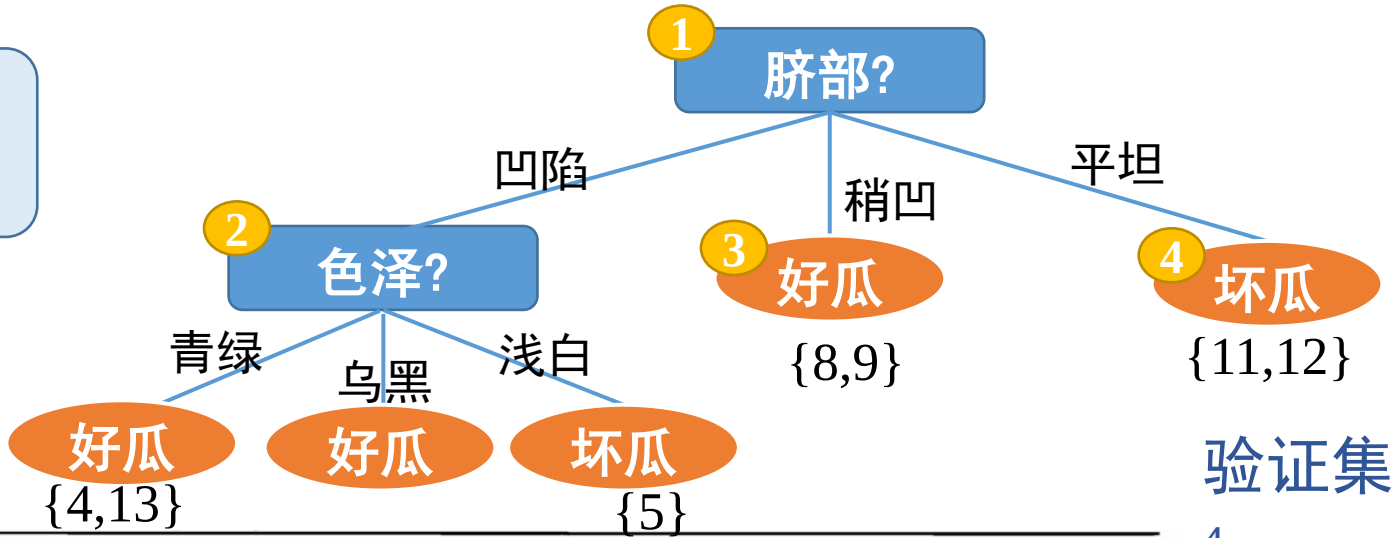
编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

预剪枝

③ 对子结点2进行划分：

- 基于信息增益算法，选择“色泽”作为划分属性

测试阶段



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是 √
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是 ×
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是 √
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否 ×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否 √
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否 √
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否 ×

验证集精度：

$\frac{4}{7} * 100\% = 57.1\%$

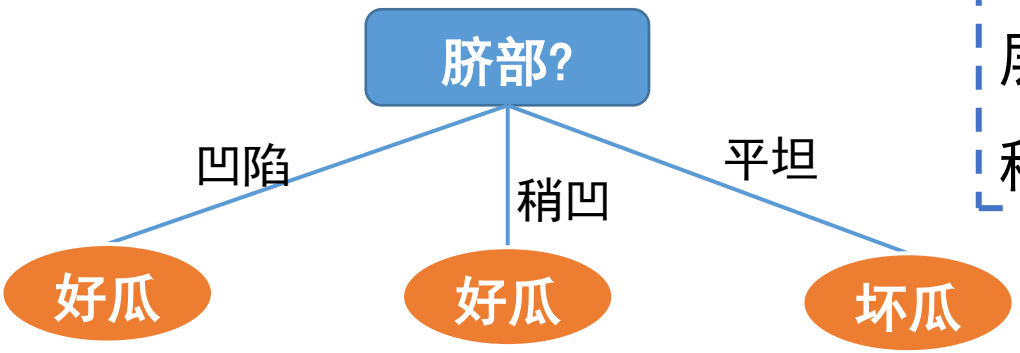
划分 ×

西安交通大学 XI'AN JIAOTONG UNIVERSITY

预剪枝

④ 同理，对子结点3按照属性“根蒂”进行划分，划分后验证集精度仍为71.4%，因此禁止划分。

⑤ 最后得到决策树如下：

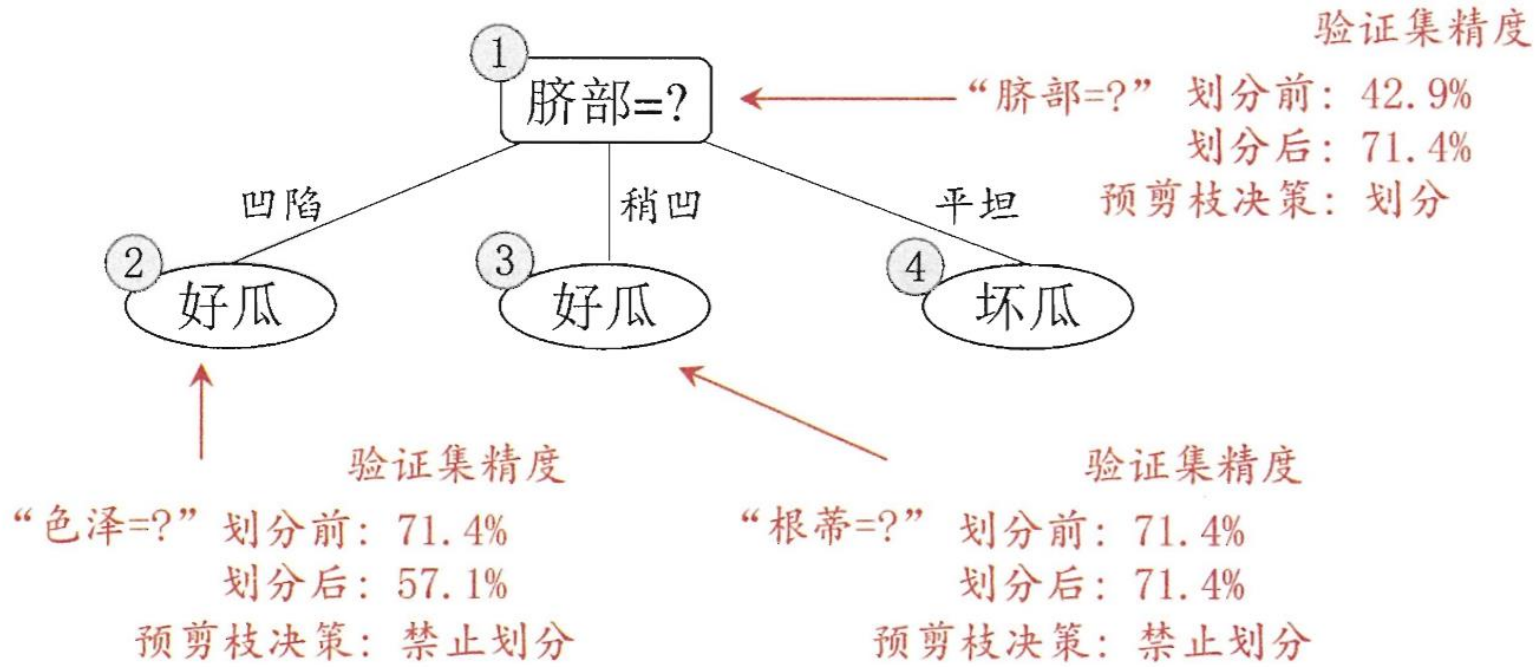


特别地，只有一层划分的决策树称为“决策树桩”

- 显著降低过拟合风险，显著减少训练和测试的时间开销。
- 虽然当前划分不能提升性能，但后续划分可能大幅提升性能。
- 预剪枝基于“贪心”本质禁止分支展开，存在欠拟合风险。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

预剪枝


验证集精度
1
脐部=?
“脐部=?” 划分前：42.9%
划分后：71.4%
预剪枝决策：划分
凹陷
稍凹
平坦
2
好瓜
3
好瓜
4
坏瓜
验证集精度
“色泽=?” 划分前：71.4%
划分后：57.1%
预剪枝决策：禁止划分
验证集精度
“根蒂=?” 划分前：71.4%
划分后：71.4%
预剪枝决策：禁止划分

后剪枝

- 将数据分为训练集和验证集，用训练集去生成一颗完整的决策树，用验证集去剪枝。
- 该算法将树上的每个节点都作为剪枝的候选对象，通过如下步骤进行剪枝操作:

step1:删除以此节点为根节点的树

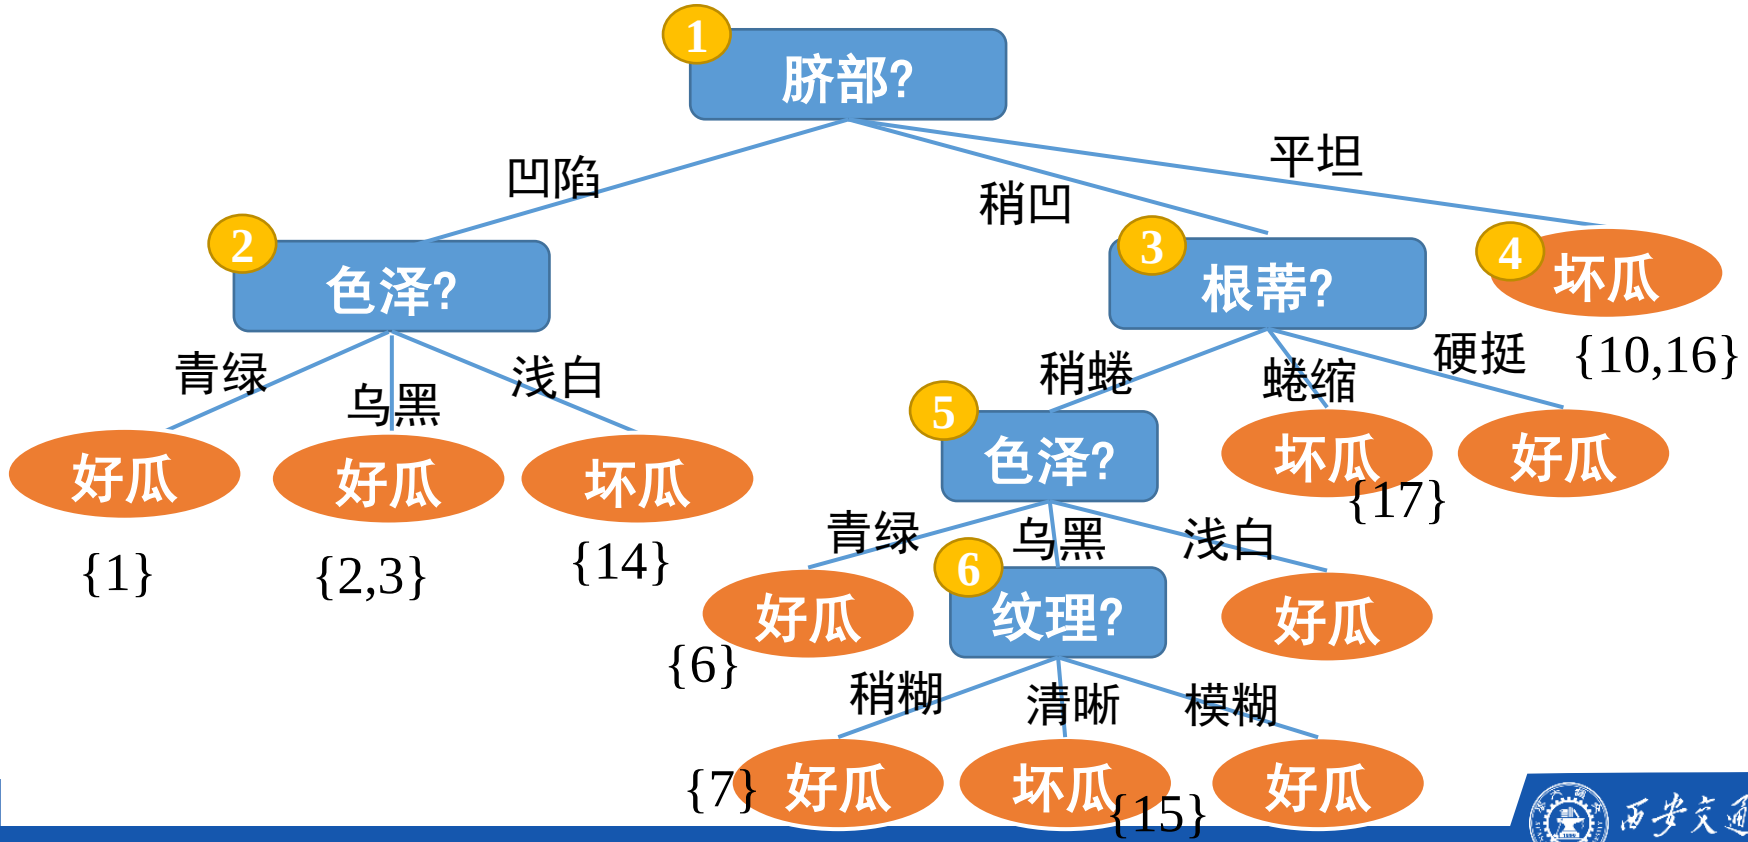
step2:使其成为叶子结点，赋予该节点最常见的分类

step3:对比删除前和删除后的性能是否有所提升，如果有则进行删除，没有则保留

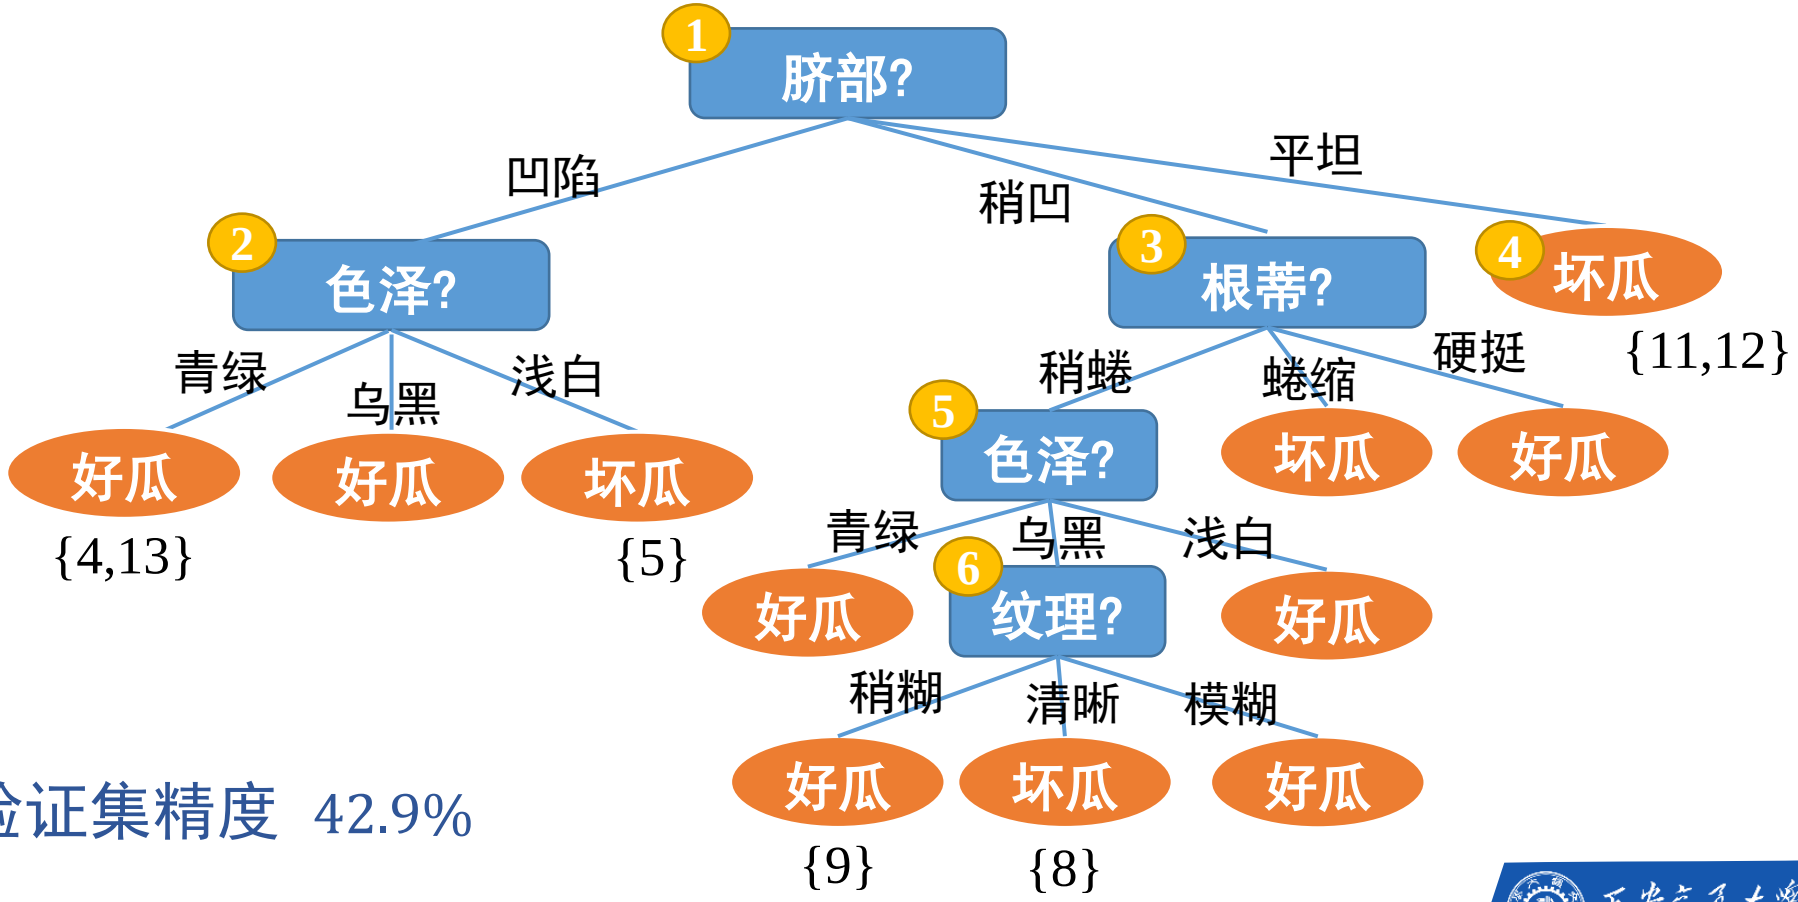
西安交通大学 XI'AN JIAOTONG UNIVERSITY

后剪枝

- 后剪枝：先从训练集中生成一颗完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能的提升，则将该子树替换成叶结点。



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是 √
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是 ×
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是 ×
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否 ×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否 √
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否 √
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否 ×

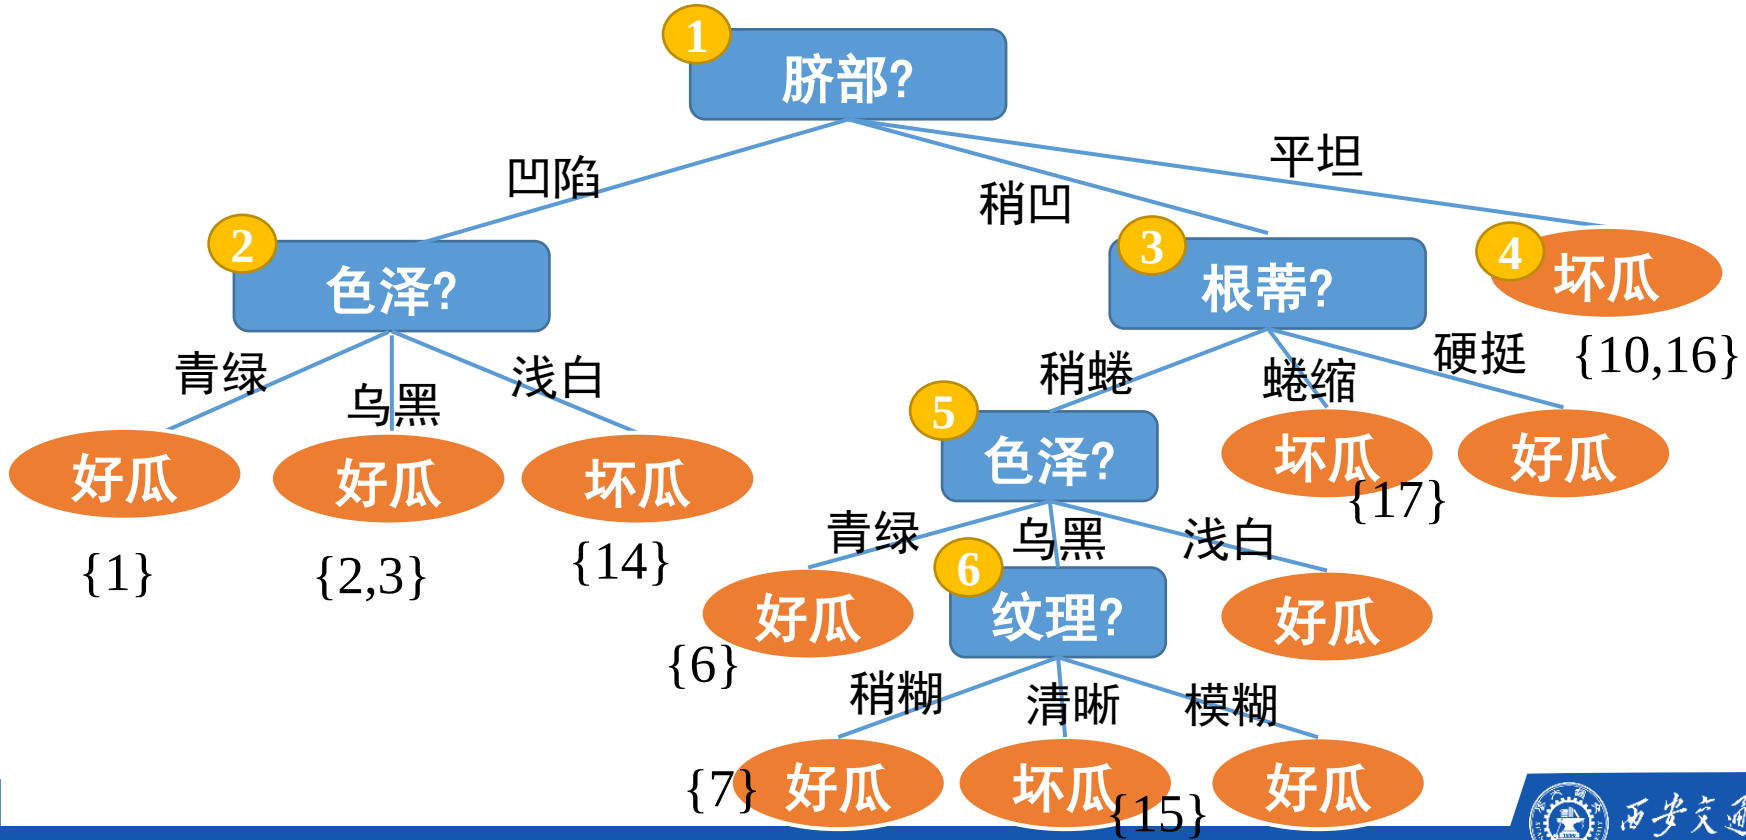


验证集精度 42.9%

后剪枝

① 首先考察结点6。若将其子树剪除，即替换为叶结点，根据样本分布{7,15}标记为“好瓜”。

替换后验证集精度提高到57.1%，因此剪枝。

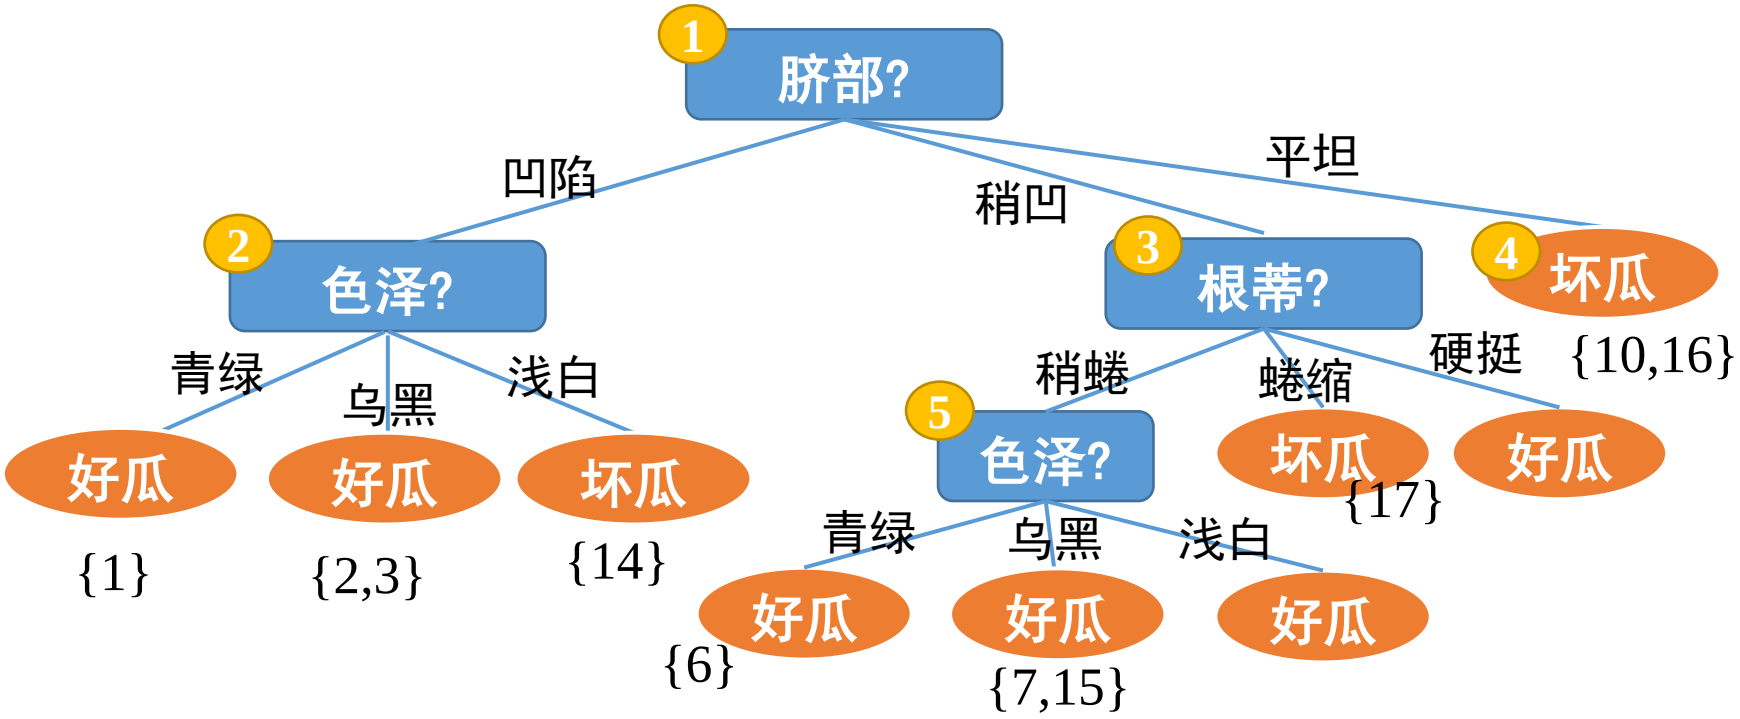


西安交通大學 XI'AN JIAOTONG UNIVERSITY

后剪枝

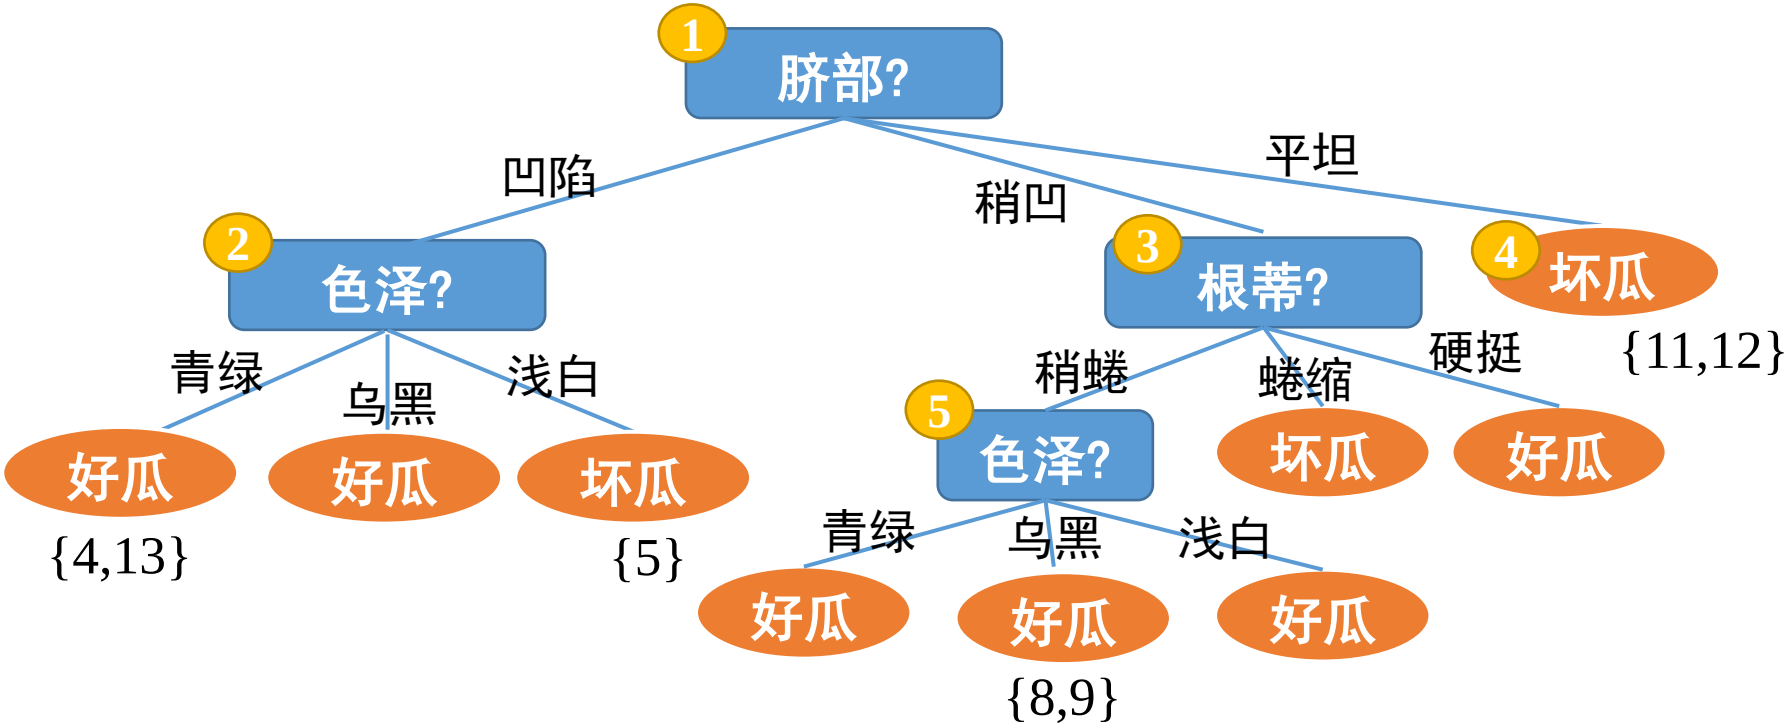
① 首先考察结点6。若将其子树剪除，即替换为叶结点，根据样本分布{7,15}标记为“好瓜”。

替换后验证集精度提高到57.1%，因此剪枝。



西安交通大學 XI'AN JIAOTONG UNIVERSITY

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是 √
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是 ×
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是 √
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否 ×
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否 √
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否 √
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否 ×

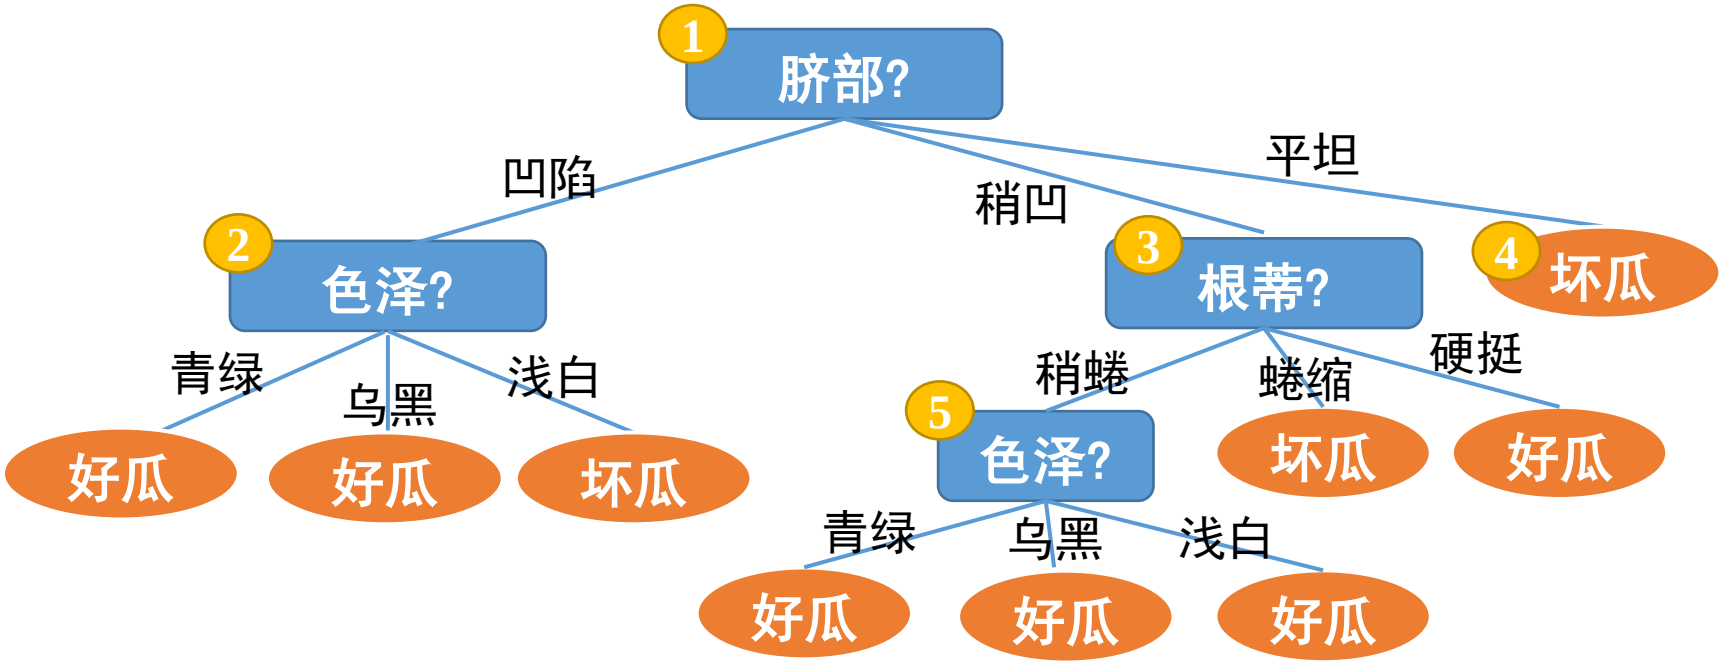


验证集精度 57.1%

后剪枝

② 然后考察结点5。若将其子树替换为叶结点，根据样本分布{6,7,15}标记为“好瓜”。

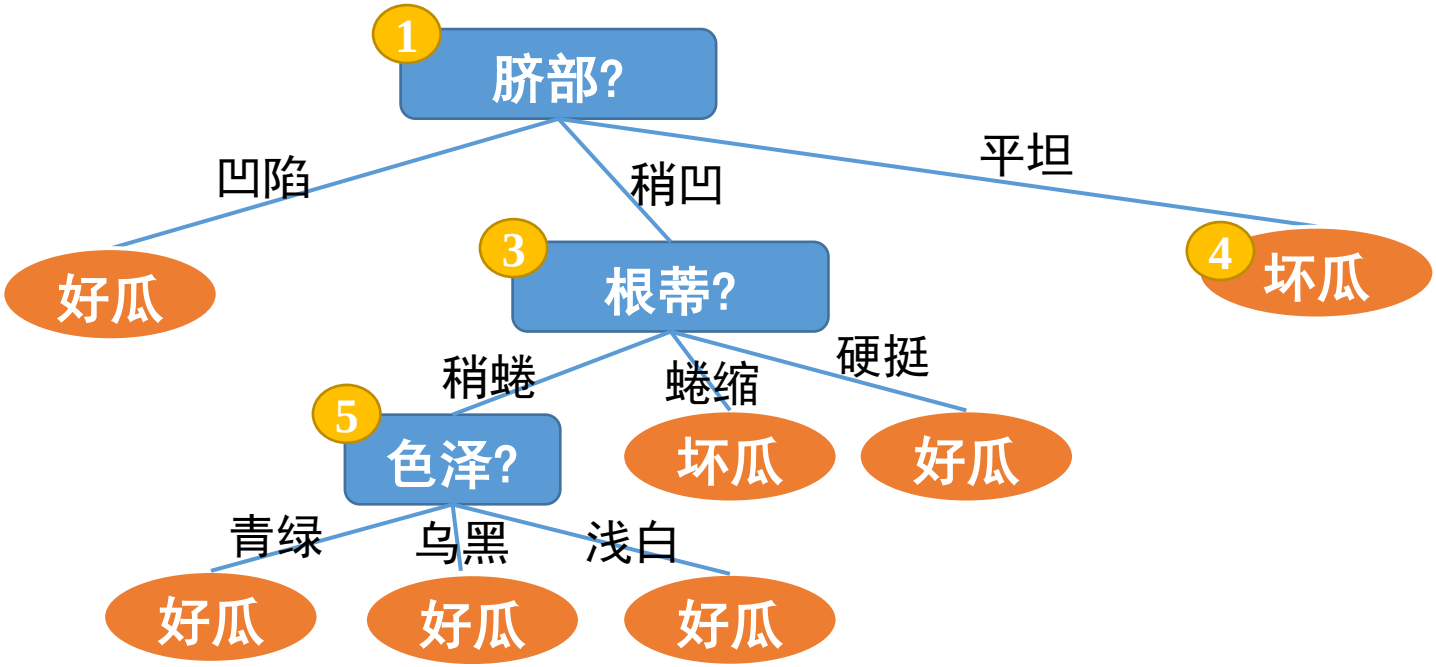
替换后验证集精度仍为57.1%，因此可以不剪枝。



后剪枝

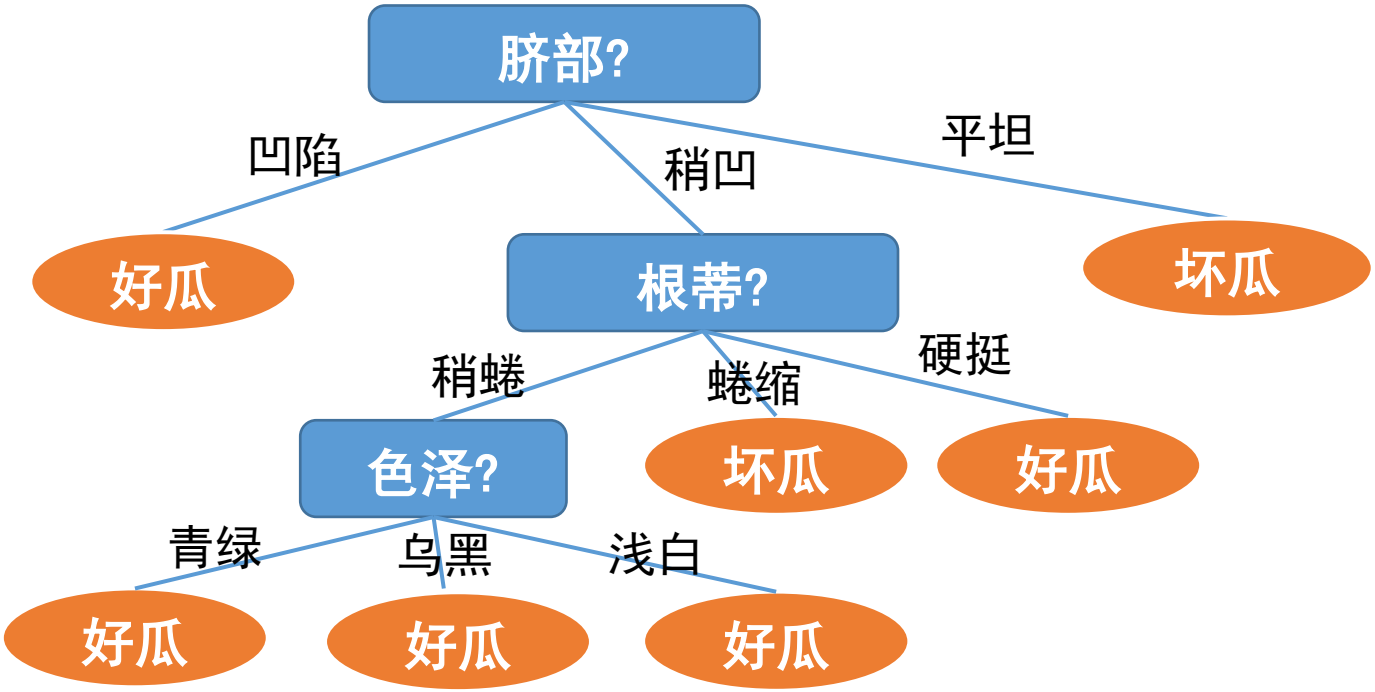
③ 然后考察结点2。若将其子树替换为叶结点，根据样本分布{1,2,3,14}标记为“好瓜”。

替换后验证集精度提高到71.4%，因此剪枝。



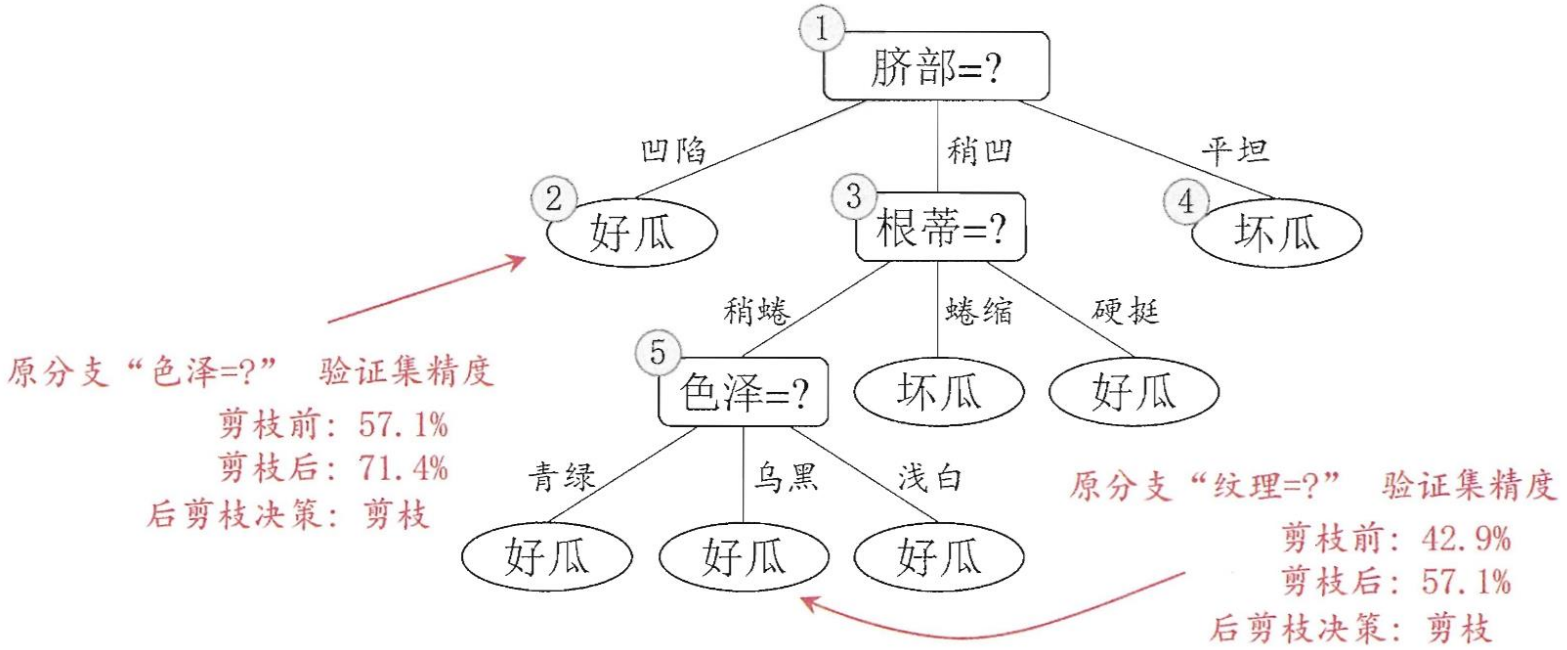
后剪枝

④ 对于结点3和结点1，若将其子树替换为叶结点，验证集精度均未得到提高，因此保留，得到最终的决策树如下：



后剪枝

- 后剪枝通常比预剪枝保留更多的分支。
- 欠拟合风险更小，泛化性能往往优于预剪枝决策树。
- 生成完全决策树之后进行的，训练时间开销大。



6.4.4 连续值、缺失值

连续值处理基本思路：连续属性离散化

常用策略：二分法 —— C4.5决策树算法

- 给定样本集D和连续属性a,假设a在D上有n个不同的取值
- 取值从小到大排序，记为$\{a^1, a^2, \ldots, a^n\}$
- 基于划分点t可将D分为子集D_t^+和D_t^-，其中D_t^-包含在属性a上取值不大于t的样本，而D_t^+则包含取得大于t的样本
- 显然对于相邻的a^i和a^{i+1}来说，t在区间$[a^i, a^{i+1})$中取任意值所产生的划分结果相同

西安交通大学 XI'AN JIAOTONG UNIVERSITY

连续值

- 对于连续属性a，可以考察n个属性值形成的n-1个候选划分点 ($[a^i, a^{i+1}$)的中位点)

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \middle| 1 \le i \le n-1 \right\}$$

- 与离散属性值一样考察这些候选划分点，选取最优的划分点进行样本集合的划分。

$$Gain(D,a) = \max_{t \in T_a} Gain(D,a,t)$$

$$= \max_{t \in T_a} Ent(D) - \sum_{\lambda \in \{-,+\}} \frac{|D_t^\lambda|}{|D|} Ent(D_t^\lambda)$$

$Gain(D,a,t)$ 是样本集D基于划分点t二分后的信息增益

西安交通大学 XI'AN JIAOTONG UNIVERSITY

连续值

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \middle| 1 \le i \le n-1 \right\}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

$$i = 1\text{时：}\ T_{\text{密度}} = \frac{a^1 + a^2}{2} = \frac{0.243 + 0.245}{2} = 0.244$$

$$i = 2\text{时：}\ T_{\text{密度}} = \frac{a^2 + a^3}{2} = \frac{0.245 + 0.343}{2} = 0.294$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

连续值

- 对属性“密度”，根结点包含的17个训练样本在该属性上取值均不同。该属性的候选划分点集合包含16个候选值。$T_{密度} = \{0.244,\ 0.294,\ 0.351, 0.381, \dots,\ 0.648,\ 0.661,\ 0.681,\ 0.708,\ 0.746\}$。
- 计算出属性“密度”的信息增益为 0.262，对应于划分点 0.381。
- $D_{0.381}^{-} = \{排名1-4的密度值\}$，$D_{0.381}^{+} = \{排名5-17的密度值\}$

$$Gain(D, a, 0.381) = Ent(D) - \sum_{\lambda \in \{-,+\}} \frac{|D_{0.381}^{\lambda}|}{|D|} Ent\left(D_{0.381}^{\lambda}\right) = 0.262$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

连续值

- 对属性“含糖率”，其候选划分点集合也包含16个候选值：

$T_{\text{含糖率}} = \{0.049, 0.074, 0.095, 0.101, \ldots, 0.292, 0.344, 0.373, 0.418\}$。类似的，可计算出其信息增益为0.349，对应于划分点0.126。

$Gain(D, \text{根蒂}) = 0.143$；$Gain(D, \text{敲声}) = 0.141$；

$Gain(D, \text{色泽}) = 0.109$；$Gain(D, \text{脐部}) = 0.289$；

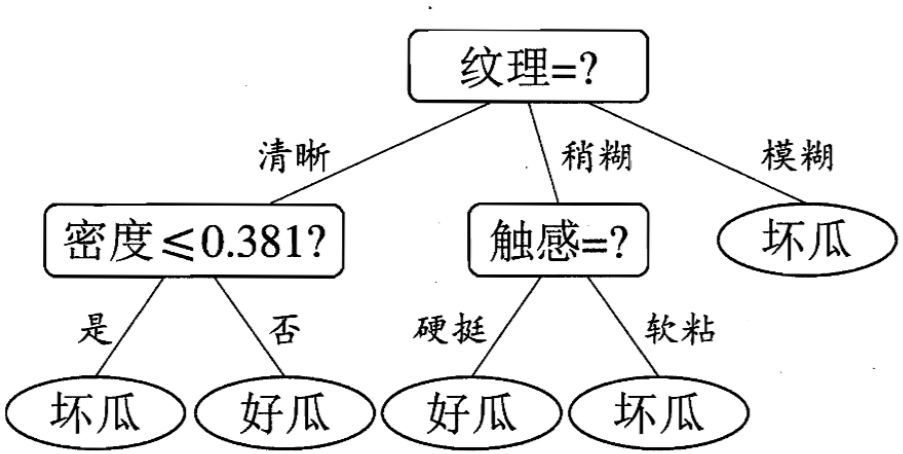
$Gain(D, \text{触感}) = 0.006$；$Gain(D, \text{纹理}) = 0.381$；

$Gain(D, \text{密度}) = 0.262$；$Gain(D, \text{含糖率}) = 0.349$；

西安交通大學 XI'AN JIAOTONG UNIVERSITY

连续值

- 于是，“纹理”被选作根结点划分属性，此后结点划分过程递归进行，最终生成如图所示的决策树。



- 需注意的是，与离散属性不同，若当前结点划分属性为连续属性，该属性还可作为其后代结点的划分属性。
- 例如在父结点上使用了“密度≤0. 381”不会禁止在子结点上使用“密度≤ 0. 294”。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

现实任务中常会遇到不完整样本，即样本某些属性值缺失

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

现实任务中常会遇到不完整样本，即样本某些属性值缺失

仅使用无缺失的样例？→ 对数据的极大浪费

① 如何在属性值缺失的情况下进行划分属性选择？

② 给定划分属性，若样本在该属性上的值缺失，如何对样本进行划分？

基本思路：样本赋权，权重划分

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

① 如何在属性值缺失的情况下进行划分属性选择？

通过无缺失值的样例来判断划分属性的优劣。

给定数据集D和属性a，$\tilde{D}$表示D中在属性a上无缺失值的样本子集

$\tilde{D}^v$表示$\tilde{D}$中在属性a上取值为a^v的样本子集

$\tilde{D}_k$表示$\tilde{D}$中属于第k类的样本子集，

为每个样本x赋予一个权重w_x，定义：

$$\rho = \frac{\sum_{x\in\tilde{D}} w_x}{\sum_{x\in D} w_x}, \tilde{p}_k = \frac{\sum_{x\in\tilde{D}_k} w_x}{\sum_{x\in\tilde{D}} w_x} \quad (1 \le k \le |y|),$$

$$\tilde{r}_v = \frac{\sum_{x\in\tilde{D}^v} w_x}{\sum_{x\in\tilde{D}} w_x} \quad (1 \le v \le V)$$

ρ无缺失值样本所占比例

$\tilde{p}_k$无缺失值样本中第k类所占比例

$\tilde{r}_v$无缺失值样本中在属性a上取值a^v的样本所占比例

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

以色泽为例：

$$\tilde{D} = \{2, 3, 4, 6, 7, 8, 9, 10, 11, 12, 14, 15, 16, 17\}$$

$$\tilde{D}^{乌黑} = \{2,3,7,8,9,15\},\quad \tilde{D}_{好瓜} = \{2, 3, 4, 6, 7, 8\}$$

学习开始个样本权重初始化为1

$$\rho = \frac{\sum_{x\in\tilde{D}} w_x}{\sum_{x\in D} w_x} = \frac{14}{17},$$

$$\tilde{p}_{k=1} = \frac{\sum_{x\in\tilde{D}_k} w_x}{\sum_{x\in\tilde{D}} w_x} = \frac{6}{14}$$

$$(1 \le k \le |y|)$$

$$\tilde{r}_{v=乌黑} = \frac{\sum_{x\in\tilde{D}^v} w_x}{\sum_{x\in\tilde{D}} w_x} = \frac{6}{14}$$

$$(1 \le v \le V)$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

- 信息增益可推广为：

$$Gain(D,a) = \rho \times Gain(\tilde{D},a)$$

$$= \rho \times (\mathrm{Ent}(\tilde{D}) - \sum_{v=1}^{V} \tilde{r}_v \, Ent(\tilde{D}^v))$$

$$Ent(\tilde{D}) = -\sum_{k=1}^{|y|} \tilde{p}_k \log_2 \tilde{p}_k$$

ρ无缺失值样本所占比例

$\tilde{p}_k$无缺失值样本中第k类所占比例

$\tilde{r}_v$无缺失值样本中在属性a上取值a^v的样本所占比例

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

② 给定划分属性，若样本在该属性上值缺失，如何对样本划分？

1. 若样本x在划分属性a上的取值已知，则将x划入与其取值对应的子结点，且样本权值在子结点中保持为w_x

2. 若取值未知，则将x同时划入所有子结点，且样本权值在与属性值a^v对应子结点中调整为$\tilde{r}_v \cdot w_x$

- 直观地看，就是让同一个样本以不同的概率划入到不同的子结点中去。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

学习开始，根结点包含全部17个样例，权重均为 1

以属性“色泽”为例，无缺失值样本子集$\tilde{D}$ 包含14个样例

$$Ent(\tilde{D}) = -\sum_{k=1}^{2} \tilde{p}_k \log_2 \tilde{p}_k = -\left(\frac{6}{14}\log_2\frac{6}{14} + \frac{8}{14}\log_2\frac{8}{14}\right) = 0.985$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

- 令$\tilde{D}^1, \tilde{D}^2, \tilde{D}^3$分别表示在属性“色泽”上取值为“青绿”“乌黑”“浅白”的样本子集：

$$Ent(\tilde{D}^1) = -\left(\frac{2}{4}\log_2\frac{2}{4} + \frac{2}{4}\log_2\frac{2}{4}\right) = 1.000,$$

$$Ent(\tilde{D}^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918,$$

$$Ent(\tilde{D}^3) = -\left(\frac{0}{4}\log_2\frac{0}{4} + \frac{4}{4}\log_2\frac{4}{4}\right) = 0$$

- 样本子集$\tilde{D}$上属性“色泽”的信息增益为：

$$Gain(\tilde{D}, 色泽) = Ent(\tilde{D}) - \sum_{v=1}^{3} \tilde{r}_v \, Ent(\tilde{D}^v)$$

$$= 0.985 - \left(\frac{4}{14} \times 1 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0\right) = 0.306$$

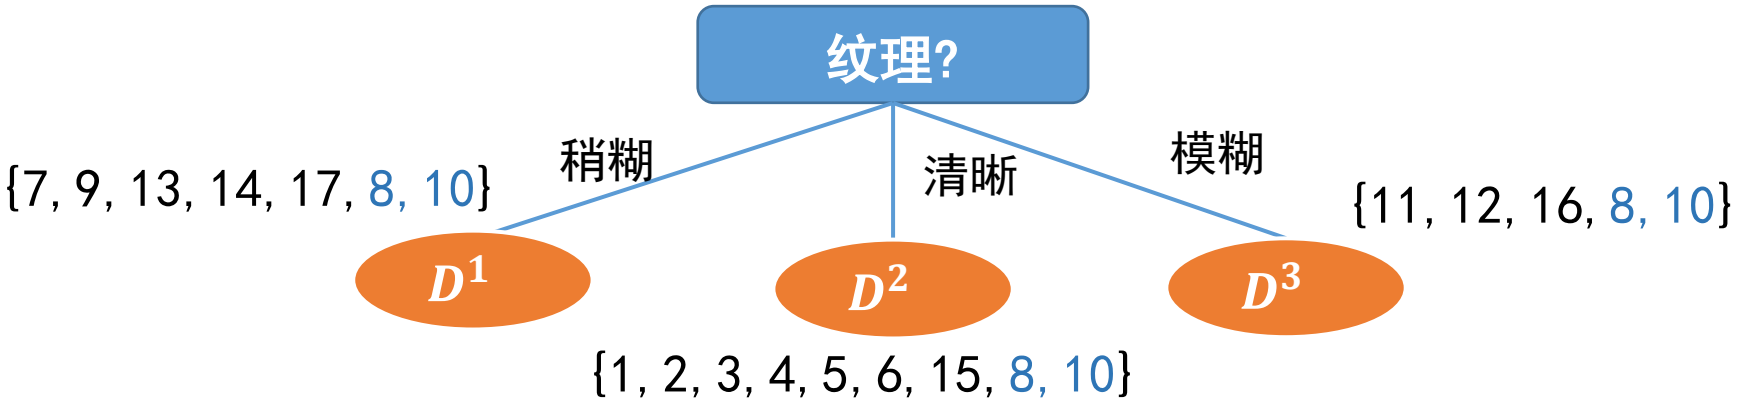
- 样本集D上属性“色泽”的信息增益：$Gain(D, 色泽) = \rho \times Gain(\tilde{D}, 色泽) = \frac{14}{17} \times 0.306 = 0.252$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

缺失值

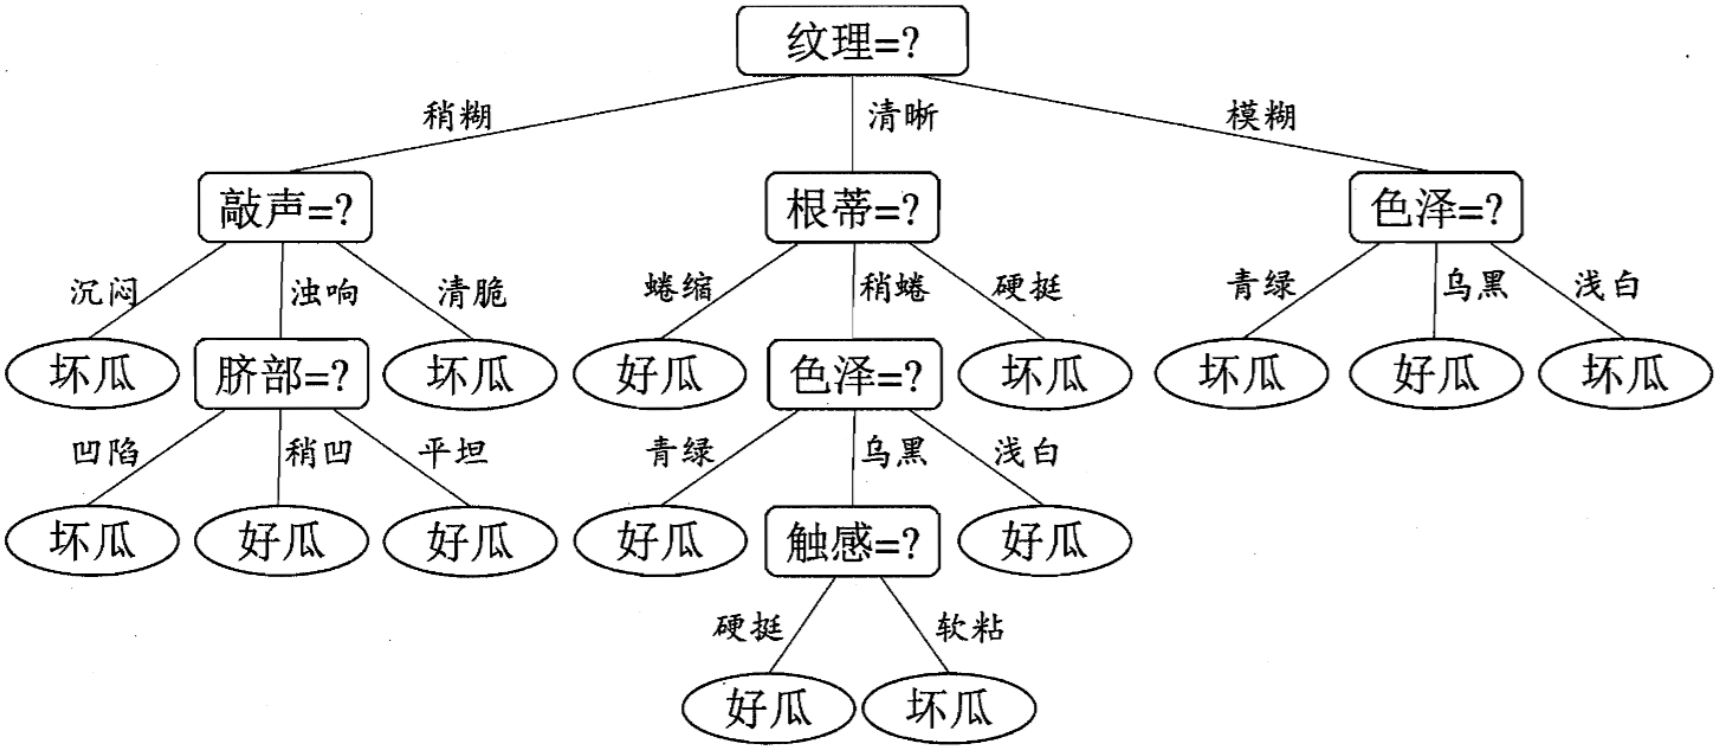
同理，可计算出所有属性在D上的信息增益：

$$Gain(D, 色泽) = 0.252; Gain(D, 根蒂) = 0.171;$$
$$Gain(D, 敲声) = 0.145; Gain(D, 纹理) = 0.424;$$
$$Gain(D, 脐部) = 0.289; Gain(D, 触感) = 0.006$$



- 编号为8、10的样本在“纹理”上具有缺失值，因此它将同时进入三个分支中，且权重分别调整为5/15、7/15、3/15。
- 其余样本权重保持为1。

缺失值



西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.4.5 多变量决策树

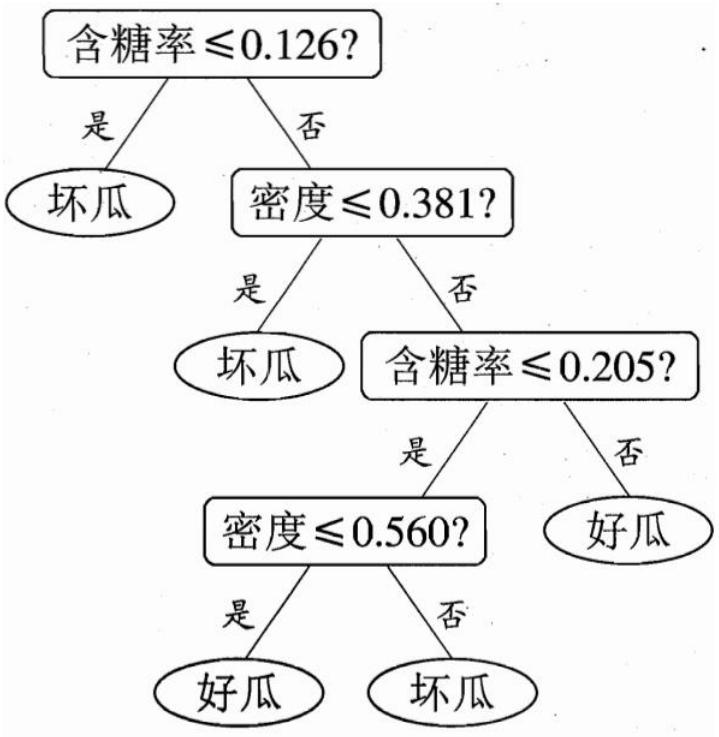
- 若把每个属性视为坐标空间中的一个坐标轴，则d个属性描述的样本就对应了d维空间中的一个数据点，对样本分类则意味着在这个坐标空间中寻找不同类样本之间的分类边界。
- 决策树所形成的分类边界有一个明显的特点：轴平行(axis-parallel)，即它的分类边界由若干个与坐标轴平行的分段组成。

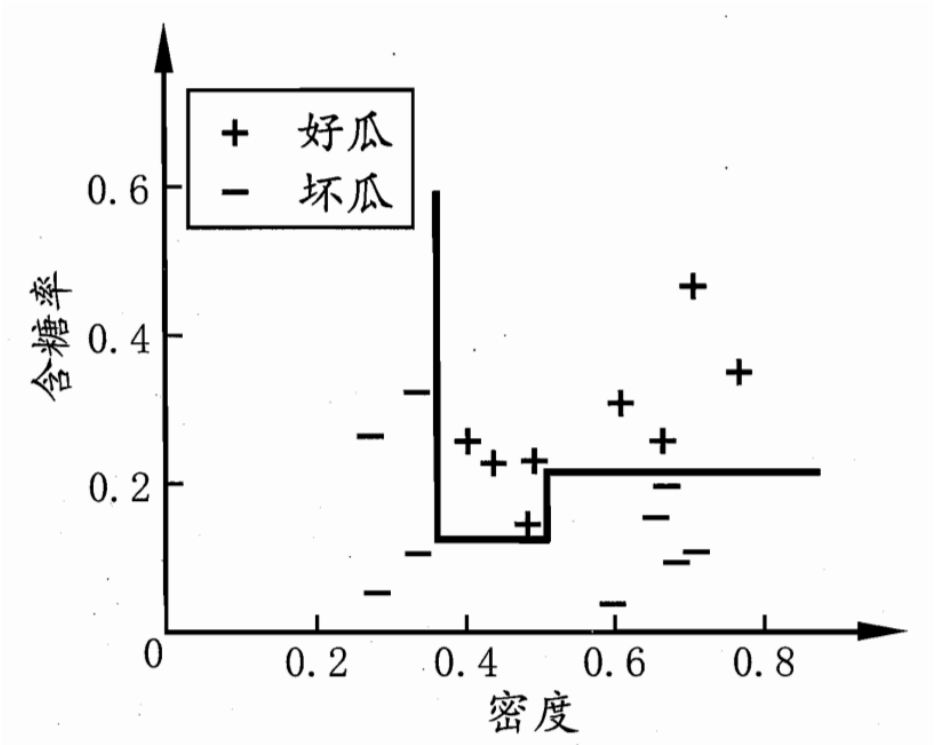
西安交通大学 XI'AN JIAOTONG UNIVERSITY

多变量决策树

单变量决策树：在每个非叶结点仅考虑一个划分属性

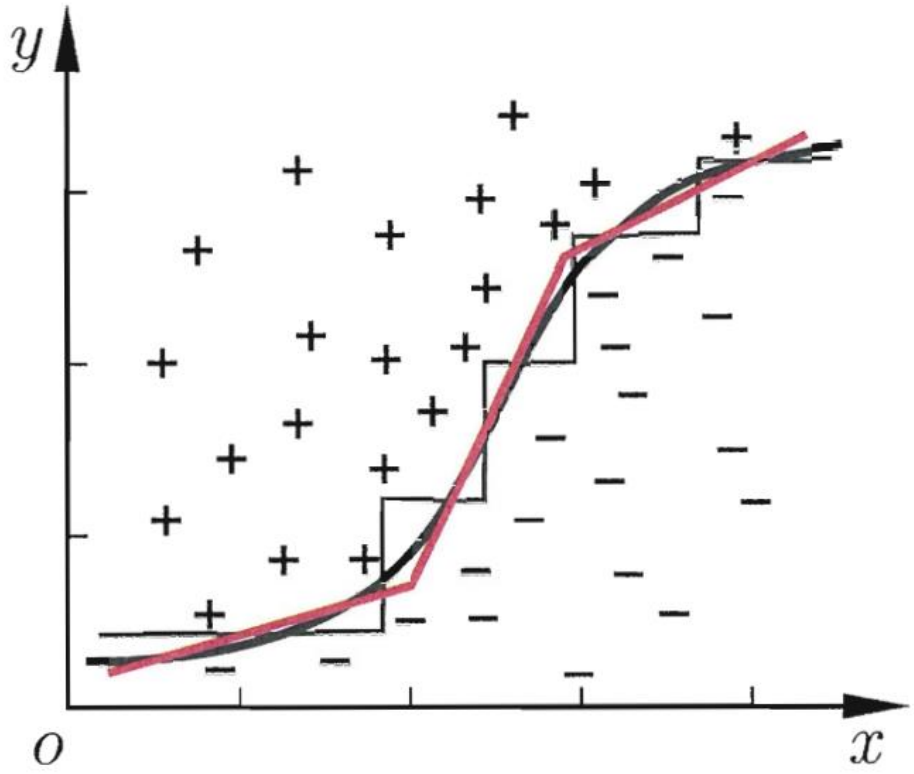
产生“轴平行”分类面，可解释性好





多变量决策树

当学习任务的真实分类边界比较复杂时，需要使用很多段划分才能获得较好的近似。



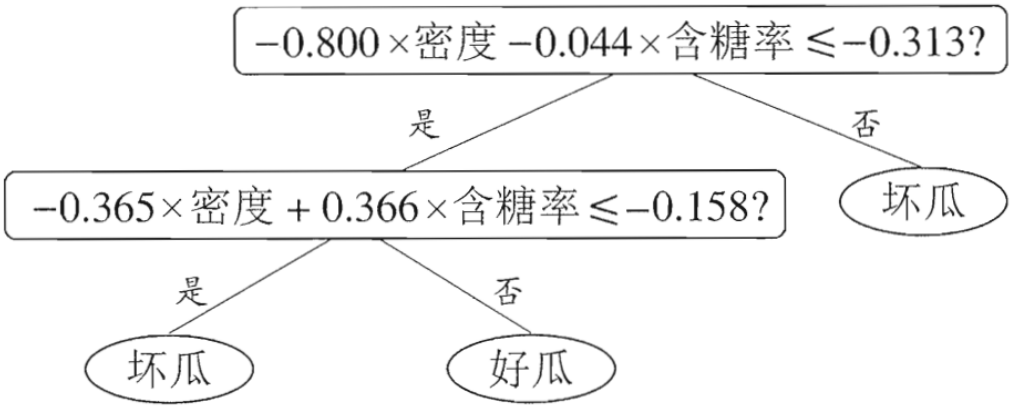
此时决策树非常复杂，预测时间开销很大。

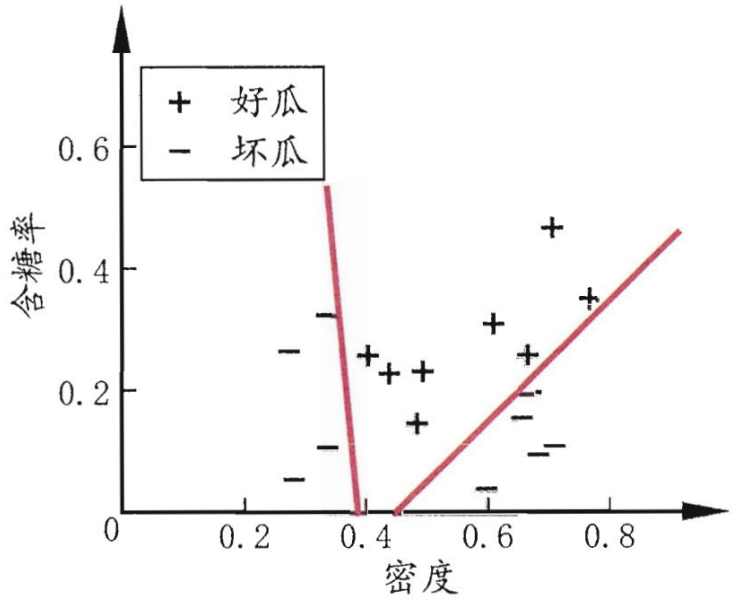
若能适应斜的划分边界，如红色线段所示，模型将大为简化。

多变量决策树

多变量决策树：在每个非叶结点不仅考虑一个属性。

“斜决策树”：不是为每个非叶结点寻找最优划分属性，而是建立一个线性分类器





完