

西安交通大学
XI'AN JIAOTONG UNIVERSITY

人工智能
Artificial Intelligence

- 主讲：刘欢
- 西安交通大学计算机学院
- E-mail：huanliu@xjtu.edu.cn

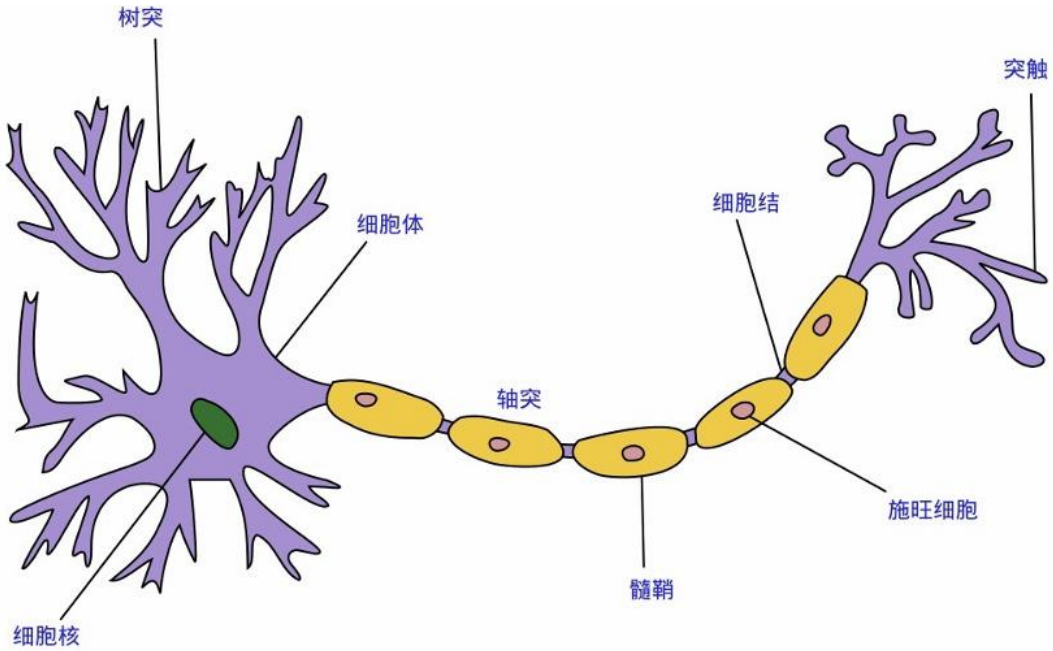
第7章　神经网络

- 7.1 神经网络基础
  - 7.1.1 神经网络概念
  - 7.1.2 多层感知器
  - 7.1.3 前向传播
- 7.2 神经网络训练
  - 7.2.1 BP 算法
  - 7.2.2 训练问题

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.1.1 从生物神经元到神经网络

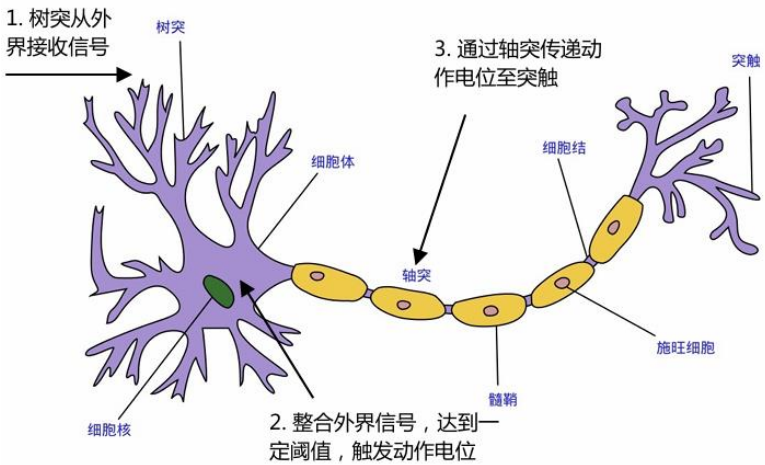
- 人类大脑是人体最复杂的器官，由神经元、神经胶质细胞、神经干细胞和血管组成。神经元也叫神经细胞，是携带和传输信息的细胞，是人脑神经系统中最基本的单元。人脑神经系统包含近860亿个神经元，每个神经元有上千个突触和其它神经元相连接。



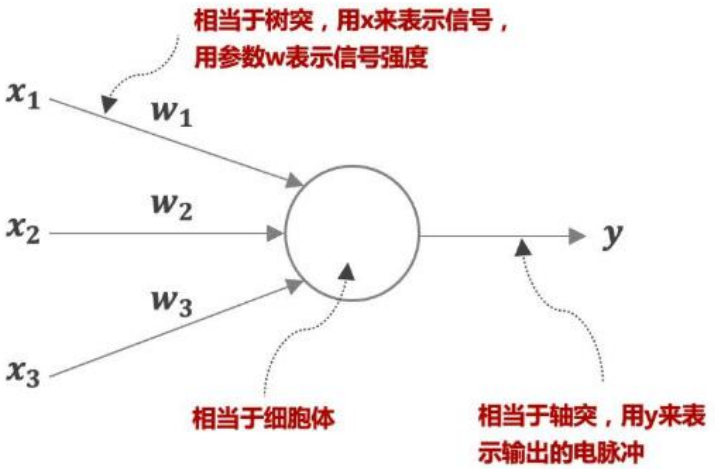
生物神经元结构

7.1.1 从生物神经元到神经网络

- 人工神经元是一种计算模型，是对生物神经元的抽象和模拟，它包括输入、处理和输出三个部分。通过接收来自外部的多个带有不同权重的输入数据，经过激活函数的处理后对外输出结果。

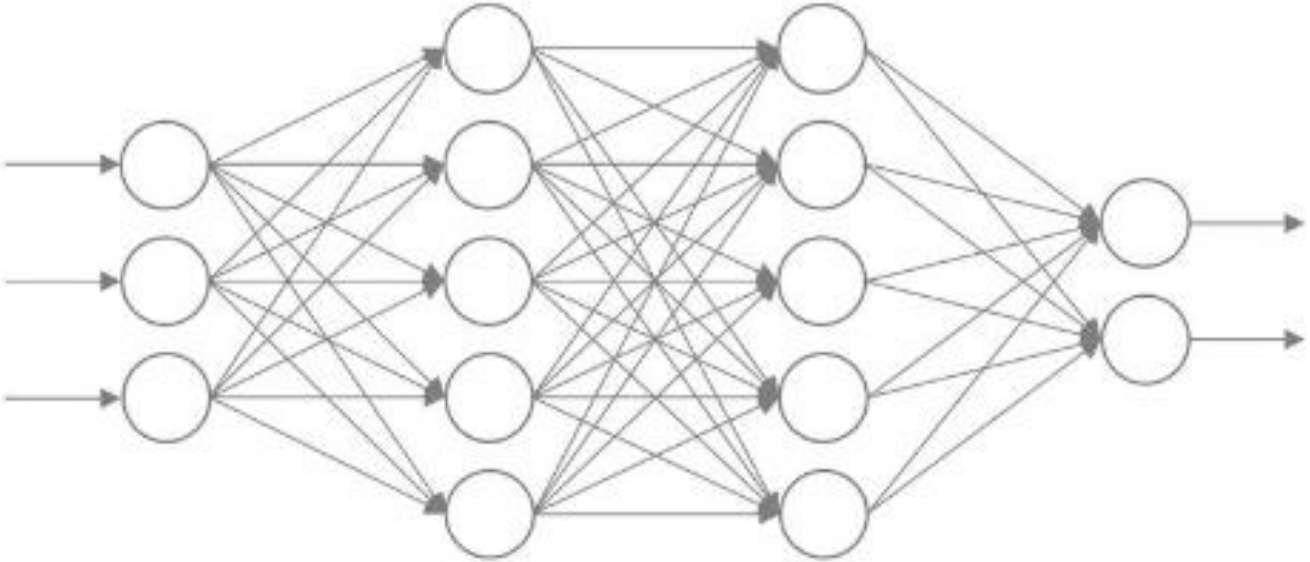


模拟



7.1.1 从生物神经元到神经网络

- 数量众多的人工神经元之间相互连接，形成一种网络结构模型，这种模型我们称之为人工神经网络（简称为神经网络）。



西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.1.1 神经网络定义

- 在广义上，神经网络可以泛指生物神经网络也可以指人工神经网络。
- 所谓人工神经网络（Artificial Neural Network）是指模拟人脑神经系统的结构和功能，运用大量的处理部件，由人工方式建立起来的网络系统。
- 人脑是ANN的原型，ANN是对人脑神经系统的模拟。在人工智能领域中，在不引起混淆的情况下，神经网络一般都指的是ANN。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.1 人工神经网络的特点

- 具有大规模并行协同处理能力。
  - 每一个神经元的功能和结构都很简单，但是由大量神经元构成的整体却具有很强的处理能力。
- 具有较强的容错能力。
  - 信息的分布式存储提供容错功能。
- 具有较强的学习能力。
  - 由于其运算的不精确性，表现成“去噪音、容残缺”的能力，比较自然地实现模式的自动分类。具有很强的普化与抽象能力。
- 是大规模自组织、自适应的非线性动力系统。
  - 具有一般非线性动力系统的共性，即不可预测性、耗散性、高维性、不可逆性、广泛连接性和自适应性等。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

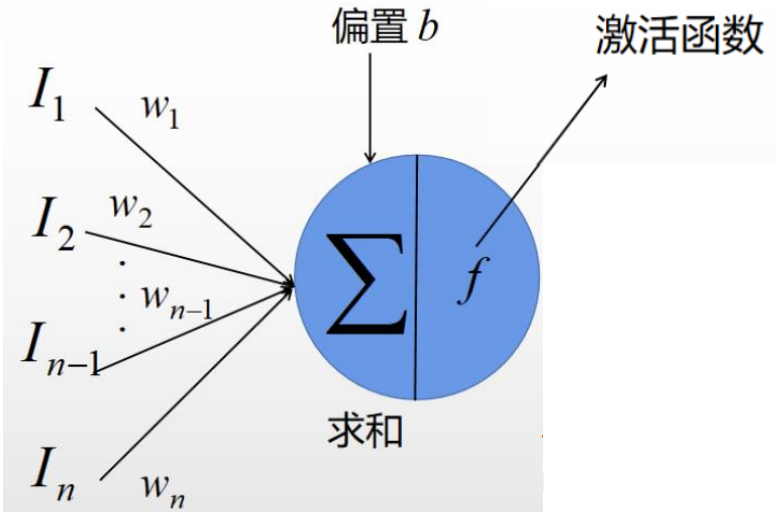
7.1.1 物理符号系统和人工神经网络系统差别

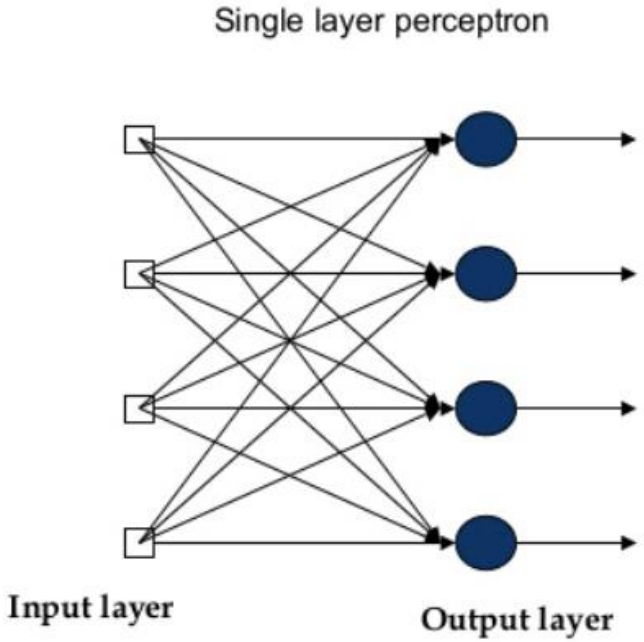
	物理符号系统	人工神经网络
处理方式	逻辑运算	模拟运算
执行方式	串行	并行
存储方式	局部集中	全局分布
处理数据	离散为主	连续为主
自适应性	由人根据已知环境构造模型，依赖于人为适应	自动从样本中抽取内涵，自动适应应用环境
应用领域	精确计算：符号处理、数值计算	非精确计算：模拟处理、感觉、大规模数据并行处理
模拟对象	左脑（逻辑思维）	右脑（形象思维）

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.2 多层感知器

MP模型是现代神经网络的一个神经元，如下图左。



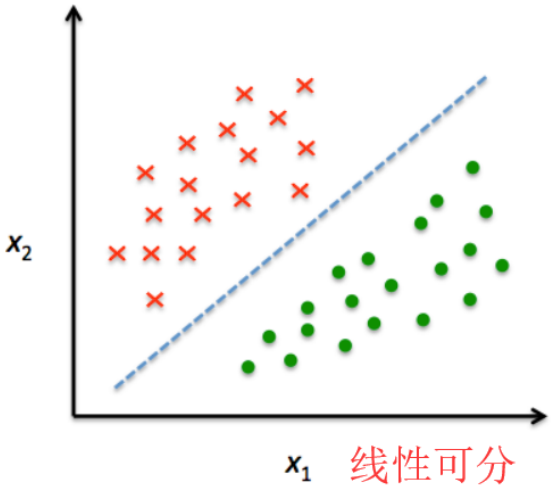


单层感知器就是多个M-P模型的堆叠，其引入学习的概念，即通过梯度下降法对损失函数极小化

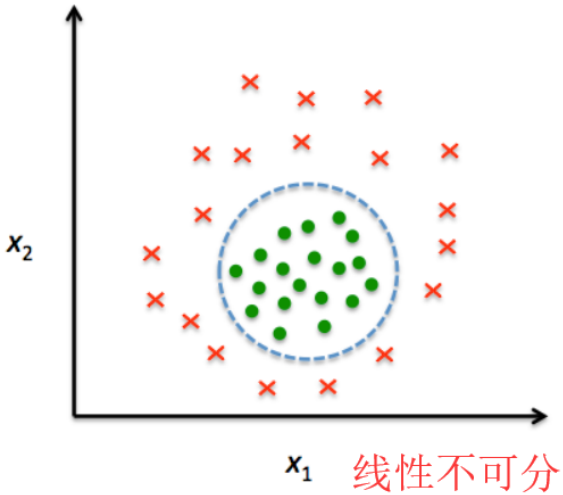
7.1.2 多层感知器

单层感知器的致命缺陷：不能解决线性不可分问题。

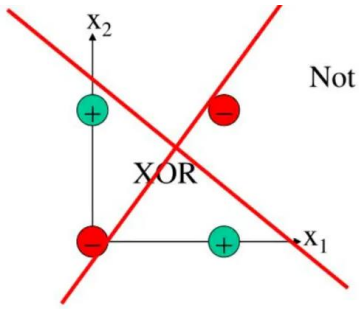
线性不可分问题就是无法用一个平面（直线）把超空间（二维平面）中的点正确划分为两部分的问题。



线性可分



线性不可分



Not linearly separable

Minsky & Papert (1969)

7.1.2 多层感知器

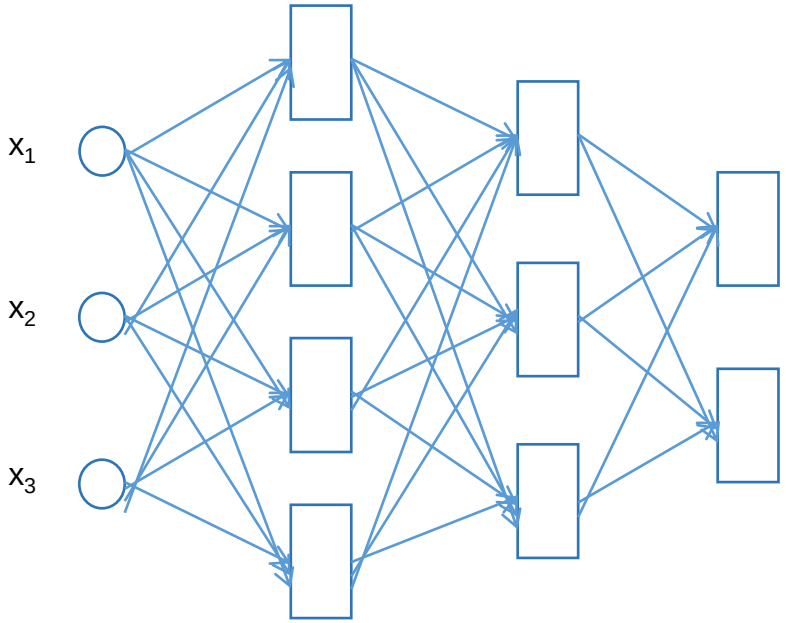
在输入和输出层间加上一层或多层的神经元（隐层神经元），就可构成多层前向网络，这里称为多层感知器。

网络结构	决策区域类型	区域形状
无隐层（单层感知器）	有一个超平面把数据空间划分成两部分	
单隐层	可在数据空间中划分出开凸区域或闭凸区域	
双隐层	可在数据空间中划分出任意形状（复杂度由隐层单元数目决定）	

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.1.2 多层感知器

- 多层感知器只允许调节一层的连接权。这是因为按感知器的概念，无法给出一个有效的多层感知器学习算法。

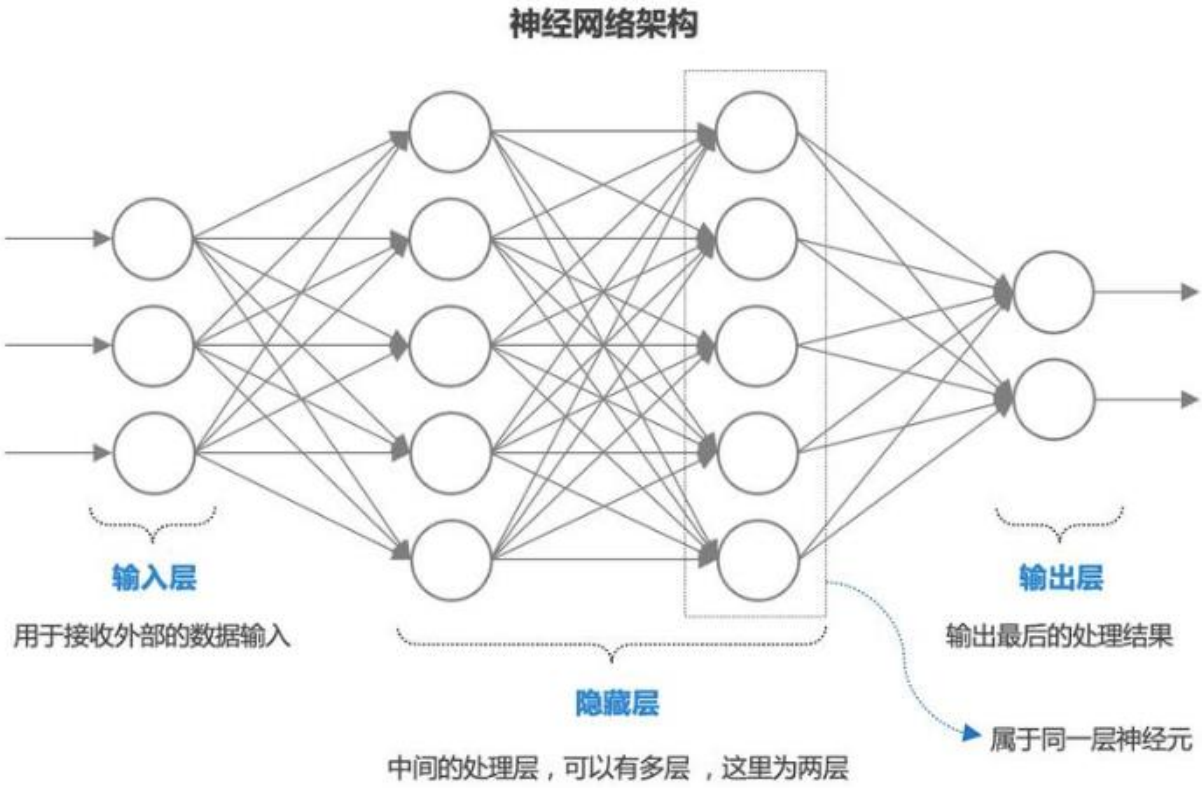


- 左侧三层感知器中，有两层连接权，输入层与隐层单元间的权值是随机设置的固定值，不被调节；输出层与隐层间的连接权是可调节的。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.2 前馈神经网络

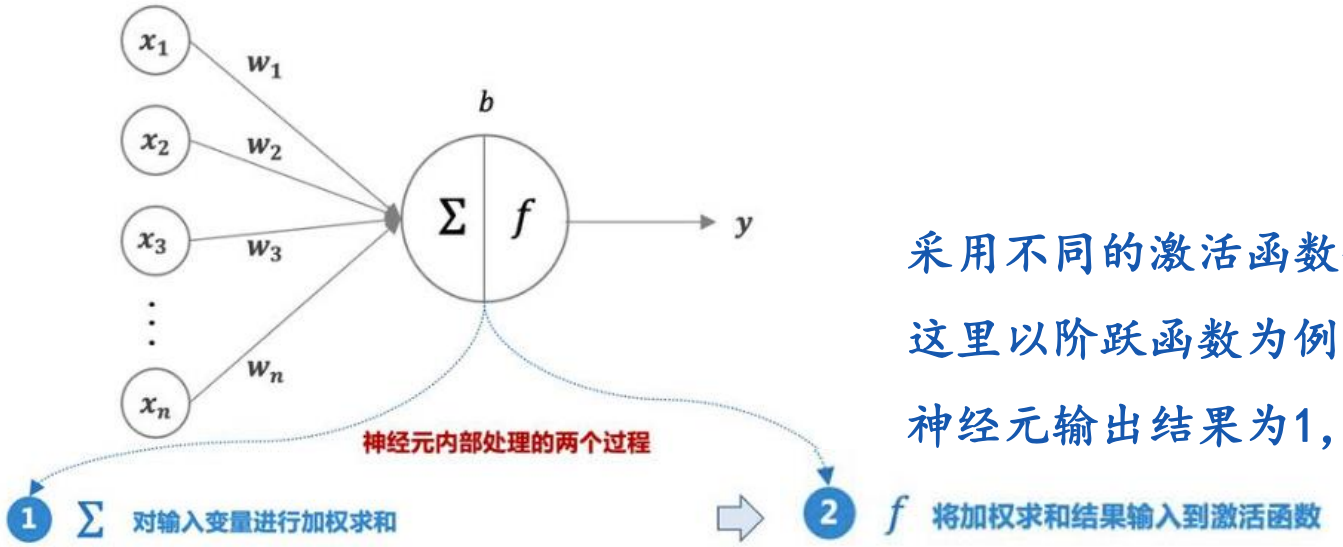
- 神经网络的外部整体结构：神经网络由输入层、隐藏层和输出层三部分组成。这种数据总是前向传播，不反向回馈的神经网络叫做前馈神经网络。
- 多层感知器便是前馈神经网络的一种。



西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.1.2 前馈神经网络

- 单个神经元内部结构：它接收来自外部的若干个变量值，为每个变量值赋予不同的权重，对变量进行加权求和，并经过内部激活函数的处理，最终输出激活函数的处理结果。



采用不同的激活函数会产生不同的结果，这里以阶跃函数为例，当x*w+b>=0时，神经元输出结果为1，否则为0

$$z = x_1 * w_1 + x_2 * w_2 + x_3 * w_3 + \ldots + x_n * w_n + b$$

$$= \sum_{i=1}^{n} x_i w_i + b$$

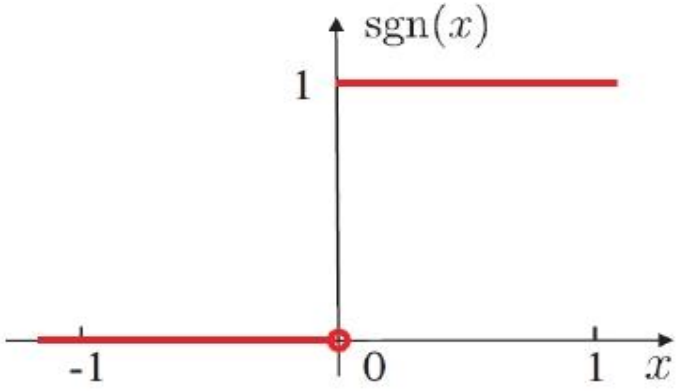
$$= x * w + b$$

$$y = f(z) = f(x * w + b)$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

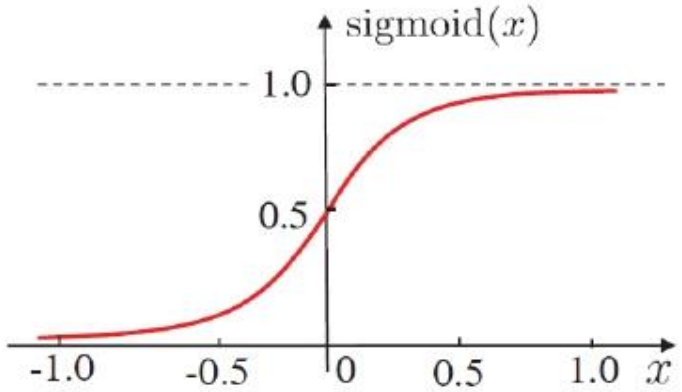
7.1.2 前馈神经网络

- 激活函数（Activation Function），就是在人工神经网络的神经元上运行的函数，负责将神经元的输入映射到输出端，它将非线性特性引入网络中。如果不用激活函数，每一层输出都是上层输入的线性函数，无论神经网络有多少层，输出都是输入的线性组合，这种情况就是最原始的感知机。



$$\mathrm{sgn}(x) = \begin{cases} 1, & \text{if } x \geq 0; \\ 0, & \text{if } x < 0. \end{cases}$$

(a) 阶跃函数

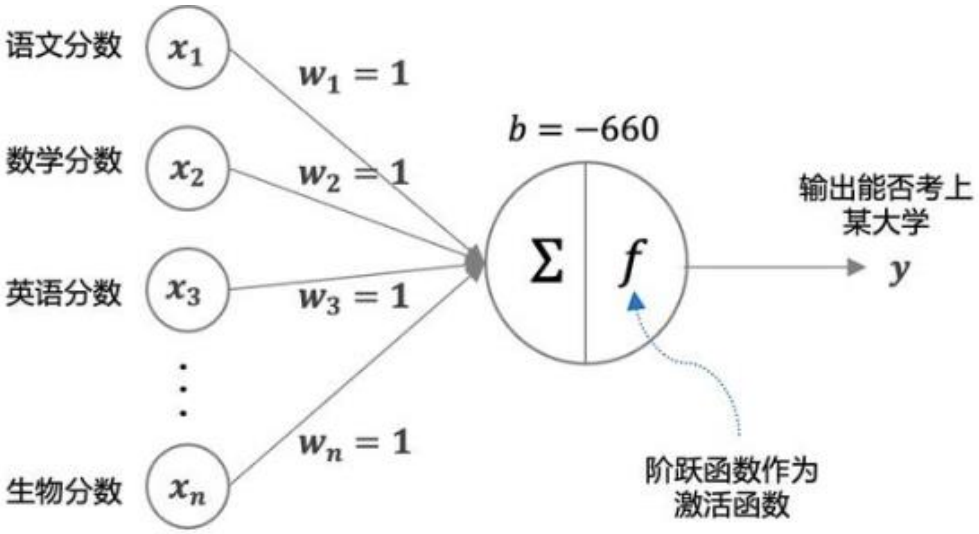


$$\mathrm{sigmoid}(x) = \frac{1}{1+e^{-x}}$$

(b) Sigmoid 函数

7.1.2 前馈神经网络

想要判断某个同学能否上某个大学的录取分数线，可以用单个神经元来进行决策，该神经元以各学科的分数作为输入变量，以该大学以往的录取分数线作为阈值，以阶跃函数作为激活函数，就可以利用该神经元来判断学生能否考上某大学了。



输入 x：这里输入变量为各个学科的分数值。

权重 w：高考总分中每一个学科的权重都相同，都为1。

偏置 b：假设根据以往数据，要考上该大学需要660分，那么偏置b设置为-660。

激活函数 f：采用阶跃函数作为激活函数，当6个学科的总分大于660分时，加权输入大于等于0，那么阶跃函数输出为1，否则为0。

输出 y：根据激活函数的输出结果，1代表能够考上该大学，0代表不能考上该大学。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.2 前馈神经网络

万能逼近定理（Universal Approximation Theorem）：

假设 $\mathrm{f}: R^n \to R$ 是一个连续函数，且 $\varepsilon > 0$ 是一个任意小的正数，那么存在一个具有有限个神经元的前馈神经网络 g(x)，使得对于所有的输入x，都有：$|\mathrm{f}(x) - g(x)| < \varepsilon$

- 该定理指出，只要有足够的神经元，一个包含至少一层隐藏层的前馈神经网络就能够逼近任意复杂的连续函数。
- 该定理为神经网络的广泛应用提供了理论支持，证明了神经网络在分类、回归、生成等多种任务中具有强大的表现能力。尽管如此，万能逼近定理也引发了对模型可解释性不足的担忧，理解神经网络内部机制变得困难，因此如何在保证性能的同时提升模型的可解释性仍是当前研究的重要课题之一。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.2 前馈神经网络

神经标度律（Neural Scaling Laws）：

如果用 N 表示网络规模（例如参数数量或训练样本量），E(N) 表示模型的误差，那么神经标度律形式上可以表达为：

$$E(N) \propto N^{-\alpha}$$

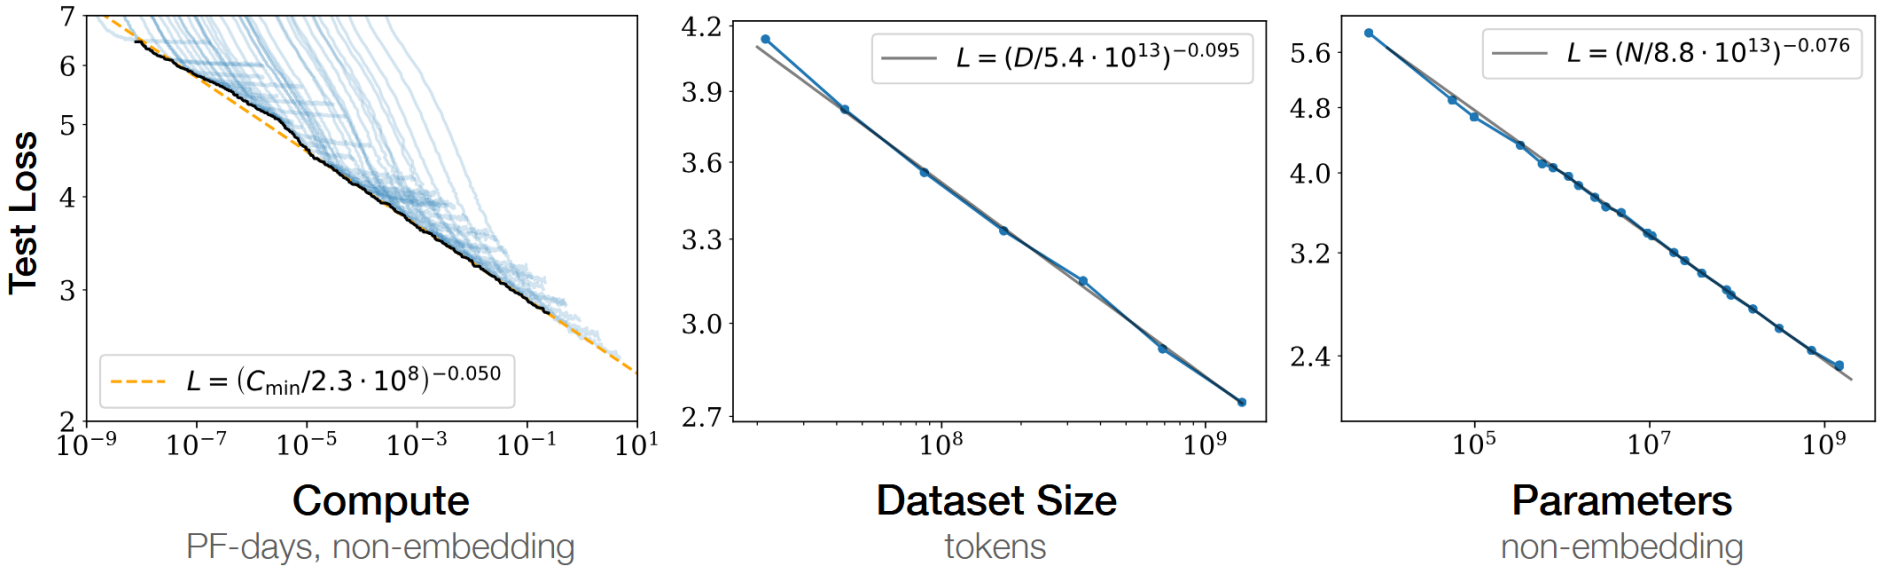
其中，α 是标度律的指数，表示误差随规模变化的速率。通常，随着 N 的增大，误差减少的速度会变慢，表现为一个幂次衰减的过程。

- 神经标度律不仅涉及参数量增大的情况，还适应于数据集的扩展。例如，大规模预训练模型在小样本任务上微调，可以显著提高最终性能，因为大模型已在海量数据中学习到了有效的特征表示。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.2 前馈神经网络

- 随着模型规模、数据集规模和训练所用计算资源的增加，语言模型性能稳步提升。为了达到最佳性能，这三个因素必须同步扩展。当不受其他两个因素的瓶颈限制时，实际性能与每个因素之间都存在幂律关系。

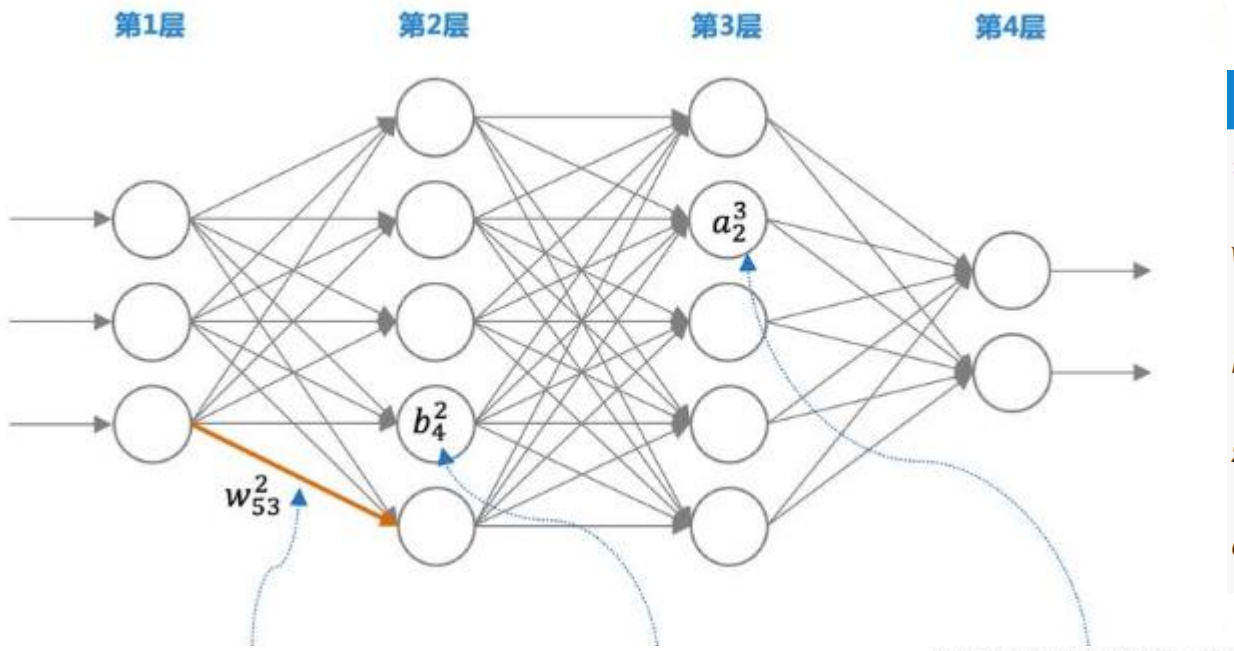


Kaplan J, McCandlish S, Henighan T, et al. Scaling laws for neural language models[J]. arXiv preprint arXiv:2001.08361, 2020.

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播

为了更为清晰地理解神经网络的整个前向计算过程，对神经网络中的权重、偏置、激活值等参数的符号表达形式进行约定，前向计算过程中将统一用使用该符号约定，同时以下面4层神经网络（每层分别包括3, 5, 5, 2个神经元）为例来说明前向计算过程。

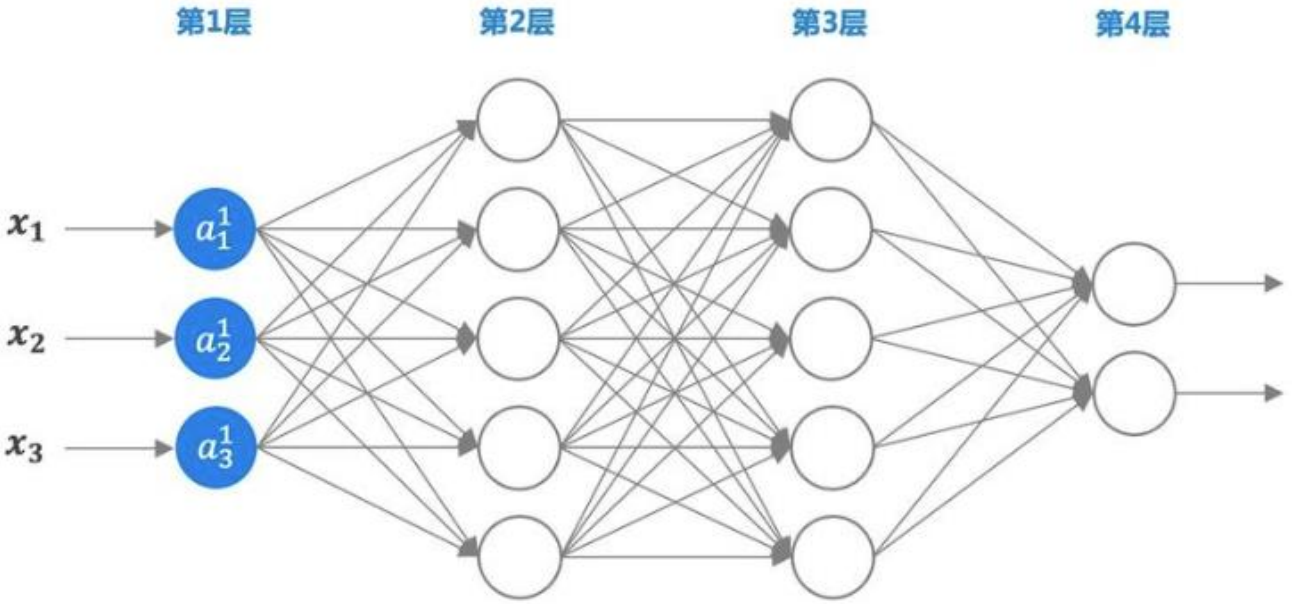


相关符号约定	
符合	含义说明
w_{jk}^l	第（$l-1$）层的第 k 个神经元到第 l 层的第 j 个神经元的连接的权重
b_j^l	第 l 层的第 j 个神经元的偏置
z_j^l	第 l 层的第 j 个神经元的带权输入（上一层的激活值与偏置的加权之和）
a_j^l	第 l 层的第 j 个神经元的激活值

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播

1. 第1层神经元计算
2.
3.
4.

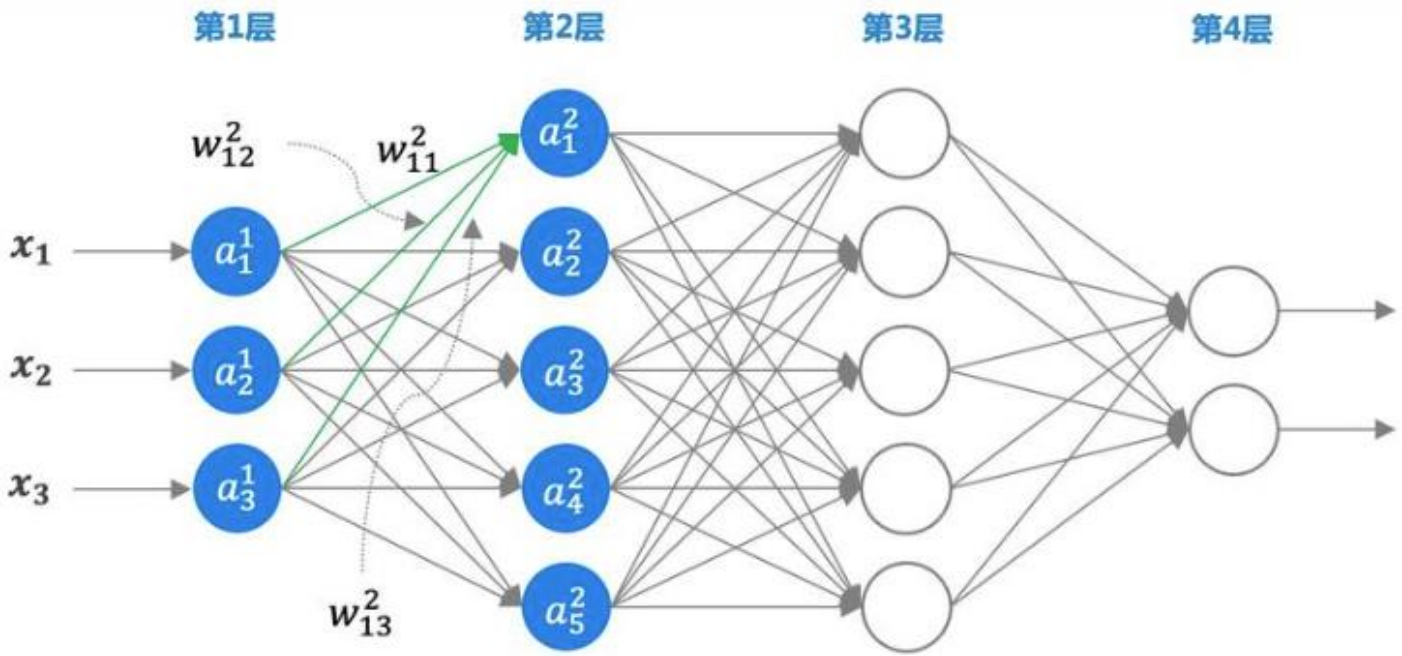


$$a_1^1 = x_1 \qquad a_2^1 = x_2 \qquad a_3^1 = x_3$$

输入层神经元与隐藏层和输出层的神经元略有不同，其输出结果就是原始的输入变量值

7.1.3 前向传播

1
2 第2层神经元计算
3
4



1. 神经元加权和

$$z_1^2 = w_{11}^2 * a_1^1 + w_{12}^2 * a_2^1 + w_{13}^2 * a_3^1 + b_1^2$$

2. 激活函数输出结果

$$a_1^2 = \sigma(z_1^2)$$

$$z_2^2 = w_{21}^2 * a_1^1 + w_{22}^2 * a_2^1 + w_{23}^2 * a_3^1 + b_2^2$$

$$a_2^2 = \sigma(z_2^2)$$

这里$\sigma()$为sigmoid激活函数

.....

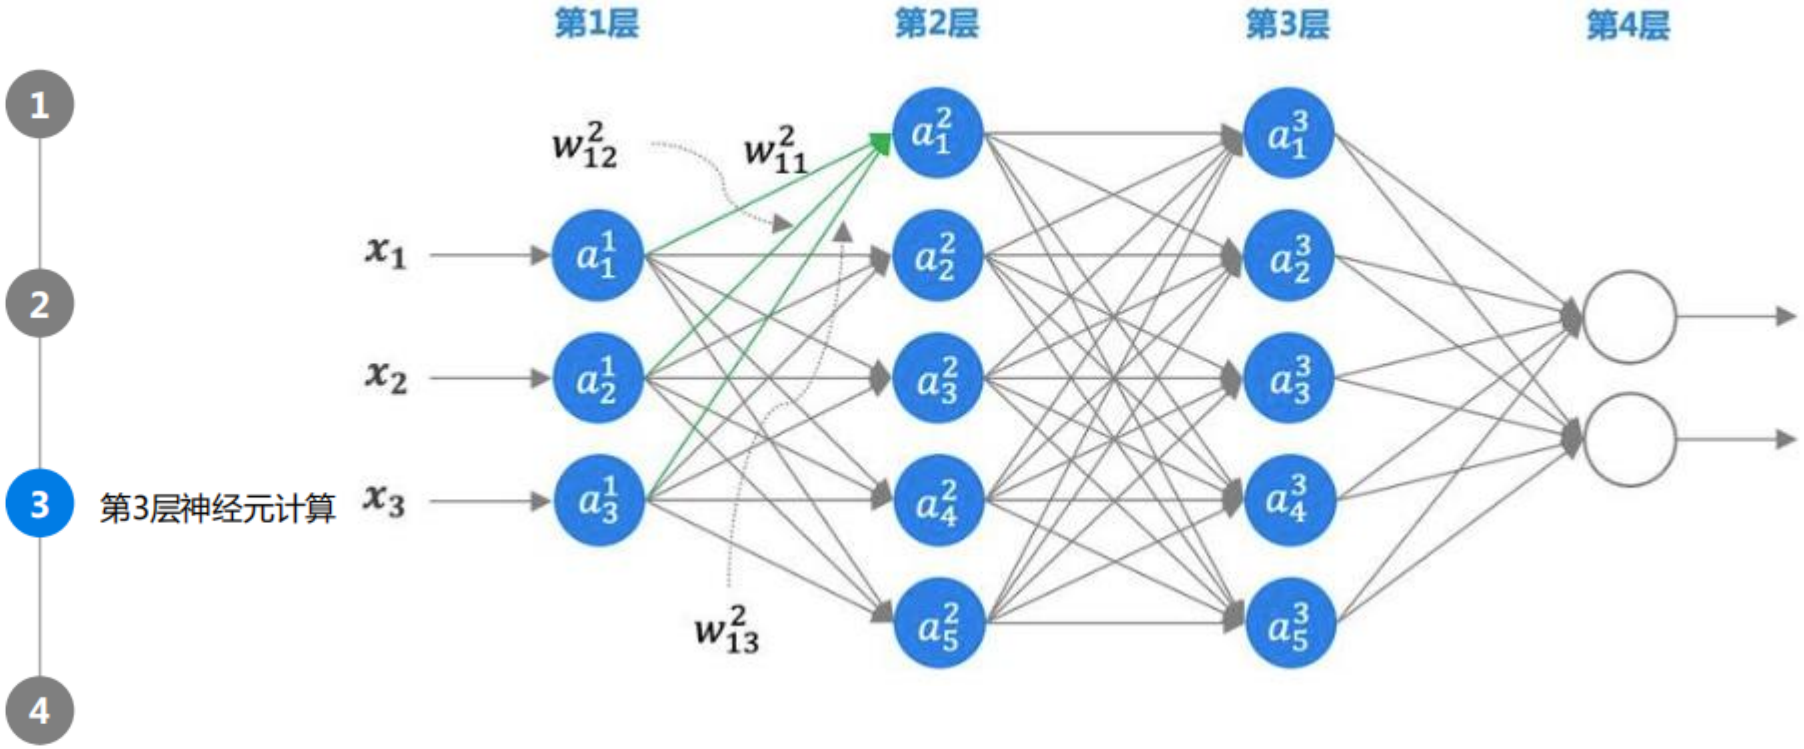
.....

$$z_j^2 = \sum_k w_{jk}^2 a_k^1 + b_j^2$$

$$a_j^2 = \sigma(z_j^2)$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播



1. 神经元加权和

$$z_1^3 = w_{11}^3 * a_1^2 + w_{12}^3 * a_2^2 + w_{13}^3 * a_3^2 + w_{14}^3 * a_4^2 + w_{15}^3 * a_5^2 + b_1^3$$

2. 激活函数输出结果

$$a_1^3 = \sigma(z_1^3)$$

$$z_2^3 = w_{21}^3 * a_1^2 + w_{22}^3 * a_2^2 + w_{23}^3 * a_3^2 + w_{24}^3 * a_4^2 + w_{25}^3 * a_5^2 + b_2^3$$

$$a_2^3 = \sigma(z_2^3)$$

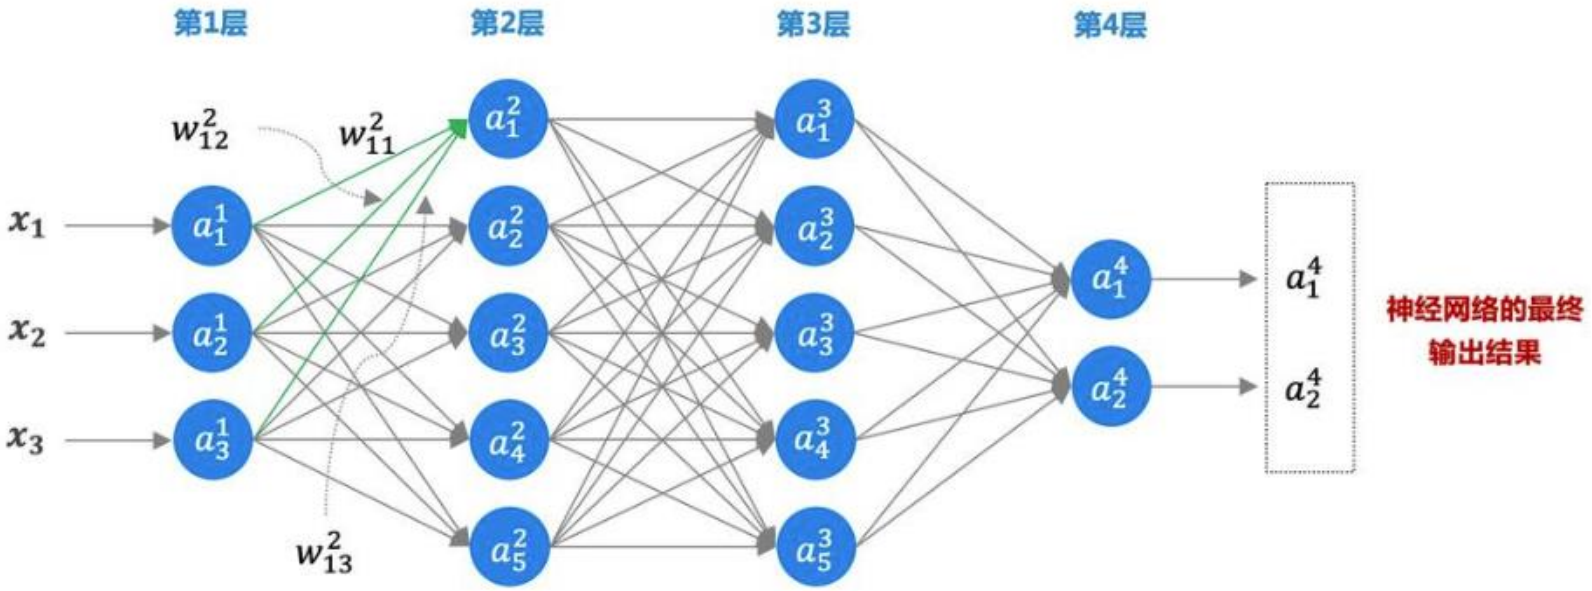
.....

.....

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播

1
2
3
4 第4层神经元计算



1. 神经元加权和

$$z_1^4 = w_{11}^4 * a_1^3 + w_{12}^4 * a_2^3 + w_{13}^4 * a_3^3 + w_{14}^4 * a_4^3 + w_{15}^4 * a_5^3 + b_1^4$$

2. 激活函数输出结果

$$a_1^4 = \sigma(z_1^4)$$

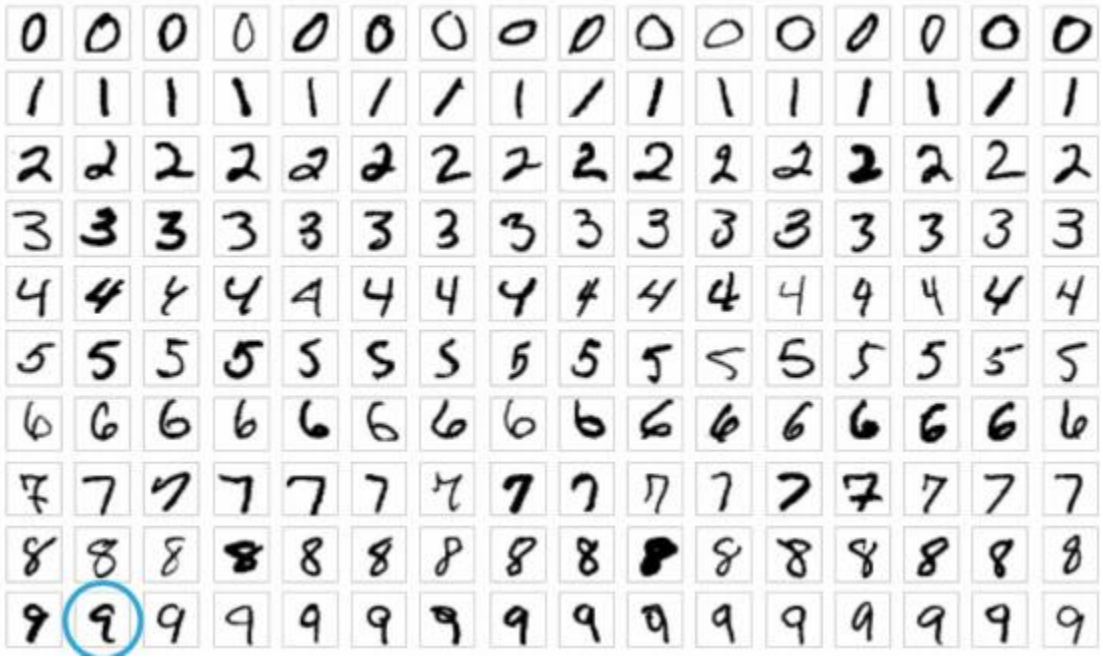
$$z_2^4 = w_{21}^4 * a_1^3 + w_{22}^4 * a_2^3 + w_{23}^4 * a_3^3 + w_{24}^4 * a_4^3 + w_{25}^4 * a_5^3 + b_2^4$$

$$a_2^4 = \sigma(z_2^4)$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

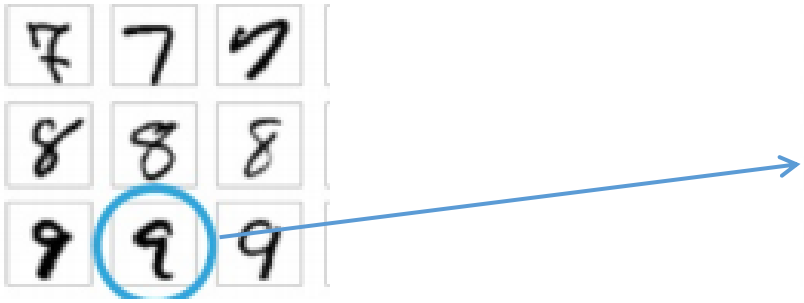
7.1.3 前向传播

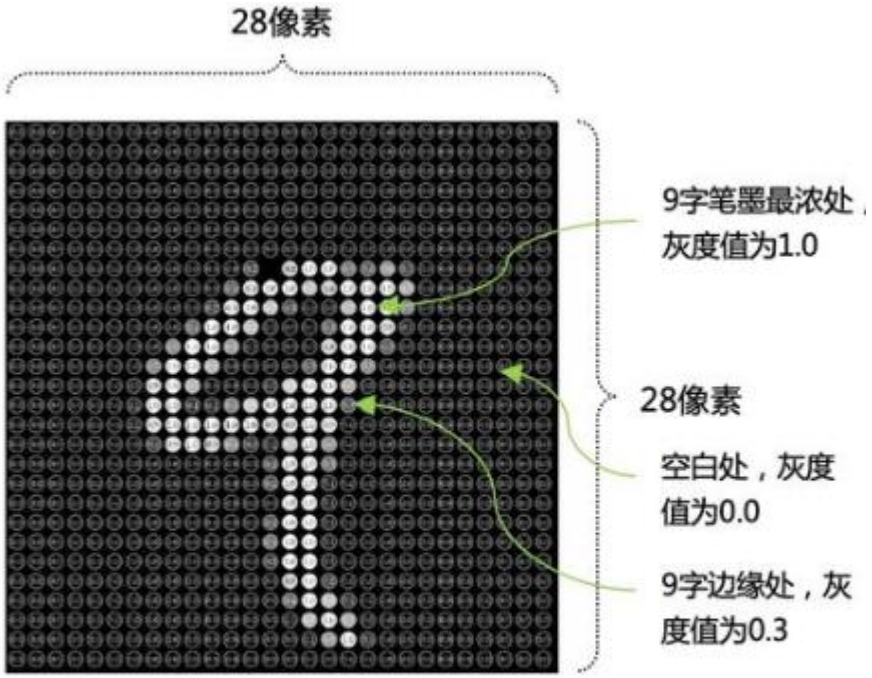
利用神经网络来自动识别手写的数字是一个典型的应用案例，在这里用到了MNIST数据集，数据集中包含了经过扫描后的数字图像，每一个数字图像由28*28像素的灰度值组成，要解决的问题是输入一个数字图像，然后通过神经网络准确识别具体的数字。



西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播

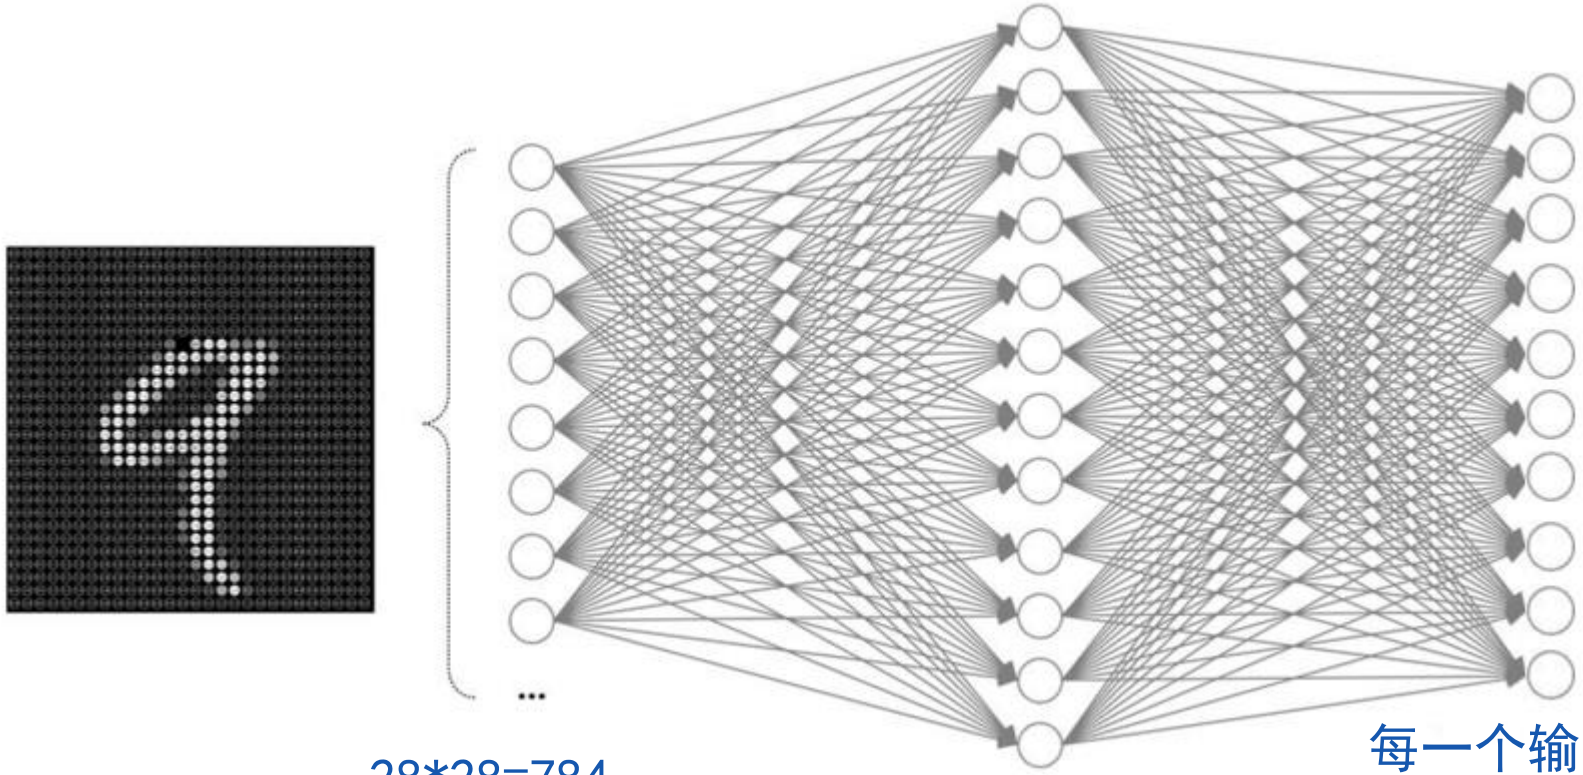




每一个像素用灰度值来表示，灰度值介于0和1之间，0代表白色，1代表黑色，中间值代表灰度。

7.1.3 前向传播

设计一个输入、隐藏和输出层的神经元个数分别为784、12、10的神经网络。在通过训练得到神经网络参数值（w，b）的前提下，可根据输入值计算得到输出神经元的激活值，从而判断对应数字。



28*28=784
个输入变量

每一个输出神经元代表某个数字

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.1.3 前向传播

在这个案例中，神经网络要能够正式用于识别手写数字，还需要经过训练学习的过程。只有经过合适的训练学习之后，才能得到合适的参数（各层神经元的权重w和偏置b参数），从而达到最佳的预测效果，在这个过程中，还面临着如下的挑战：

1. 在训练学习过程中，如何来表示模型拟合的好坏？

2. 如何找到合适的权重w和偏置b参数，使得神经网络达到最佳的预测效果？

3. 如何选择合适的损失函数？

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

神经网络的训练过程

① **准备数据集，划分为训练集和验证集；神经网络参数初始化**

② **前向传播（Forward Propagation）**

- 输入数据通过网络的每一层，每层都计算其加权输入和，加上偏置，然后应用激活函数。最终，输出层生成预测结果。
- 使用一个损失函数（如均方误差或交叉熵损失）来衡量预测结果和真实标签之间的差异。损失函数的选择取决于特定的问题。

③ **反向传播（Backpropagation）**

- 计算损失函数关于输出层的梯度。利用链式法则，从输出层开始逆向通过网络的每一层，计算损失函数关于每个权重和偏置的梯度。

④ **参数更新（Parameter Update）**

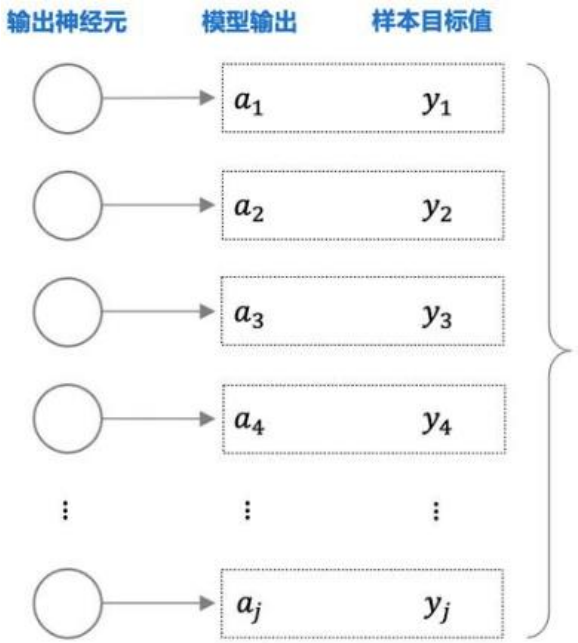
- 使用梯度下降法或其他优化算法（如Adam、RMSprop等）根据计算得到的梯度更新网络的权重和偏置：新参数=旧参数−学习率×梯度
- 计算新的参数在训练集和测试集上的分类性能

重复步骤2-4，直到训练集性能无法进一步改进；选择在验证集上性能最好的参数作为最终的神经网络

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

通过损失函数来表示模型拟合的好坏：如果模型表现较好，那么损失函数的结果值将相当小；反之结果值将变得较大。



希望每个输出神经元的结果能够完美拟合样本目标值，即有：

$$a_j \approx y_j$$

用二次损失函数来表示拟合的好坏：

对于每一个样本，拟合误差用如下损失函数表示：

$$C(w,b) = \frac{1}{2} \| y(x) - a \|^2$$

$$= \frac{1}{2} \sum_j (y_j(x) - a_j)^2$$

假设有n样本数据，则所有样本数据的损失函数表示为：

$$C(w,b) = \frac{1}{2n} \sum_x \| y(x) - a \|^2$$

7.2.1 BP 算法

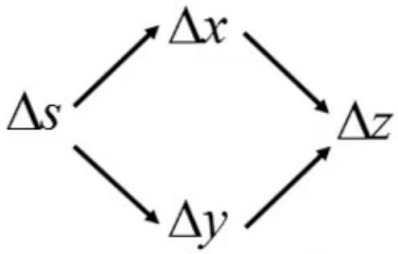
链式法则：

Case 1 $y = g(x) \quad z = h(y)$

$$\Delta x \to \Delta y \to \Delta z \qquad \frac{dz}{dx} = \frac{dz}{dy}\frac{dy}{dx}$$

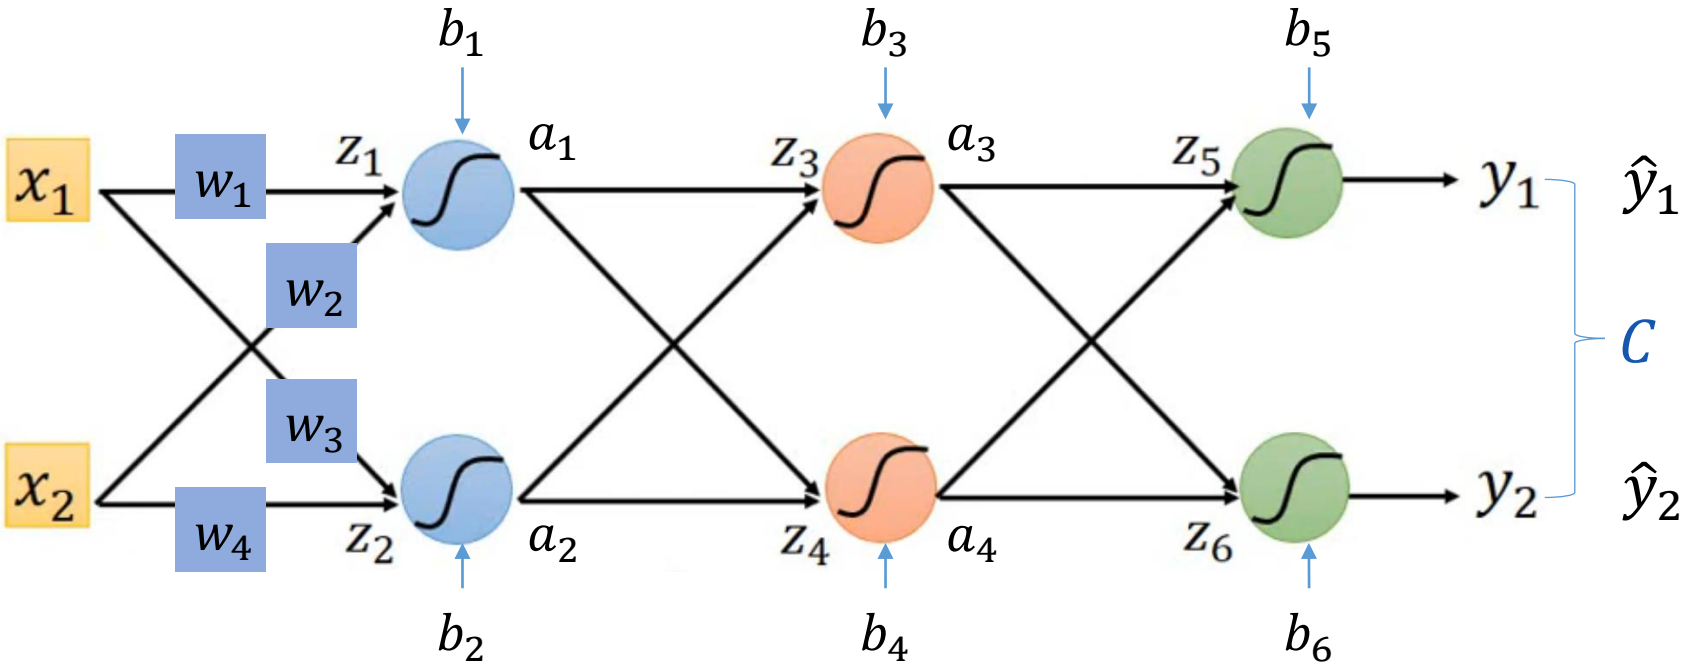
Case 2

$$x = g(s) \qquad y = h(s) \qquad z = k(x, y)$$



$$\frac{dz}{ds} = \frac{\partial z}{\partial x}\frac{dx}{ds} + \frac{\partial z}{\partial y}\frac{dy}{ds}$$

7.2.1 BP 算法



前向传播：

$$z_1 = x_1 w_1 + x_2 w_2 + b_1$$

$$a_1 = \sigma(z_1)$$

…

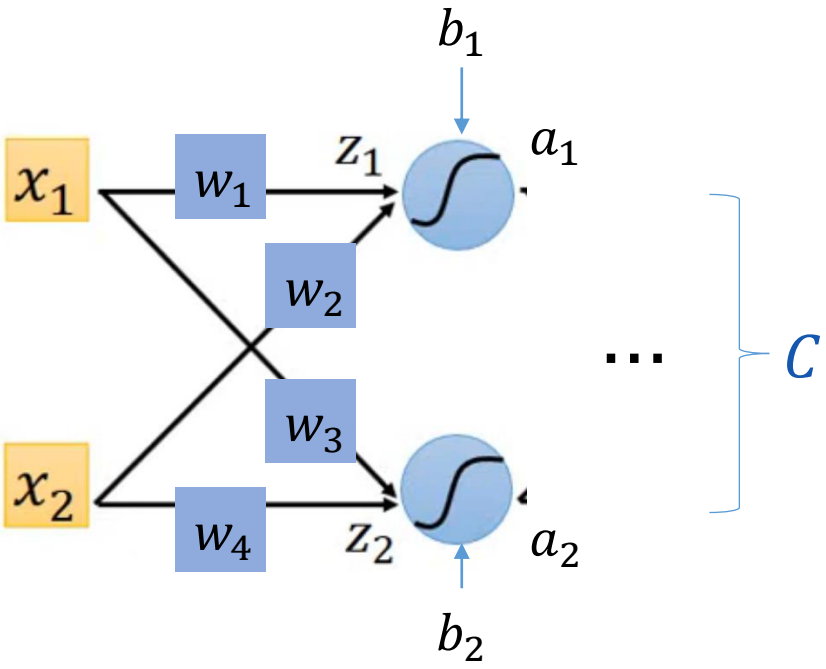
新参数=旧参数−学习率×梯度

$$\frac{\partial C}{\partial w}?$$

C：神经网络的损失函数

西安交通大学 XI'AN JIAOTONG UNIVERSITY

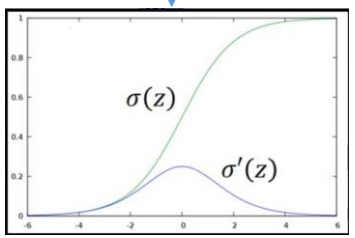
7.2.1 BP 算法



$$\frac{\partial C}{\partial w_1} = \frac{\partial C}{\partial z_1}\frac{\partial z_1}{\partial w_1}$$

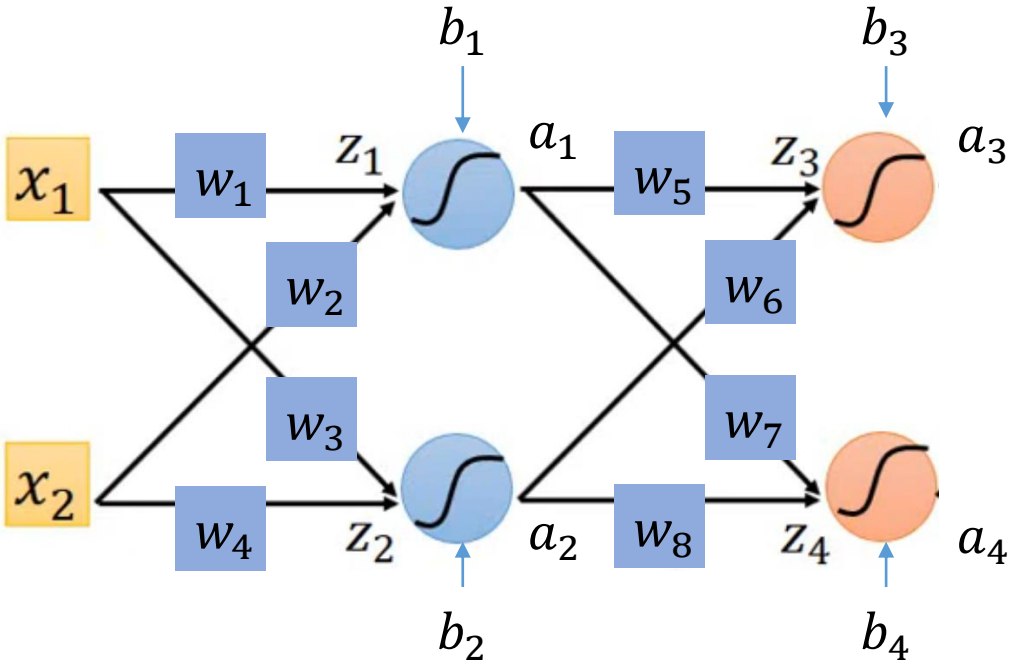
$\frac{\partial z_1}{\partial w_1} = x_1$，前向传播得到

$$\frac{\partial C}{\partial z_1} = \frac{\partial C}{\partial a_1}\frac{\partial a_1}{\partial z_1}$$



$$z_1 = x_1 w_1 + x_2 w_2 + b_1$$
$$a_1 = \sigma(z_1)$$
...

7.2.1 BP 算法

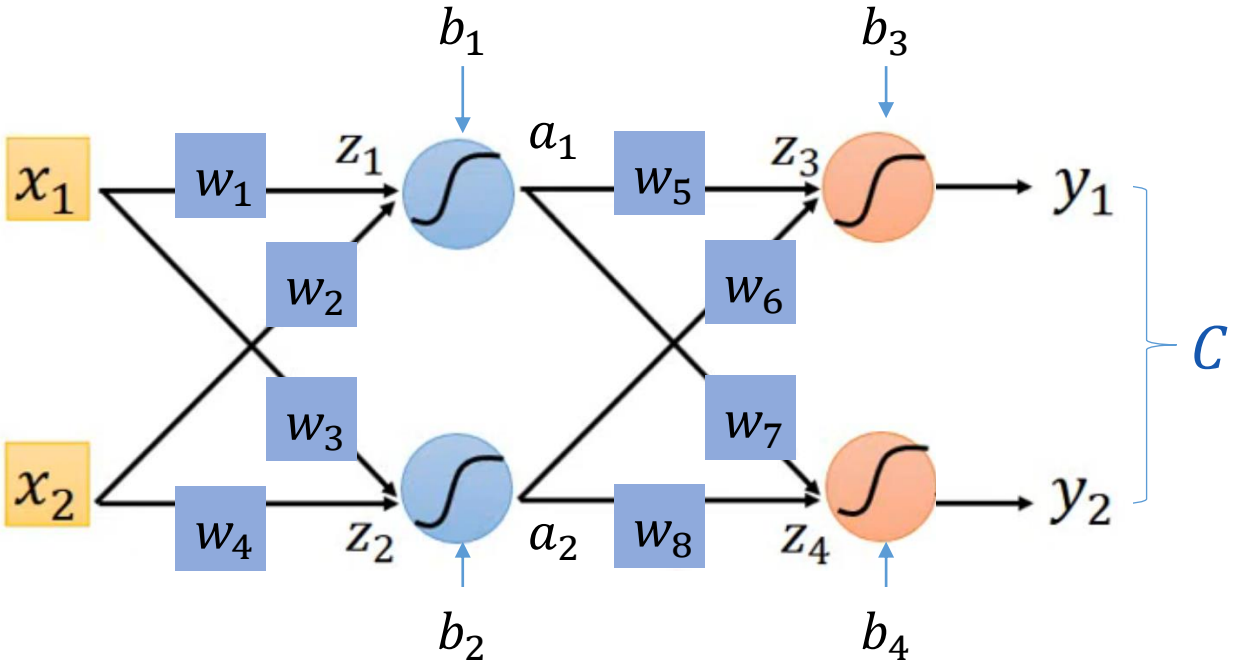


$\cdots C$

$$z_1 = x_1 w_1 + x_2 w_2 + b_1$$
$$a_1 = \sigma(z_1)$$
$$z_2 = x_1 w_3 + x_2 w_4 + b_2$$
$$a_2 = \sigma(z_2)$$
$$z_3 = a_1 w_5 + a_2 w_6 + b_3$$
$$a_3 = \sigma(z_3)$$
$$z_4 = a_1 w_7 + a_2 w_8 + b_4$$
$$a_4 = \sigma(z_4)$$
$$\cdots$$

$$\frac{\partial C}{\partial w_1} = \frac{\partial C}{\partial z_1}\frac{\partial z_1}{\partial w_1} \qquad \frac{\partial C}{\partial z_1} = \frac{\partial C}{\partial a_1}\frac{\partial a_1}{\partial z_1} \qquad \frac{\partial C}{\partial a_1} = \frac{\partial C}{\partial z_3}\frac{\partial z_3}{\partial a_1} + \frac{\partial C}{\partial z_4}\frac{\partial z_4}{\partial a_1}$$

7.2.1 BP 算法



$$z_1 = x_1 w_1 + x_2 w_2 + b_1$$
$$a_1 = \sigma(z_1)$$
$$z_2 = x_1 w_3 + x_2 w_4 + b_2$$
$$a_2 = \sigma(z_2)$$
$$z_3 = a_1 w_5 + a_2 w_6 + b_3$$
$$y_1 = \sigma(z_3)$$
$$z_4 = a_1 w_7 + a_2 w_8 + b_4$$
$$y_2 = \sigma(z_4)$$

$$\frac{\partial C}{\partial a_1} = \frac{\partial C}{\partial z_3}\frac{\partial z_3}{\partial a_1} + \frac{\partial C}{\partial z_4}\frac{\partial z_4}{\partial a_1}$$

$$\frac{\partial C}{\partial z_3} = \frac{\partial C}{\partial y_1}\frac{\partial y_1}{\partial z_3}$$

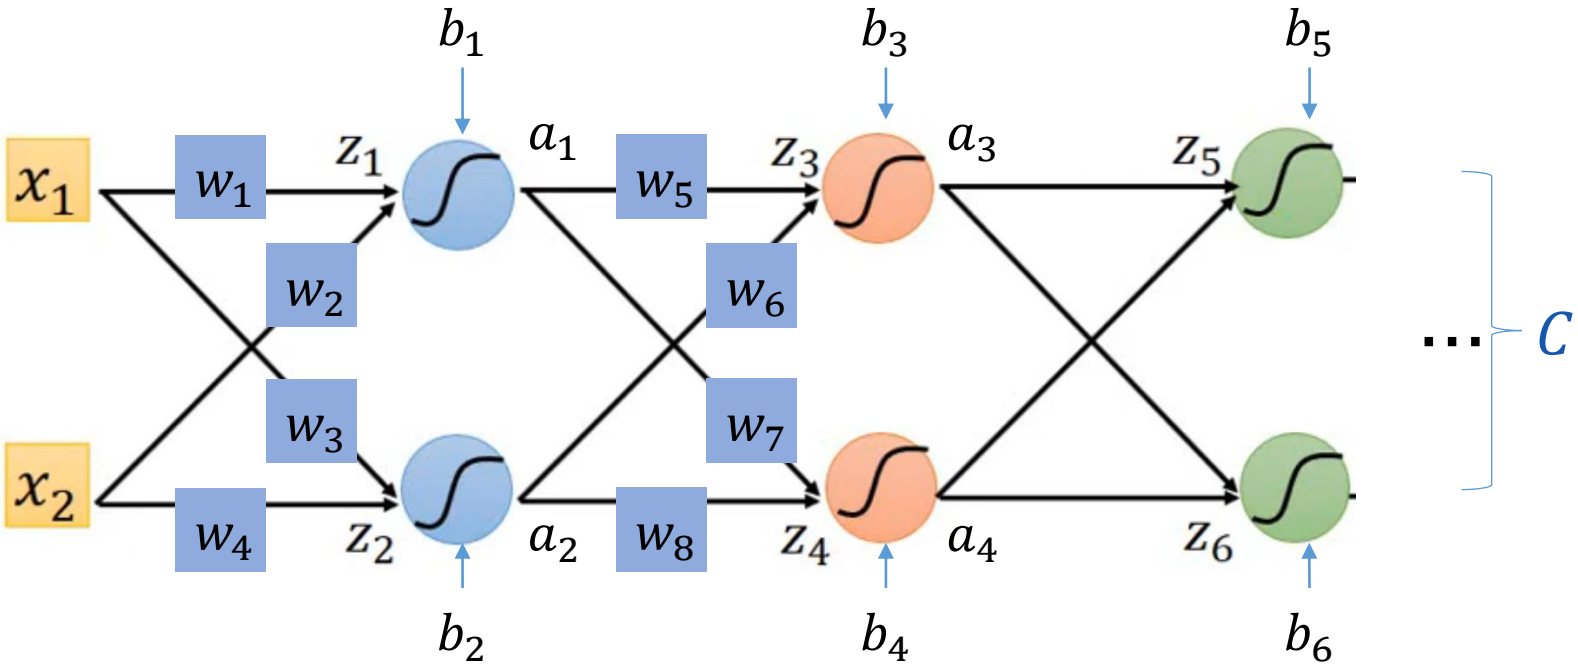
$$\frac{\partial C}{\partial z_4} = \frac{\partial C}{\partial y_2}\frac{\partial y_2}{\partial z_4}$$

输出层，结束

C是y_1和y_2的函数

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法



$$\frac{\partial C}{\partial a_1} = \frac{\partial C}{\partial z_3}\frac{\partial z_3}{\partial a_1} + \frac{\partial C}{\partial z_4}\frac{\partial z_4}{\partial a_1}$$

$$\frac{\partial C}{\partial z_3} = \frac{\partial C}{\partial a_3}\frac{\partial a_3}{\partial z_3}$$

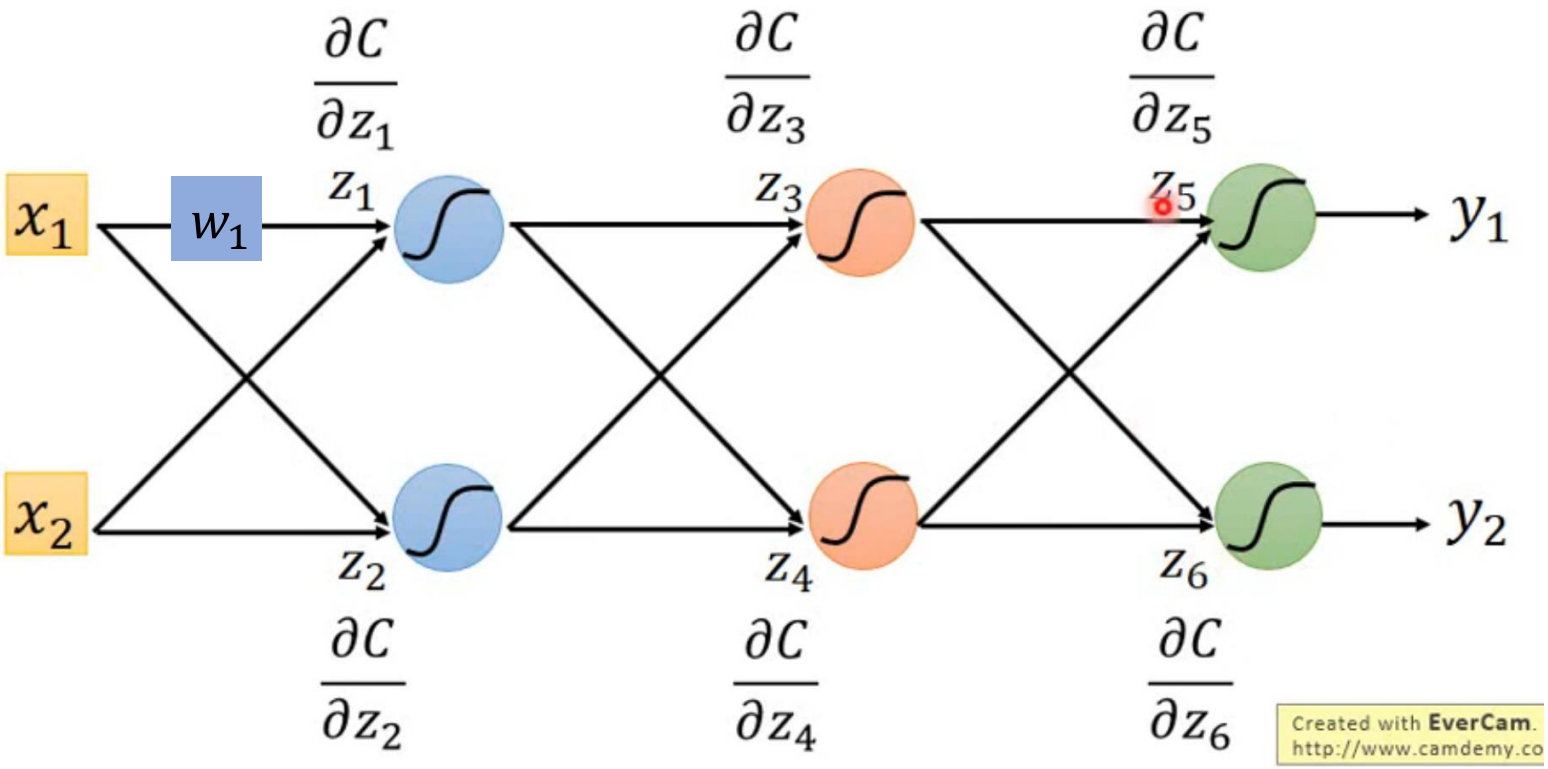
$$\frac{\partial C}{\partial z_4} = \frac{\partial C}{\partial a_4}\frac{\partial a_4}{\partial z_4}$$

非输出层，递归计算$\frac{\partial C}{\partial z}$直到到达输出层

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

从后往前（反向）计算所有的$\frac{\partial C}{\partial z}$

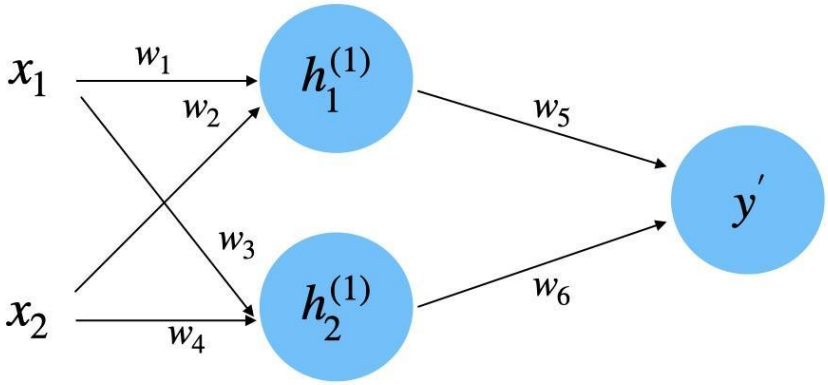


$$\frac{\partial C}{\partial w_1} \leftarrow \frac{\partial C}{\partial z_1} \leftarrow \frac{\partial C}{\partial z_3}, \frac{\partial C}{\partial z_4} \leftarrow \frac{\partial C}{\partial z_5}, \frac{\partial C}{\partial z_6} \leftarrow \cdots$$

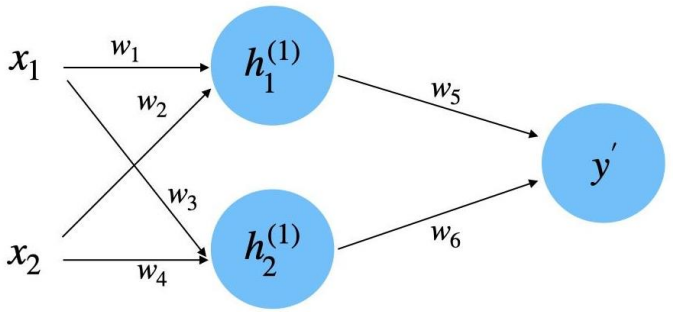
西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

构建一个只有一层的神经网络



正向传播完成



假设这个样本的特征有两个维度，每个维度的值为

$$x_1 = 0.5$$
$$x_2 = 1.0$$

假设这个样本的真实值为：

$$y = 0.8$$

神经网络所有参数随机初始化，且恰好如下

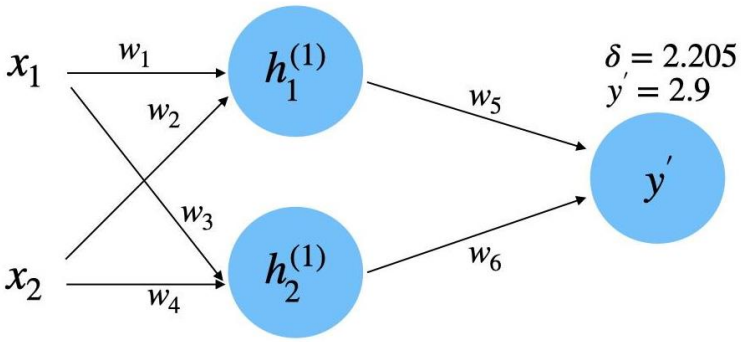
$$w_1 = 1.0$$
$$w_2 = 0.5$$
$$w_3 = 0.5$$
$$w_4 = 0.7$$
$$w_5 = 1.0$$
$$w_6 = 2.0$$

$$\delta = \frac{1}{2}(y - y')^2$$
$$= 0.5(0.8 - 2.9)^2$$
$$= 2.205$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

backward propagation反向传播



以计算w_5为例，w_6同理

$$\frac{\partial \delta}{\partial w_5} = \frac{\partial \delta}{\partial y'} \cdot \frac{\partial y'}{\partial w_5}$$

$$\delta = \frac{1}{2}(y - y')^2$$

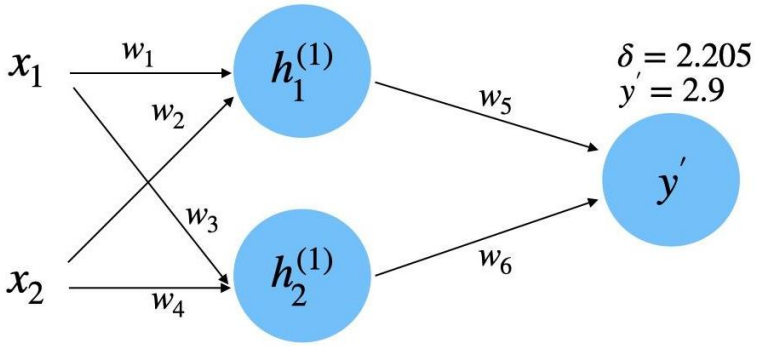
$$\frac{\partial \delta}{\partial y'} = 2 \cdot \frac{1}{2} \cdot (y - y')(-1)$$
$$= y' - y$$
$$= 2.9 - 0.8 = 2.1$$

$$y' = w_5 \cdot h_1^{(1)} + w_6 \cdot h_2^{(1)}$$

$$\frac{\partial y'}{\partial w_5} = h_1^{(1)} + 0$$
$$= 1.0$$

$$\frac{\partial \delta}{\partial w_5} = 2.1 \cdot 1.0 = 2.1$$

backward propagation反向传播



那么便可更新w5的值

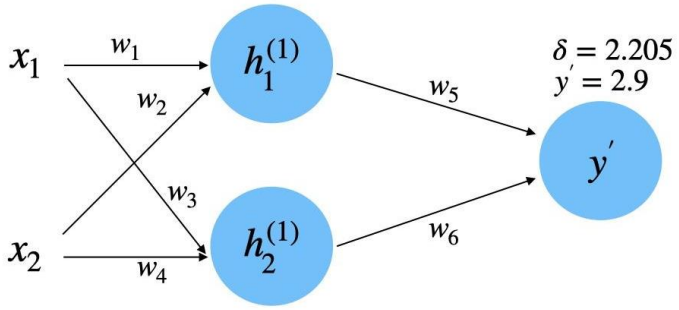
学习率，属于超参数，自行设定

$$w_5^{(update)} = w_5 - \eta \cdot \frac{\partial \delta}{\partial w_5}$$
$$= 1.0 - 0.1 \cdot 2.1$$
$$= 0.79$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

backward propagation反向传播



以计算w_1为例，
w_2, w_3, w_4同理

$$\frac{\partial \delta}{\partial w_1} = \frac{\partial \delta}{\partial y'} \cdot \frac{\partial y'}{\partial h_1^{(1)}} \cdot \frac{\partial h_1^{(1)}}{\partial w_1}$$

$$\delta = \frac{1}{2}(y - y')^2$$

$$\frac{\partial \delta}{\partial y'} = 2 \cdot \frac{1}{2} \cdot (y - y')(-1)$$
$$= y' - y$$
$$= 2.9 - 0.8$$
$$= 2.1$$

$$y' = w_5 \cdot h_1^{(1)} + w_6 \cdot h_2^{(1)}$$

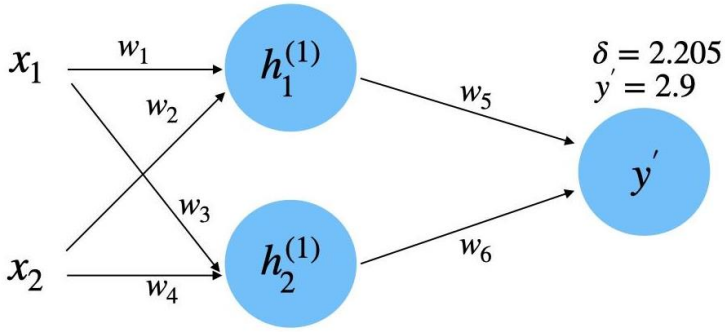
$$\frac{\partial y'}{\partial h_1^{(1)}} = w_5 + 0$$
$$= 1.0$$

$$h_1^{(1)} = w_1 \cdot x_1 + w_2 \cdot x_2$$

$$\frac{\partial h_1^{(1)}}{\partial w_1} = x_1 + 0$$
$$= 0.5$$

$$\frac{\partial \delta}{\partial w_1} = 2.1 \cdot 1.0 \cdot 0.5 = 1.05$$

backward propagation反向传播



那么便可更新w_1的值

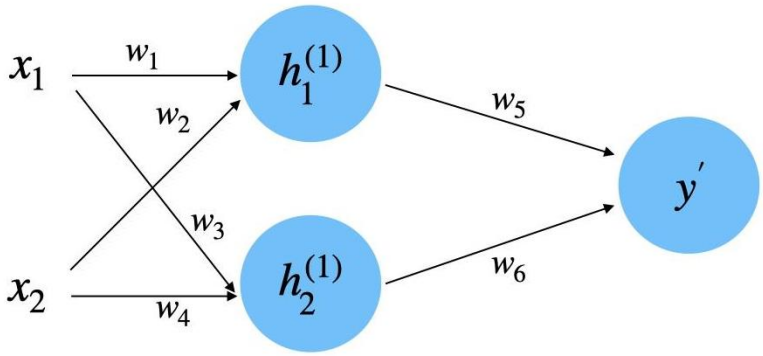
学习率，属于超参数，自行设定

$$w_1^{(update)} = w_1 - \eta \cdot \frac{\partial \delta}{\partial w_1}$$
$$= 1.0 - 0.1 \cdot 1.05$$
$$= 0.895$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.1 BP 算法

backward propagation反向传播



假设这个样本的特征有两个维度，每个维度的值为

$$x_1 = 0.5$$
$$x_2 = 1.0$$

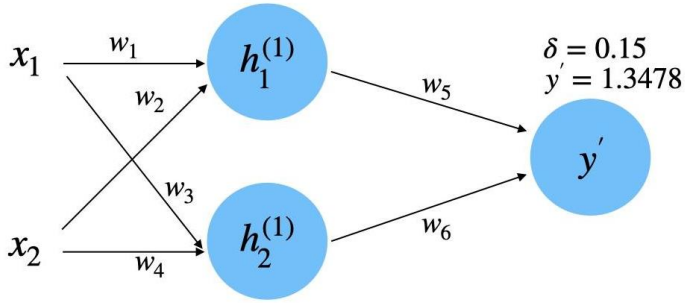
假设这个样本的真实值为：

$$y = 0.8$$

一轮正向反向传播后更新得到的参数：

$$w_1 = 0.895$$
$$w_2 = 0.29$$
$$w_3 = 0.29$$
$$w_4 = 0.28$$
$$w_5 = 0.79$$
$$w_6 = 1.8005$$

第二轮正向传播得到的误差



$$h_1^{(1)} = w_1 \cdot x_1 + w_2 \cdot x_2 = 0.895 \cdot 0.5 + 0.29 \cdot 1.0 = 0.7375$$

$$h_2^{(1)} = w_3 \cdot x_1 + w_4 \cdot x_2 = 0.29 \cdot 0.5 + 0.28 \cdot 1.0 = 0.425$$

$$y' = w_5 \cdot h_1^{(1)} + w_6 \cdot h_2^{(1)} = 0.79 \cdot 0.7375 + 1.8005 \cdot 0.425 = 1.3478$$

误差比第一轮减小了

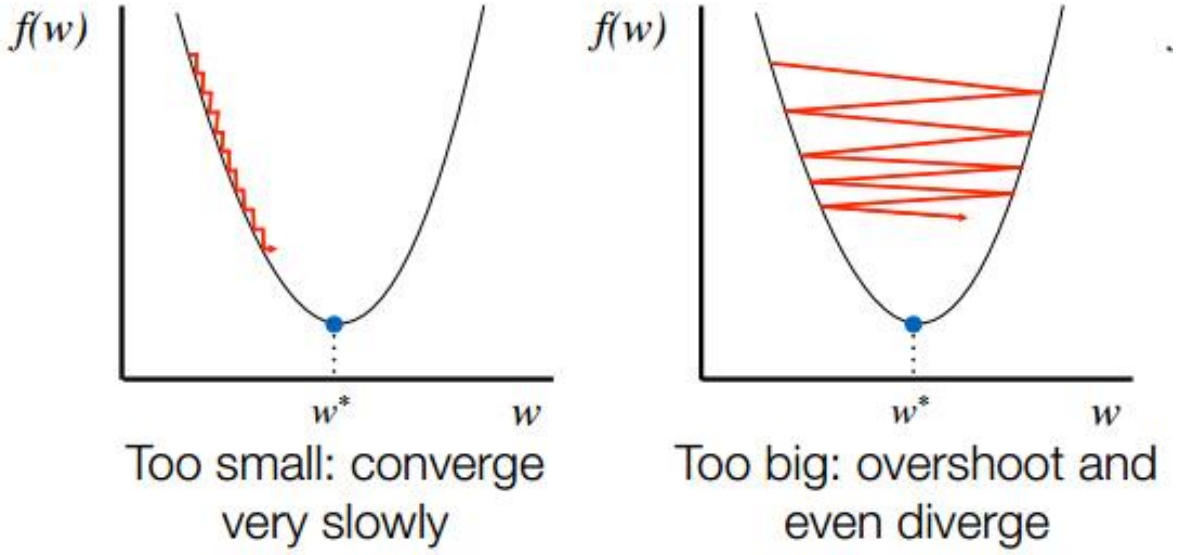
$$\delta = \frac{1}{2}(y - y')^2 = 0.5(0.8 - 1.3478)^2 = 0.15$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

（1）学习速率

学习速率η直接影响权系数调整时的步长。学习速率过小，导致算法收敛速度缓慢。学习速率过大，导致算法不收敛。学习速率的典型取值$\eta \approx 0.1$。另外学习速率可变。

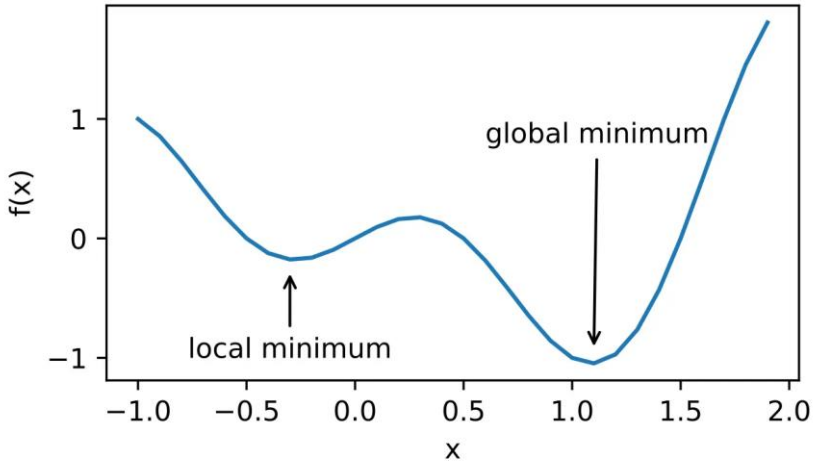


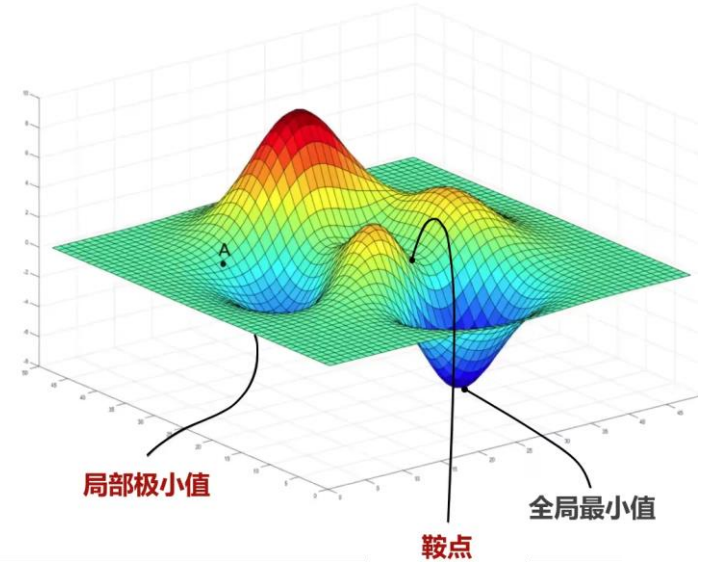
7.2.2 训练问题

（2）损失函数的局部极小值

调整权系数的目标是使损失函数取得最小值。 但是采用梯度下降法不能保证获得最小值，而只能保证得到一个极小值。

如果训练过程无法使损失函数降低到预期的程度，一种常用的方法是：再一次对权系数进行随机初始化，并重新训练网络。



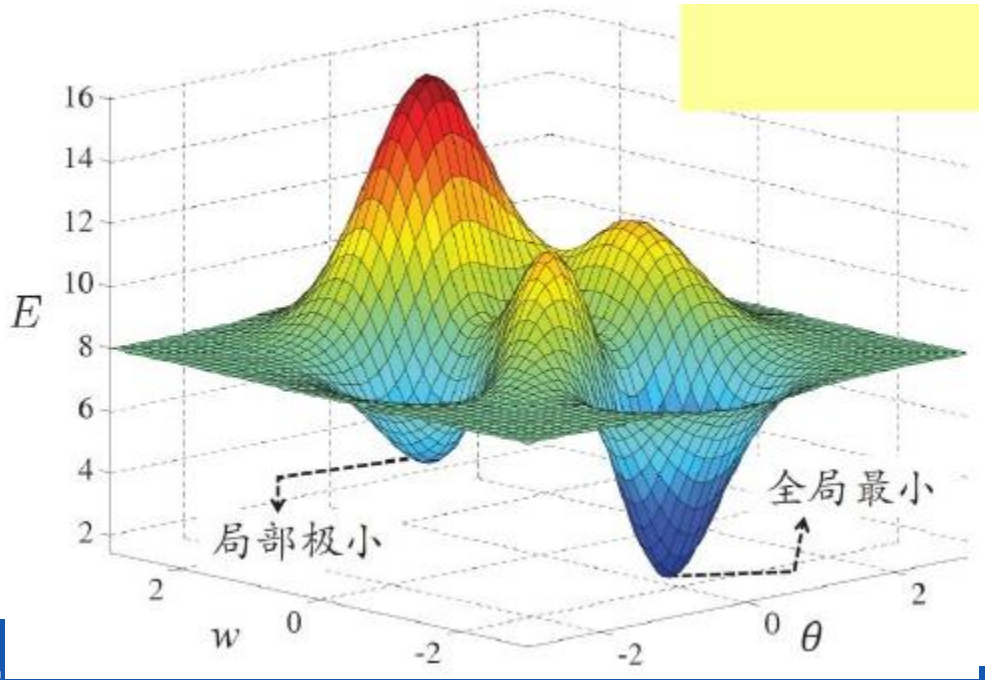


西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

全局最小 vs. 局部极小

- 神经网络的训练过程可看作一个参数寻优过程：
- 在参数空间中，寻找一组最优参数使得误差最小
- 然而存在多个“局部极小”，只有一个“全局最小”



“跳出”局部极小的常见策略：

- ✓ 不同的初始参数
- ✓ 模拟退火
- ✓ 随机扰动
- ✓ 遗传算法
- ✓ ……

西安交通大學 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

(1)以多组不同参数值初始化多个神经网络，按标准方法训练后，取其中误差最小的解作为最终参数。这相当于从多个不同的初始点开始搜索，这样就可能陷入不同的局部极小，从中进行选择有可能获得更接近全局最小的结果。

(2)使用“模拟退火”（simulated annealing） 技术 [Aarts and Korst, 1989]。模拟退火在每一步都以一定的概率接受比当前解更差的结果，从而有助于“跳出”局部极小.在每步迭代过程中，接受“次优解”的概率要随着时间的推移而逐渐降低，从而保证算法稳定。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

(3) 使用随机梯度下降。与标准梯度下降法精确计算梯度不同，随机梯度下降法在计算梯度时加入了随机因素。于是，即便陷入局部极小点，它计算出的梯度仍可能不为零，这样就有机会跳出局部极小继续搜索。

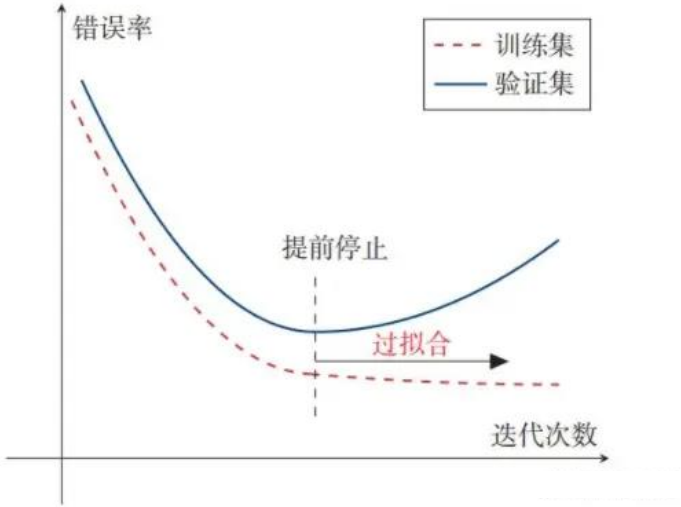
西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

（3）结束训练的准则

过度拟合：在经过长时间的训练以后，神经网络对训练样本的分类能力很好，但是对测试样本的分类能力却很差，这一现象称为过度拟合。

结束训练的准则：通过学习曲线可以避免过度拟合的发生。在验证集上的平均误差函数取得最小值的时候，就可以停止训练过程，并认为此时的权系数为最优的权系数。



7.2.2 训练问题

缓解过拟合主要策略：

（1）早停（early stopping）

若训练误差连续 a 轮的变化小于 b，则停止训练；

使用验证集：若训练误差降低、验证误差升高，则停止训练

（2）正则化（regularization）

在误差目标函数中增加一项描述网络复杂度

例如 $$E = \lambda \frac{1}{m} \sum_{k=1}^{m} E_k + (1-\lambda) \sum_i w_i^2$$

偏好比较小的连接权和阈值，使网络输出更“光滑”

西安交通大学 XI'AN JIAOTONG UNIVERSITY

7.2.2 训练问题

（4）隐层单元数量的确定

- 隐层单元的数量直接决定了神经网络的复杂度。
- 隐层单元数量过少，无法实现复杂的分类面，因此无法对复杂的数据分布进行有效分类。隐层单元数量过多，容易产生过度拟合，因此影响对未来新样本的分类能力。

- 经验法则：隐层单元数量决定了网络权系数的数量。合适的单元数量应该保证网络权系数的数量近似等于N/10（N为训练集中样本的数量）。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

完

谢谢

课程智能体

http://10.184.27.128:8888/

西安交通大学 XI'AN JIAOTONG UNIVERSITY